

# 机器学习

# Machine Learning

肖力

信息科学技术学院—6系

<https://faculty.ustc.edu.cn/xiaoli>

# 第1章：基本术语

# 数据


| 特征或属性 |    |    |    | 标签 |
|-------|----|----|----|----|
| ↑     |    |    |    | ↑  |
| 编号    | 色泽 | 根蒂 | 敲声 | 好瓜 |
| 1     | 青绿 | 蜷缩 | 浊响 | 是  |
| 2     | 乌黑 | 蜷缩 | 沉闷 | 是  |
| 3     | 青绿 | 硬挺 | 清脆 | 否  |
| 4     | 乌黑 | 稍蜷 | 沉闷 | 否  |
|       |    |    |    |    |
| 1     | 青绿 | 蜷缩 | 沉闷 | ?  |

训练集←

测试集←

# 样本空间

- 属性或特征张成的空间称为属性空间、样本空间、或输入空间。



# 预测任务

---

## □ 预测目标:

### ○ 分类: 离散值

- 二分类: 好瓜; 坏瓜

- 多分类: 冬瓜; 南瓜; 西瓜

### ○ 回归: 连续值

- 瓜的成熟度


### ○ 聚类: 无标记信息

# 泛化能力

- 机器学习的目标是使得学到的模型能很好的适用于“新样本”，而不仅仅是训练集合，我们称模型适用于新样本的能力为泛化（generalization）能力。
- 通常假设样本空间中的样本服从一个未知分布  $\mathcal{D}$ ，样本从这个分布中独立获得，即“独立同分布” (independent and identically distributed, 简称i.i.d.)。一般而言，训练样本越多，得到的关于  $\mathcal{D}$  的信息越多，越有可能通过学习获得强泛化能力的模型。

# 假设空间

- **假设空间**：输入到输出的可能映射的集合。学习过程就是在假设空间中进行搜索的过程，搜索目标是找到与训练集匹配的假设。



# 假设空间

| 编号 | 色泽 | 根蒂 | 敲声 | 好瓜 |
|----|----|----|----|----|
| 1  | 青绿 | 蜷缩 | 浊响 | 是  |
| 2  | 乌黑 | 蜷缩 | 沉闷 | 是  |
| 3  | 青绿 | 硬挺 | 清脆 | 否  |
| 4  | 乌黑 | 稍蜷 | 沉闷 | 否  |


**$(\text{色泽}=?)\wedge(\text{根蒂}=?)\wedge(\text{敲声}=?)\leftrightarrow\text{好瓜}$**

**色泽：**青绿、乌黑、浅白； **根蒂：**蜷缩、硬挺、稍蜷；  
**敲声：**浊响、沉闷、清脆

**在模型空间中搜索不违背训练集的假设，  
假设空间大小：  $4*4*4+1=65$**

# 归纳偏好


假设空间中有三个与训练集一致的假设



| 编号 | 色泽 | 根蒂 | 敲声 | 好瓜 |
|----|----|----|----|----|
| 1  | 青绿 | 蜷缩 | 浊响 | 是  |
| 2  | 乌黑 | 蜷缩 | 沉闷 | 是  |
| 3  | 青绿 | 硬挺 | 清脆 | 否  |
| 4  | 乌黑 | 稍蜷 | 沉闷 | 否  |

# 归纳偏好


假设空间中有三个与训练集一致的假设，但他们对（色泽=青绿；根蒂=蜷缩；敲声=沉闷）的瓜会预测出不同的结果：



| 编号 | 色泽 | 根蒂 | 敲声 | 好瓜 |
|----|----|----|----|----|
| 1  | 青绿 | 蜷缩 | 浊响 | 是  |
| 2  | 乌黑 | 蜷缩 | 沉闷 | 是  |
| 3  | 青绿 | 硬挺 | 清脆 | 否  |
| 4  | 乌黑 | 稍蜷 | 沉闷 | 否  |

# 归纳偏好

假设空间中有三个与训练集一致的假设，但他们对（色泽=青绿；根蒂=蜷缩；敲声=沉闷）的瓜会预测出不同的结果：



**选取哪个假设作为学习模型？**


# 归纳偏好

---

机器学习算法在学习过程中对某种类型假设的偏好称作归纳偏好。任何一个有效的机器学习算法必有其归纳偏好，才能找出它认为“正确”的模型。

# 归纳偏好


机器学习算法在学习过程中对某种类型假设的偏好称作**归纳偏好**。任何一个有效的机器学习算法必有其归纳偏好，才能找出它认为“正确”的模型。





存在多条曲线与有限样本训练集一致

# 归纳偏好

机器学习算法在学习过程中对某种类型假设的偏好称作**归纳偏好**。任何一个有效的机器学习算法必有其归纳偏好，才能找出它认为“正确”的模型。



存在多条曲线与有限样本训练集一致



没有免费的午餐. (黑点: 训练样本; 白点: 测试样本)

# 归纳偏好

---

- 归纳偏好可看作学习算法自身在一个可能很庞大的假设空间中对假设进行选择的启发式或“价值观”。
- “奥卡姆剃刀”（Occam's razor）是一种常用的、自然科学研究中最基本的原则，即“若有多个假设与观察一致，选最简单的那个”。
- 具体的现实问题中，学习算法本身所做的假设是否成立，也即算法的归纳偏好是否与问题本身匹配，大多数时候直接决定了算法能否取得好的性能。

# No Free Lunch

一个算法  $\xi_a$  如果在某些问题上比另一个算法  $\xi_b$  好, 必然存在另一些问题  $\xi_b$  比  $\xi_a$  好, 也即 “**没有免费的午餐**” (No Free Lunch, 简称 NLF) 定理。

简单起见, 假设样本空间  $\mathcal{X}$  和假设空间  $\mathcal{H}$  离散, 令  $P(h|X, \mathcal{L}_a)$  代表算法  $\mathcal{L}_a$  基于训练数据  $X$  产生假设  $h$  的概率, 在令  $f$  代表要学的目标函数,  $\mathcal{L}_a$  在训练集之外所有样本上的总误差为

$$E_{ote}(\mathcal{L}_a|X, f) = \sum_h \sum_{\mathbf{x} \in \mathcal{X} - X} P(\mathbf{x}) \mathbb{I}(h(\mathbf{x}) \neq f(\mathbf{x})) P(h | X, \mathcal{L}_a)$$

其中,  $\mathbb{I}(\cdot)$  为指示函数, 若  $\cdot$  为真取值 1, 否则取值 0.

# No Free Lunch

考虑二分类问题，目标函数可以为任何函数  $\mathcal{X} \mapsto \{0, 1\}$ ，函数空间为  $\{0, 1\}^{|\mathcal{X}|}$ ，对所有可能  $f$  按均匀分布对误差求和，有：

$$\begin{aligned}\sum_f E_{ote}(\mathcal{L}_a | X, f) &= \sum_f \sum_h \sum_{\mathbf{x} \in \mathcal{X}-X} P(\mathbf{x}) \mathbb{I}(h(\mathbf{x}) \neq f(\mathbf{x})) P(h | X, \mathcal{L}_a) \\&= \sum_{\mathbf{x} \in \mathcal{X}-X} P(\mathbf{x}) \sum_h P(h | X, \mathcal{L}_a) \sum_f \mathbb{I}(h(\mathbf{x}) \neq f(\mathbf{x})) \\&= \sum_{\mathbf{x} \in \mathcal{X}-X} P(\mathbf{x}) \sum_h P(h | X, \mathcal{L}_a) \frac{1}{2} 2^{|\mathcal{X}|} \\&= \frac{1}{2} 2^{|\mathcal{X}|} \sum_{\mathbf{x} \in \mathcal{X}-X} P(\mathbf{x}) \sum_h P(h | X, \mathcal{L}_a) \\&= 2^{|\mathcal{X}|-1} \sum_{\mathbf{x} \in \mathcal{X}-X} P(\mathbf{x}) \cdot 1. \quad \text{总误差与学习算法无关!}\end{aligned}$$

**NFL定理的寓意：**实际问题中，并非所有问题出现的可能性都相同，脱离具体问题，空谈“什么学习算法更好”毫无意义。

# 本章总结

---

- **数据**：特征、标签、训练集、测试集
- **样本空间**：特征张成的空间
- **预测任务**：分类（二分类和多分类）、回归、聚类
- **泛化能力**：模型适用于新样本的能力
- **假设空间**：输入到输出的可能映射的集合
- **归纳偏好**：学习过程中对某种类型假设的偏好
- **No Free Lunch**：必须针对具体的学习问题，来谈论算法的相对优劣，否则毫无意义

P P T 结 束 页

谢谢！

