

机器学习

Machine Learning

肖力

信息科学技术学院—6系

<https://faculty.ustc.edu.cn/xiaoli>

第2章：模型评估与选择

经验误差与过拟合

❑ 错误率&误差：

- 错误率

错误率即错分样本的占比： $E = a/m$

- 误差

误差即样本真实输出与预测输出之间的差异

- 训练(经验)误差 ← 训练集

- 泛化误差 ← 除训练集外所有样本（对未参与训练的样本总体）

经验误差与过拟合

□ 错误率&误差：

● 错误率

错误率即错分样本的占比： $E = a/m$

● 误差

误差即样本真实输出与预测输出之间的差异

● 训练(经验)误差 ← 训练集

● 泛化误差 ← 除训练集外所有样本（对未参与训练的样本总体）

★ 机器学习的目的是通过现有样本，学习到泛化误差小的预测模型；

由于事先并不知道新样本的特征，我们只能努力使经验误差最小化；但是，一味地减小经验误差并不必然意味着泛化误差减小。很多时候虽然能在训练集上做到分类错误率为零，但多数情况下这样的学习器并不好。

经验误差与过拟合

□ 过拟合:

学习器把训练样本学习的“太好”，将训练样本本身的特点当做所有潜在样本都具有的一般性质，这样就会导致泛化性能下降。

- 特征降维（降低模型的复杂度）
 - 优化目标加正则项（限制优化目标的搜索空间）
-
- 为此，应该从训练样本中尽可能学习出适用于所有潜在样本的“普遍规律”，这样才能在遇到新样本的时候做出正确的判读。

经验误差与过拟合



经验误差与过拟合

□ 过拟合:

学习器把训练样本学习的“太好”，将训练样本本身的特点当做所有样本的一般性质，导致泛化性能下降

- 特征降维（降低模型的复杂度）
- 优化目标加正则项（限制优化目标的搜索空间）


□ 欠拟合:

对训练样本的一般性质尚未学好

- 决策树: 拓展分支
- 神经网络: 增加训练轮数

经验误差与过拟合

树叶训练样本



新样本



过拟合模型分类结果：
→ 不是树叶
(误以为树叶必须有锯齿)



欠拟合模型分类结果：
→ 是树叶
(误以为绿色的都是树叶)

过拟合、欠拟合的直观类比

评估方法

- 模型的泛化误差无法直接获取，而训练误差由于过拟合现象的存在而不适合作为模型选择的标准。

评估方法

- 模型的泛化误差无法直接获取，而训练误差由于过拟合现象的存在而不适合作为模型选择的标准。
- 通常，我们通过实验测试来对模型的泛化误差进行评估并进而做出选择。为此，需要一个测试集来测试模型对新样本的判别能力。

评估方法

- 模型的泛化误差无法直接获取，而训练误差由于过拟合现象的存在而不适合作为模型选择的标准。
- 通常，我们通过实验测试来对模型的泛化误差进行评估并进而做出选择。为此，需要一个测试集来测试模型对新样本的判别能力。
- 我们假设测试集是从样本真实分布中独立采样获得，将测试集上的“测试误差”作为泛化误差的近似，所以测试集要和训练集中的样本尽量互斥。

评估方法

我们只有一个包含 m 个样本的数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$
那怎么样才能既要有训练集，又要有测试集呢？

评估方法

我们只有一个包含 m 个样本的数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$
那怎么样才能既要有训练集，又要有测试集呢？

拆分成训练集 S 和测试集 T ，使得 $D = S \cup T$, $S \cap T = \emptyset$

评估方法

我们只有一个包含 m 个样本的数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$
那怎么样才能既要有训练集，又要有测试集呢？

拆分成训练集 S 和测试集 T ，使得 $D = S \cup T$, $S \cap T = \emptyset$

- 训练集-测试集窘境：若训练集 S 越大，则训练出来的模型可能更接近于用 D 训练出来的模型，但由于测试集 T 较小，评估结果可能不够稳定准确；若测试集 T 越大，则训练集 S 与 D 差别更大，被评估的模型与用 D 训练出来的模型相比可能有较大差异，从而降低了评估结果的保真性。

评估方法


□ 留出法 (hold-out) :

- 直接将数据集划分为两个互斥集合
- 训练/测试集划分要尽可能保持数据分布的一致性，避免因数据划分过程引入额外的偏差而对最终结果产生影响
- 一般若干次随机划分、重复实验取平均值
- 训练/测试样本比例通常为**2:1~4:1**

评估方法

□ 交叉验证法 (cross validation) :

将数据集**分层采样**划分为**k**个大小相似的互斥子集，每次用**k-1**个子集的并集作为训练集，余下的一个子集作为测试集，最终返回**k**个测试结果的均值，**k**最常用的取值是**10**.



10 折交叉验证示意图

评估方法

与留出法类似，将数据集 D 划分为 k 个子集同样存在多种划分方式，为了减小因样本划分不同而引入的差别， k 折交叉验证通常随机使用不同的划分重复 p 次，最终的评估结果是这 p 次 k 折交叉验证结果的均值，例如常见的“10次10折交叉验证”。

假设数据集 D 包含 m 个样本，若令 $k = m$ ，则得到留一法：

- 不受随机样本划分方式的影响
- 结果往往比较准确：因为训练集与 D 只少一个样本，故被评估出来的模型与用 D 训练出的模型很相似
- 当数据集比较大时，计算开销太大

评估方法

□ 自助法 (bootstrapping) :

以自助采样法为基础，对数据集 D 有放回采样 m 次得到训练集 D' ， $D \setminus D'$ 用做测试集。

- 实际模型与预期模型都使用 m 个训练样本
- 显然有一部分样本会在训练集中多次出现，而另一部分样本不出现。约有 $1/3$ 的样本没在训练集中出现

$$\lim_{m \rightarrow \infty} \left(1 - \frac{1}{m}\right)^m \mapsto \frac{1}{e} \approx 0.368, \quad (2.1)$$

- 自助法在数据集较小、难以有效划分训练/测试集时很有用；由于改变了数据集分布可能引入估计偏差，在数据量足够时，留出法和交叉验证法更常用。

性能度量

- 对模型的泛化性能进行评估，除了需要有效的实验估计方法，还需要衡量模型泛化性能的评价标准。
- 性能度量是衡量模型泛化能力的评价标准，反映了任务需求；使用不同的性能度量往往会导致不同的评判结果。

性能度量

- 对模型的泛化性能进行评估，除了需要有效的实验估计方法，还需要衡量模型泛化性能的评价标准。
- 性能度量是衡量模型泛化能力的评价标准，反映了任务需求；使用不同的性能度量往往会导致不同的评判结果。
- 在预测任务中，给定样例集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$ ，评估学习器 f 的性能，就是把预测结果 $f(\mathbf{x})$ 和真实标记比较，估计出 $f(\mathbf{x})$ 和真实标记的接近程度。

性能度量

- 回归任务最常用的性能度量是“均方误差”（MSE）：

$$E(f; D) = \frac{1}{m} \sum_{i=1}^m (f(\mathbf{x}_i) - y_i)^2$$

性能度量

- 回归任务最常用的性能度量是“均方误差”（MSE）：

$$E(f; D) = \frac{1}{m} \sum_{i=1}^m (f(\mathbf{x}_i) - y_i)^2$$

- 平均绝对值误差（MAE）： $\frac{1}{m} \sum_{i=1}^m (|y_i - f(\mathbf{x}_i)|)$

- Pearson's correlation coefficient: $\frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$

- 决定系数：

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

性能度量

- 对于分类任务，错误率和精度是最常用的两种性能度量：
 - 错误率：分错样本占样本总数的比率
 - 精度（正确率）：分对样本占样本总数的比率

分类错误率

$$E(f; D) = \frac{1}{m} \sum_{i=1}^m \mathbb{I}(f(\mathbf{x}_i) \neq y_i)$$

精度（正确率）

$$\begin{aligned} \text{acc}(f; D) &= \frac{1}{m} \sum_{i=1}^m \mathbb{I}(f(\mathbf{x}_i) = y_i) \\ &= 1 - E(f; D) . \end{aligned}$$

性能度量

- 信息检索、Web搜索等场景中经常需要衡量正例被预测出来的比率或者预测出来的正例中正确的比率，此时查准率和查全率比错误率和精度更适合。

统计真实标记和预测结果的组合可得到“混淆矩阵” confusion matrix

分类结果混淆矩阵

真实情况	预测结果	
	正例	反例
正例	TP (真正例)	FN (假反例)
反例	FP (假正例)	TN (真反例)


查准率
(精确率, precision) $P = \frac{TP}{TP + FP}$

查全率
(召回率, recall;
灵敏度, sensitivity) $R = \frac{TP}{TP + FN}$

查准率和查全率是一对矛盾的指标。

性能度量

如何评价二分类模型！混淆矩阵、召回率、精确率、准确率




性能度量

- 对样本进行分类时，模型一般会存在置信度，即当判断一个样本为目标类别的概率。根据学习器的预测结果按正例可能性大小对样例进行排序，并逐个把样本作为正例进行预测，则可以得到查准率-查全率曲线，简称“P-R曲线”

样本ID	原本类别	预测概率	阈值=0.95	阈值=0.86	阈值=0.7
1	正	0.95	正	正	正
2	正	0.86	负	正	正
3	负	0.70	负	负	正
4	正	0.65	负	负	负
5	正	0.55	负	负	负
6	负	0.53	负	负	负
7	负	0.52	负	负	负
8	负	0.43	负	负	负
9	正	0.42	负	负	负
10	负	0.35	负	负	负

性能度量

- 对样本进行分类时，模型一般会存在置信度，即当判断一个样本为目标类别的概率。根据学习器的预测结果按正例可能性大小对样例进行排序，并逐个把样本作为正例进行预测，则可以得到查准率-查全率曲线，简称“P-R曲线”



P-R曲线与平衡点示意图

平衡点是曲线上“查准率=查全率”时的取值，可用来用于度量P-R曲线有交叉的分类器性能高低。学习器A好于学习器B

性能度量

- 比P-R曲线平衡点更常用的是F1度量：

$$F1 = \frac{2 \times P \times R}{P + R} = \frac{2 \times TP}{\text{样例总数} + TP - TN}$$

在一些应用中，对查准率和查全率的重视程度有所不同，故有比F1更一般的形式 F_β ，

$$F_\beta = \frac{(1 + \beta^2) \times P \times R}{(\beta^2 \times P) + R}$$


$\beta = 1$: 标准F1

$\beta > 1$: 偏重查全率(逃犯信息检索)

$\beta < 1$: 偏重查准率(商品推荐系统)

性能度量

- 类似P-R曲线，根据学习器的预测结果对样例排序，并逐个作为正例进行预测。通过阈值，将样本分为两部分，前部分判作正例，后部分判作反例。在不同应用任务中，可根据任务需求采用不同的阈值，例如若更重视查准率，可选择排序中靠前的位置进行截断；若更重视查全率，则选择靠后的位置进行截断。




性能度量

- 类似P-R曲线，根据学习器的预测结果对样例排序，并逐个作为正例进行预测。通过阈值，将样本分为两部分，前部分判作正例，后部分判作反例。在不同应用任务中，可根据任务需求采用不同的阈值，例如若更重视查准率，可选择排序中靠前的位置进行截断；若更重视查全率，则选择靠后的位置进行截断。

综合考虑学习器在不同任务下（一般情况下）的“期望泛化性能”的好坏，ROC曲线被引入。以“假正例率FPR”为横轴（specificity, 特异度），“真正例率TPR”（查全率、或者sensitivity, 灵敏度）为纵轴可得到ROC曲线, 全称“受试者工作特征”曲线。


$$\text{TPR} = \frac{TP}{TP + FN}, \quad \text{FPR} = \frac{FP}{TN + FP}.$$

性能度量




查准率：所有预测为正例的样本中，真正为正例的样本占比。查准率越高，说明模型的误判率越低。

性能度量



查全率、真正例率：所有真正为正例的样本中，被模型预测为正例的样本占比。查全率越高，说明模型的漏判率越低。


性能度量



假正例率：所有真正为反例的样本中，被模型预测为正例的样本占比。

性能度量

ROC图的绘制：给定 m^+ 个正例和 m^- 个负例，根据学习器预测结果对样例进行排序，将分类阈值设为每个样例的预测值，当前标记点坐标为 (x, y) ，当前若为真正例，则对应标记点的坐标为 $(x, y + \frac{1}{m^+})$ ；当前若为假正例，则对应标记点的坐标为 $(x + \frac{1}{m^-}, y)$ ，然后用线段连接相邻点。



性能度量

样本ID	原本类别	预测概率	阈值=0.95	阈值=0.86	阈值=0.7
1	正	0.95	正	正	正
2	正	0.86	负	正	正
3	负	0.70	负	负	正
4	正	0.65	负	负	负
5	正	0.55	负	负	负
6	负	0.53	负	负	负
7	负	0.52	负	负	负
8	负	0.43	负	负	负
9	正	0.42	负	负	负
10	负	0.35	负	负	负


以阈值为0.95为例

$$\text{FPR} = 0/5 = 0$$

$$\text{TPR} = 1/5 = 0.2$$


对应到坐标系的点即为[0,0.2]

(0, 0) (0, 0.2) (0, 0.4) (0.2, 0.4) (0.2, 0.6) (0.2, 0.8)
(0.4, 0.8) (0.6, 0.8) (0.8, 0.8) (0.8, 1.0) (1.0, 1.0)



性能度量

- 若某个学习器的ROC曲线被另一个学习器的曲线“包住”，则后者性能优于前者；否则如果曲线交叉，可以根据ROC曲线下面积大小进行比较，也即AUC值.



基于有限样例绘制的 ROC 曲线
与 AUC

假设ROC曲线由 $\{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$ 的点按序连接而形成 $(x_1 = 0, x_m = 1)$ ，则：
AUC可估算为：

$$\text{AUC} = \frac{1}{2} \sum_{i=1}^{m-1} (x_{i+1} - x_i) \cdot (y_i + y_{i+1})$$

AUC衡量了样本预测的排序质量。

偏差与方差

- 通过实验可以估计学习算法的泛化性能，而“偏差-方差分解”可以用来帮助解释泛化性能。偏差-方差分解试图对学习算法期望的泛化错误率进行拆解。
- 对测试样本 $\boldsymbol{x}$ ，令 y_D 为 $\boldsymbol{x}$ 在数据集中的标记， y 为 $\boldsymbol{x}$ 的真实标记， $f(\boldsymbol{x}; D)$ 为训练集 D 上学得模型 f 在 $\boldsymbol{x}$ 上的预测输出。以回归任务为例：学习算法的期望预期为：

$$\bar{f}(\boldsymbol{x}) = \mathbb{E}_D[f(\boldsymbol{x}; D)]$$

使用样本数目相同的不同训练集产生的方差为

$$\text{var}(\boldsymbol{x}) = \mathbb{E}_D \left[(f(\boldsymbol{x}; D) - \bar{f}(\boldsymbol{x}))^2 \right]$$

噪声为

$$\varepsilon^2 = \mathbb{E}_D \left[(y_D - y)^2 \right]$$

偏差与方差

□ 期望输出与真实标记的差别称为偏差，即 $\text{bias}^2(\mathbf{x}) = (\bar{f}(\mathbf{x}) - y)^2$

为便于讨论，假定噪声期望为0，即 $\mathbb{E}_D[y_D - y] = 0$ ，对泛化误差分解

$$\begin{aligned} E(f; D) &= \mathbb{E}_D \left[(f(\mathbf{x}; D) - y_D)^2 \right] \\ &= \mathbb{E}_D \left[(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}) + \bar{f}(\mathbf{x}) - y_D)^2 \right] \\ &= \mathbb{E}_D \left[(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}))^2 \right] + \mathbb{E}_D \left[(\bar{f}(\mathbf{x}) - y_D)^2 \right] \\ &\quad + \mathbb{E}_D \left[2(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}))(\bar{f}(\mathbf{x}) - y_D) \right] \\ &= \mathbb{E}_D \left[(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}))^2 \right] + \mathbb{E}_D \left[(\bar{f}(\mathbf{x}) - y_D)^2 \right] \end{aligned}$$

偏差与方差

$$\begin{aligned} &= \mathbb{E}_D \left[(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}))^2 \right] + \mathbb{E}_D \left[(\bar{f}(\mathbf{x}) - y + y - y_D)^2 \right] \\ &= \mathbb{E}_D \left[(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}))^2 \right] + \mathbb{E}_D \left[(\bar{f}(\mathbf{x}) - y)^2 \right] + \mathbb{E}_D \left[(y - y_D)^2 \right] \\ &\quad + 2\mathbb{E}_D \left[(\bar{f}(\mathbf{x}) - y)(y - y_D) \right] \end{aligned}$$

又由假设中噪声期望为**0**，可得

$$E(f; D) = \mathbb{E}_D \left[(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}))^2 \right] + (\bar{f}(\mathbf{x}) - y)^2 + \mathbb{E}_D \left[(y_D - y)^2 \right]$$

于是, $E(f; D) = bias^2(\mathbf{x}) + var(\mathbf{x}) + \varepsilon^2$

也即泛化误差可分解为偏差、方差与噪声之和。

偏差与方差


- 偏差度量了学习算法期望预测与真实结果的偏离程度；即刻画了学习算法本身的拟合能力；
- 方差度量了同样大小训练集的变动所导致的学习性能的变化；即刻画了数据扰动所造成的影响；
- 噪声表达了在当前任务上任何学习算法所能达到的期望泛化误差的下界；即刻画了学习问题本身的难度。

泛化性能是由学习算法的能力、数据的充分性以及学习任务本身的难度所共同决定的。给定学习任务，为了取得好的泛化性能，需要使偏差小(即能够充分拟合数据)，而且方差较小(即使得数据扰动产生的影响小)。

偏差与方差

一般来说，偏差与方差是有冲突的，称为偏差-方差窘境。如图所示，给定学习任务，假如我们能控制算法的训练程度：

- 在训练不足时，学习器拟合能力不强，训练数据的扰动不足以使学习器的拟合能力产生显著变化，此时偏差主导泛化错误率；
- 随着训练程度加深，学习器拟合能力逐渐增强，训练数据的微小扰动导致学习器发生显著变化，此时方差逐渐主导泛化错误率；
- 训练充足后，学习器的拟合能力非常强，训练数据的轻微扰动都会导致学习器的显著变化，若训练数据自身非全局特性被学到则会发生过拟合。



泛化误差与偏差、方差的关系示意图

本章总结

- **误差**：经验（训练）误差、测试误差、泛化误差
- **过拟合和欠拟合**：模型学的过好和未学好
- **评估方法**：留出法、交叉验证法、自助法
- **性能度量**：回归：均方误差、平均绝对值误差、相关系数、决定系数；分类：误差率、精度、混淆矩阵、召回率、精确率、F1度量、AUC等。
- **偏差与方差**：偏差-方差窘境

P P T 结 束 页

谢谢！

