

机器学习

Machine Learning

肖力

信息科学技术学院—6系

<https://faculty.ustc.edu.cn/xiaoli>

第3章：线性模型

目录

- 线性回归
 - 最小二乘法
- 二分类任务
 - 对数几率回归
 - 线性判别分析
- 多分类任务
 - 一对一
 - 一对其余
 - 多对多
- 类别不平衡问题

基本形式


- 给定由 d 个属性描述的样品 $\mathbf{x} = (x_1; x_2; \dots; x_d)$, 其中 x_i 是 $\mathbf{x}$ 在第 i 个属性上的取值.
- 线性模型基本形式

$$f(\mathbf{x}) = w_1x_1 + w_2x_2 + \dots + w_dx_d + b.$$

基本形式

- 给定由 d 个属性描述的样品 $\mathbf{x} = (x_1; x_2; \dots; x_d)$, 其中 x_i 是 $\mathbf{x}$ 在第 i 个属性上的取值.
- 线性模型基本形式

$$f(\mathbf{x}) = w_1x_1 + w_2x_2 + \dots + w_dx_d + b.$$



权重

偏移量

基本形式

- 给定由 d 个属性描述的样品 $\mathbf{x} = (x_1; x_2; \dots; x_d)$, 其中 x_i 是 $\mathbf{x}$ 在第 i 个属性上的取值.
- 线性模型基本形式

$$f(\mathbf{x}) = w_1x_1 + w_2x_2 + \dots + w_dx_d + b.$$

- 向量形式

$$f(\mathbf{x}) = \mathbf{w}'\mathbf{x} + b,$$

其中 $\mathbf{w} = (w_1; w_2; \dots; w_d)$.

基本形式

- 给定由 d 个属性描述的样品 $\mathbf{x} = (x_1; x_2; \dots; x_d)$, 其中 x_i 是 $\mathbf{x}$ 在第 i 个属性上的取值.

- 线性模型基本形式


$$f(\mathbf{x}) = w_1x_1 + w_2x_2 + \dots + w_dx_d + b.$$

- 向量形式

$$f(\mathbf{x}) = \mathbf{w}'\mathbf{x} + b,$$

其中 $\mathbf{w} = (w_1; w_2; \dots; w_d)$.

- 主要优点: 形式简单、可解释性强、可以衍生出许多非线性模型.



线性回归

一元线性回归 $f(x) = wx + b$

一元线性回归 $f(x) = wx + b$

- 数据集 $D = \{(x_i, y_i)\}_{i=1}^m$, 其中 $x_i, y_i \in \mathbb{R}$.

一元回归中 $d=1$, 因此是标量

一元线性回归 $f(x) = wx + b$

- 数据集 $D = \{(x_i, y_i)\}_{i=1}^m$, 其中 $x_i, y_i \in \mathbb{R}$.
- 一元线性回归的目标

一元线性回归 $f(x) = wx + b$

- 数据集 $D = \{(x_i, y_i)\}_{i=1}^m$, 其中 $x_i, y_i \in \mathbb{R}$.
- 一元线性回归的目标是寻找 “最优” 函数
$$f(x) = wx + b,$$
使得 $f(x_i) = wx_i + b \approx y_i, i = 1, 2, \dots, m$.

一元线性回归 $f(x) = wx + b$

- 数据集 $D = \{(x_i, y_i)\}_{i=1}^m$, 其中 $x_i, y_i \in \mathbb{R}$.
- 一元线性回归的目标是寻找“最优”函数

$$f(x) = wx + b,$$

使得 $f(x_i) = wx_i + b \approx y_i, i = 1, 2, \dots, m$.

拟合值

真实值

一元线性回归 $f(x) = wx + b$

- 一元线性回归的目标是寻找“最优”函数

$$f(x) = wx + b,$$

使得 $f(x_i) = wx_i + b \approx y_i, i = 1, 2, \dots, m.$

- 最小化均方误差

$$E_{(w,b)} = \sum_{i=1}^m (y_i - f(x_i))^2 = \sum_{i=1}^m (y_i - wx_i - b)^2$$

一元线性回归 $f(x) = wx + b$

- 一元线性回归的目标是寻找“最优”函数

$$f(x) = wx + b,$$

使得 $f(x_i) = wx_i + b \approx y_i, i = 1, 2, \dots, m.$

- 最小化均方误差

$$E_{(w,b)} = \sum_{i=1}^m (y_i - f(x_i))^2 = \sum_{i=1}^m (y_i - wx_i - b)^2$$

- 参数/模型估计：最小二乘法(least square method)

$$\min_{(w,b)} \sum_{i=1}^m (y_i - wx_i - b)^2$$

一元线性回归 $f(x) = wx + b$

- 一元线性回归的目标是寻找“最优”函数

$$f(x) = wx + b,$$

使得 $f(x_i) = wx_i + b \approx y_i, i = 1, 2, \dots, m.$

- 最小化均方误差

$$E_{(w,b)} = \sum_{i=1}^m (y_i - f(x_i))^2 = \sum_{i=1}^m (y_i - wx_i - b)^2$$

- 参数/模型估计：最小二乘法(least square method)

$$(w^*, b^*) = \arg \min_{(w,b)} \sum_{i=1}^m (y_i - wx_i - b)^2$$

最小二乘法——求解

- 目标函数 $E_{(w,b)} = \sum_{i=1}^m (y_i - wx_i - b)^2$

最小二乘法——求解

- 目标函数 $E_{(w,b)} = \sum_{i=1}^m (y_i - wx_i - b)^2$
- 分别对 w 和 b 求导，可得

$$\begin{cases} \frac{\partial E_{(w,b)}}{\partial w} = \\ \frac{\partial E_{(w,b)}}{\partial b} = \end{cases}$$

最小二乘法——求解

- 目标函数 $E_{(w,b)} = \sum_{i=1}^m (y_i - wx_i - b)^2$
- 分别对 w 和 b 求导，可得

$$\begin{cases} \frac{\partial E_{(w,b)}}{\partial w} = 2 \left(w \sum_{i=1}^m x_i^2 - \sum_{i=1}^m (y_i - b)x_i \right), \\ \frac{\partial E_{(w,b)}}{\partial b} = 2 \left(mb - \sum_{i=1}^m (y_i - wx_i) \right). \end{cases}$$

最小二乘法——求解

- 目标函数 $E_{(w,b)} = \sum_{i=1}^m (y_i - wx_i - b)^2$
- 分别对 w 和 b 求导，可得

$$\begin{cases} \frac{\partial E_{(w,b)}}{\partial w} = 2 \left(w \sum_{i=1}^m x_i^2 - \sum_{i=1}^m (y_i - b)x_i \right), \\ \frac{\partial E_{(w,b)}}{\partial b} = 2 \left(mb - \sum_{i=1}^m (y_i - wx_i) \right). \end{cases}$$

通过这个方程组求得的驻点的海塞矩阵一定是正定的

最小二乘法——求解

- 得到闭式(closed-form)解

$$\begin{cases} w^* = \frac{\sum_{i=1}^m y_i (x_i - \bar{x})}{\sum_{i=1}^m x_i^2 - \frac{1}{m} (\sum_{i=1}^m x_i)^2}, \\ b^* = \frac{1}{m} \sum_{i=1}^m (y_i - w x_i). \end{cases}$$

- 其中 $\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$.

多元线性回归 $f(\mathbf{x}) = w_1x_1 + w_2x_2 + \cdots + w_dx_d + b$.

- 给定数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$, 其中 $y_i \in \mathbb{R}$, $\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{id})$.

- 多元线性回归的目标是寻找“最优”函数,

$$f(\mathbf{x}) = \mathbf{w}'\mathbf{x} + b,$$

使得 $f(\mathbf{x}_i) = \mathbf{w}'\mathbf{x}_i + b \approx y_i, i = 1, 2, \dots, m$.

- 最小化均方误差

$$E_{(\mathbf{w}, b)} = \sum_{i=1}^m (y_i - f(\mathbf{x}_i))^2 = \sum_{i=1}^m (y_i - \mathbf{w}'\mathbf{x}_i - b)^2.$$

多元线性回归 $f(\mathbf{x}) = w_1x_1 + w_2x_2 + \cdots + w_dx_d + b$.

- 给定数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$, 其中 $y_i \in \mathbb{R}$, $\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{id})$.

- 多元线性回归的目标是寻找“最优”函数,

$$f(\mathbf{x}) = \mathbf{w}'\mathbf{x} + b,$$

使得 $f(\mathbf{x}_i) = \mathbf{w}'\mathbf{x}_i + b \approx y_i, i = 1, 2, \dots, m$.

- 最小化均方误差

$$E_{(\mathbf{w}, b)} = \sum_{i=1}^m (y_i - f(\mathbf{x}_i))^2 = \sum_{i=1}^m (y_i - \mathbf{w}'\mathbf{x}_i - b)^2.$$

将 $E_{(\mathbf{w}, b)}$ 依次对 $w_1, w_2, \dots, w_d, b$ 求偏导并令它们为0, 得到 $d + 1$ 个方程组成的方程组. 从中可求得闭形式解.

多元线性回归——向量化描述

- 给定数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$, 其中 $y_i \in \mathbb{R}$, $\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{id})$.
- 定义

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{i1} & x_{i2} & \cdots & x_{id} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{pmatrix}, \mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}, \tilde{\mathbf{w}} = \begin{pmatrix} \mathbf{w} \\ b \end{pmatrix}.$$



$m \times (d + 1)$

多元线性回归——向量化描述

■ 定义

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{pmatrix}, \mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \dots \\ y_m \end{pmatrix}, \tilde{\mathbf{w}} = \begin{pmatrix} \mathbf{w} \\ b \end{pmatrix}$$

- 多元线性回归的目标是寻找“最优”函数

$$f(\mathbf{x}) = \mathbf{w}'\mathbf{x} + b,$$

使得 $f(\mathbf{x}_i) = \mathbf{w}'\mathbf{x}_i + b \approx y_i, i = 1, 2, \dots, m.$

多元线性回归——向量化描述

■ 定义

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{pmatrix}, \mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \dots \\ y_m \end{pmatrix}, \tilde{\mathbf{w}} = \begin{pmatrix} \mathbf{w} \\ b \end{pmatrix}$$

■ 多元线性回归的目标是寻找“最优”函数

$$f(\mathbf{x}) = \mathbf{w}'\mathbf{x} + b,$$

使得

$$\begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{pmatrix} \tilde{\mathbf{w}} \approx \begin{pmatrix} y_1 \\ y_2 \\ \dots \\ y_m \end{pmatrix}$$

多元线性回归——向量化描述

- 定义
$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{pmatrix}, \mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \dots \\ y_m \end{pmatrix}, \tilde{\mathbf{w}} = \begin{pmatrix} \mathbf{w} \\ b \end{pmatrix}$$
- 多元线性回归的目标是寻找“最优”函数
$$f(\mathbf{x}) = \mathbf{w}'\mathbf{x} + b,$$
使得 $\mathbf{Y} \approx \mathbf{X}\tilde{\mathbf{w}}.$

多元线性回归——向量化描述

- 定义
$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{pmatrix}, \mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}, \tilde{\mathbf{w}} = \begin{pmatrix} \mathbf{w} \\ b \end{pmatrix}$$

- 多元线性回归的目标是寻找“最优”函数

$$f(\mathbf{x}) = \mathbf{w}'\mathbf{x} + b,$$

使得 $\mathbf{Y} \approx \mathbf{X}\tilde{\mathbf{w}}$.

- 最小化均方误差

$$E_{(\mathbf{w}, b)} = \sum_{i=1}^m (y_i - f(\mathbf{x}_i))^2 = \sum_{i=1}^m (y_i - \mathbf{w}'\mathbf{x}_i - b)^2.$$

多元线性回归——向量化描述

■ 定义

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{pmatrix}, \mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}, \tilde{\mathbf{w}} = \begin{pmatrix} \mathbf{w} \\ b \end{pmatrix}$$

- 多元线性回归的目标是寻找“最优”函数

$$f(\mathbf{x}) = \mathbf{w}'\mathbf{x} + b,$$

使得 $\mathbf{Y} \approx \mathbf{X}\tilde{\mathbf{w}}$.

- 最小化均方误差

$$E_{(\mathbf{w}, b)} = \sum_{i=1}^m (y_i - f(\mathbf{x}_i))^2 = \sum_{i=1}^m (y_i - \mathbf{w}'\mathbf{x}_i - b)^2.$$

列向量
 $\mathbf{Y} - \mathbf{X}\tilde{\mathbf{w}}$
各个分量的
平方和

多元线性回归——向量化描述

- 定义
$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{pmatrix}, \mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}, \tilde{\mathbf{w}} = \begin{pmatrix} \mathbf{w} \\ b \end{pmatrix}$$

- 多元线性回归的目标是寻找“最优”函数

$$f(\mathbf{x}) = \mathbf{w}'\mathbf{x} + b,$$

使得 $\mathbf{Y} \approx \mathbf{X}\tilde{\mathbf{w}}$.

- 最小化均方误差

$$E_{\tilde{\mathbf{w}}} = (\mathbf{Y} - \mathbf{X}\tilde{\mathbf{w}})'(\mathbf{Y} - \mathbf{X}\tilde{\mathbf{w}}).$$

多元线性回归——向量化描述

- 最小化均方误差

$$E_{\tilde{\mathbf{w}}} = (\mathbf{Y} - \mathbf{X}\tilde{\mathbf{w}})'(\mathbf{Y} - \mathbf{X}\tilde{\mathbf{w}}).$$

- 对 $\tilde{\mathbf{w}}$ 求导, 并令其等于 $\mathbf{0}$, 有:

$$\frac{\partial E_{\tilde{\mathbf{w}}}}{\partial \tilde{\mathbf{w}}} = 2\mathbf{X}'(\mathbf{X}\tilde{\mathbf{w}} - \mathbf{Y}) = \mathbf{0}.$$

- 当 $\mathbf{X}$ 是列满秩矩阵时, 得到:

$$\begin{pmatrix} \mathbf{w}^* \\ b^* \end{pmatrix} = \tilde{\mathbf{w}}^* = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y},$$

- 其中 $(\mathbf{X}'\mathbf{X})^{-1}$ 表示 $\mathbf{X}'\mathbf{X}$ 的逆矩阵.

最小二乘法 - 极大似然法

极大似然估计

概念：总体 X 的分布**已知**，参数 θ 未知。已知一组样本观测值

$$x_1, x_2, \dots, x_n.$$

参数 θ 的选择应有利于样本观测值的发生，即让这组数据发生的

概率达到最大。

最小二乘法 - 极大似然法

步骤:

➤ 似然函数: $L(x_1, x_2, \dots, x_n; \theta) = \begin{cases} \prod_{i=1}^n f(x_i; \theta), & f(x; \theta) \text{ 为 } X \text{ 的概率密度} \\ \prod_{i=1}^n p(X = x_i; \theta), & p(x; \theta) \text{ 为 } X \text{ 的分布律} \end{cases}$

➤ θ 的极大似然估计值 $\hat{\theta}(x_1, x_2, \dots, x_n)$

$$L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta)$$

➤ 求解似然方程 $\frac{d \ln L(\theta)}{d\theta} = 0$

最小二乘法 - 极大似然法

By introducing noise $\epsilon \in \mathbb{R}^m$, we can express the model as

$$\mathbf{Y} = \mathbf{X}\tilde{\mathbf{w}} + \epsilon.$$

If $\epsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_m)$, the probability density function of y_i conditioned on the model parameters and input is given by

$$p(y_i | \mathbf{x}_i; \tilde{\mathbf{w}}) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_i - \tilde{\mathbf{w}}^T \mathbf{x}_i)^2}{2\sigma^2}\right).$$

According to the maximum likelihood estimation, we obtain

$$\tilde{\mathbf{w}}^* = \operatorname{argmax}_{\tilde{\mathbf{w}}} \prod_{i=1}^m p(y_i | \mathbf{x}_i; \tilde{\mathbf{w}})$$

最小二乘法 - 极大似然法

$$\begin{aligned}\tilde{\mathbf{w}}^* &= \operatorname{argmax}_{\tilde{\mathbf{w}}} \prod_{i=1}^m p(y_i | \mathbf{x}_i; \tilde{\mathbf{w}}) \\&= \operatorname{argmax}_{\tilde{\mathbf{w}}} \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_i - \tilde{\mathbf{w}}^T \mathbf{x}_i)^2}{2\sigma^2}\right) \\&= \operatorname{argmax}_{\tilde{\mathbf{w}}} \ln \left(\prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_i - \tilde{\mathbf{w}}^T \mathbf{x}_i)^2}{2\sigma^2}\right) \right) \\&= \operatorname{argmax}_{\tilde{\mathbf{w}}} m \ln\left(\frac{1}{\sqrt{2\pi}\sigma}\right) - \frac{1}{2\sigma^2} \sum_{i=1}^m (y_i - \tilde{\mathbf{w}}^T \mathbf{x}_i)^2 \\&= \operatorname{argmin}_{\tilde{\mathbf{w}}} \sum_{i=1}^m (y_i - \tilde{\mathbf{w}}^T \mathbf{x}_i)^2 = \operatorname{argmin}_{\tilde{\mathbf{w}}} \|\mathbf{Y} - \mathbf{X}\tilde{\mathbf{w}}\|^2,\end{aligned}$$

最小二乘法等价于噪声误差服从正态分布的最大似然估计。

最小二乘法 - 极大似然法

思考：

以最小化平均绝对值误差的学习算法，那它等价于噪声误差服从拉普拉斯分布的最大似然估计。

如果随机变量的概率密度函数分布为

$$\begin{aligned} f(x|\mu, b) &= \frac{1}{2b} \exp\left(-\frac{|x - \mu|}{b}\right) \\ &= \frac{1}{2b} \begin{cases} \exp\left(-\frac{\mu - x}{b}\right) & \text{if } x < \mu \\ \exp\left(-\frac{x - \mu}{b}\right) & \text{if } x \geq \mu \end{cases} \end{aligned}$$

那么它就是拉普拉斯分布。其中， μ 是位置参数， $b > 0$ 是尺度参数。