

机器学习

Machine Learning

肖力

信息科学技术学院—6系

<https://faculty.ustc.edu.cn/xiaoli>

第3章：线性模型

目录

- 线性回归
 - 最小二乘法

- 二分类任务
 - 对数几率回归
 - 线性判别分析

- 多分类任务
 - 一对一
 - 一对其余
 - 多对多

- 类别不平衡问题

对数线性回归

- 对数线性回归：输出标记的对数为线性模型逼近的目标

$$\ln y = \mathbf{w}^T \mathbf{x} + b$$



$$y = \mathbf{w}^T \mathbf{x} + b$$


对数线性回归

□ 对数线性回归：输出标记的对数为线性模型逼近的目标

$$\ln y = \mathbf{w}^T \mathbf{x} + b$$



$$y = \mathbf{w}^T \mathbf{x} + b$$



线性回归 - 广义线性模型

□ 更一般形式

$$y = g^{-1}(\boldsymbol{w}^T \boldsymbol{x} + b)$$

□ $g(\cdot)$ 称为联系函数 (link function)

- 单调可微函数

□ 对数线性回归是 $g(\cdot) = \ln(\cdot)$ 时广义线性模型的特例

二分类任务

□ 预测值与输出标记

$$z = \mathbf{w}^T \mathbf{x} + b \quad y \in \{0, 1\}$$

□ 寻找一个单调可微函数将分类标记与线性回归模型输出联系起来

□ 最理想的函数：单位阶跃函数

$$y = \begin{cases} 0, & z < 0; \\ 0.5, & z = 0; \\ 1, & z > 0, \end{cases}$$

- 预测值大于零就判为正例，小于零则判为反例，预测值为临界值零则可任意判别

二分类任务

□ 单位阶跃函数缺点


- 不连续

□ 替代函数：对数几率函数 (logistic function)

- 单调可微、任意阶可导

单位阶跃函数与对数几率函数的比较

$$y = \frac{1}{1 + e^{-z}}$$



对数几率回归

□ 运用对数几率函数

$$y = \frac{1}{1 + e^{-z}} \quad \text{变为} \quad y = \frac{1}{1 + e^{-(w^T x + b)}}$$

□ 对数几率 (log odds / logit)

- y 可视为样本 x 作为正例的可能性，则 $1-y$ 是其作为反例的可能性，两者的比值称为几率，反映样本作为正例的相对可能性的对数

$$\ln \frac{y}{1-y} = w^T x + b$$

□ 对数几率回归优点

- 直接对分类可能性进行建模，无需事先假设数据分布，避免由假设分布不准确所带来的问题
- 不仅预测出类别，可得到“类别”的近似概率预测
- 可直接应用现有数值优化算法求取最优解

对数几率回归 - 极大似然法

□ 对数几率

$$\ln \frac{y}{1-y} = \mathbf{w}^T \mathbf{x} + b \quad \xrightarrow{y \sim p(y=1|\mathbf{x})} \ln \frac{p(y=1|\mathbf{x})}{p(y=0|\mathbf{x})} = \mathbf{w}^T \mathbf{x} + b$$

显然有

$$p(y=1|\mathbf{x}) = \frac{e^{\mathbf{w}^T \mathbf{x} + b}}{1 + e^{\mathbf{w}^T \mathbf{x} + b}}$$

$$p(y=0|\mathbf{x}) = \frac{1}{1 + e^{\mathbf{w}^T \mathbf{x} + b}}$$

对数几率回归 - 极大似然法

□ 极大似然法 (maximum likelihood method)

- 给定数据集

$$\{(\mathbf{x}_i, y_i)\}_{i=1}^m$$

- 最大化样本属于其真实标记的概率
 - 最大化对数似然函数

$$\ell(\mathbf{w}, b) = \sum_{i=1}^m \ln p(y_i \mid \mathbf{x}_i; \mathbf{w}_i, b)$$

对数几率回归 - 极大似然法

- 令 $\beta = (w; b)$, $\hat{x} = (x; 1)$, 则 $w^T x + b$ 可简写为 $\beta^T \hat{x}$
- 再令

$$p_1(\hat{x}_i; \beta) = p(y = 1 \mid \hat{x}_i; \beta)$$

$$p_0(\hat{x}_i; \beta) = p(y = 0 \mid \hat{x}_i; \beta) = 1 - p_1(\hat{x}_i; \beta)$$

则似然项可重写为

$$p(y_i \mid x_i; w_i, b) = y_i p_1(\hat{x}_i; \beta) + (1 - y_i) p_0(\hat{x}_i; \beta)$$

- 故等价形式为要最小化

$$\ell(\beta) = \sum_{i=1}^m \left(-y_i \beta^T \hat{x}_i + \ln \left(1 + e^{\beta^T \hat{x}_i} \right) \right)$$

高阶可导连续凸函数, 梯度下降法/牛顿法 [Boyd and Vandenberghe, 2004]

对数几率回归

□ 求解得

$$\boldsymbol{\beta}^* = \arg \min_{\boldsymbol{\beta}} \ell(\boldsymbol{\beta})$$

□ 牛顿法第 $t+1$ 轮迭代解的更新公式

$$\boldsymbol{\beta}^{t+1} = \boldsymbol{\beta}^t - \left(\frac{\partial^2 \ell(\boldsymbol{\beta})}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}^T} \right)^{-1} \frac{\partial \ell(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}}$$

其中关于 $\boldsymbol{\beta}$ 的一阶、二阶导数分别为


$$\frac{\partial \ell(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} = - \sum_{i=1}^m \hat{\mathbf{x}}_i (y_i - p_1(\hat{\mathbf{x}}_i; \boldsymbol{\beta}))$$

$$\frac{\partial^2 \ell(\boldsymbol{\beta})}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}^T} = \sum_{i=1}^m \hat{\mathbf{x}}_i \hat{\mathbf{x}}_i^T p_1(\hat{\mathbf{x}}_i; \boldsymbol{\beta}) (1 - p_1(\hat{\mathbf{x}}_i; \boldsymbol{\beta}))$$


二分类任务 - 线性判别分析

□ 线性判别分析 (Linear Discriminant Analysis, LDA) [Fisher, 1936]的思想：给定训练集样本，将其投影到一条直线上，


- 使同类样例的投影点尽可能接近，异类样例的投影点尽可能远离；
- 对新样本进行分类时，将其投影到同一直线，根据投影点的位置来确定新样本的类别。



二分类任务 - 线性判别分析



(a)



(b)

- 可以投影的直线有无数条，寻找一条最优的直线（即方向）。
- 数学上，**LDA**试图找到一个低维的新的特征空间，使得不同类别的训练样本在此空间中更加有利于分类。

二分类任务 - 线性判别分析

□ LDA的思想

- 欲使同类样例的投影点尽可能接近，可以让同类样例投影点的协方差尽可能小
- 欲使异类样例的投影点尽可能远离，可以让不同类中心之间的距离尽可能大

□ 一些变量

- 第 i 类示例的集合 X_i
- 第 i 类示例的均值向量 μ_i
- 第 i 类示例的协方差矩阵 $\Sigma_i = \sum_{x \in X_i} (x - \mu_i)(x - \mu_i)^T$
- 两类样本的中心在直线上的投影: $w^T \mu_0$ 和 $w^T \mu_1$
- 两类样本投影点的协方差: $w^T \Sigma_0 w$ 和 $w^T \Sigma_1 w$

二分类任务 - 线性判别分析

□ 最大化目标

$$\begin{aligned} J &= \frac{\|w^T \mu_0 - w^T \mu_1\|_2^2}{w^T \Sigma_0 w + w^T \Sigma_1 w} \\ &= \frac{w^T (\mu_0 - \mu_1) (\mu_0 - \mu_1)^T w}{w^T (\Sigma_0 + \Sigma_1) w} \end{aligned}$$

□ 类内散度矩阵

$$\begin{aligned} S_w &= \Sigma_0 + \Sigma_1 \\ &= \sum_{x \in X_0} (x - \mu_0) (x - \mu_0)^T + \sum_{x \in X_1} (x - \mu_1) (x - \mu_1)^T \end{aligned}$$

□ 类间散度矩阵

$$S_b = (\mu_0 - \mu_1) (\mu_0 - \mu_1)^T$$

二分类任务 - 线性判别分析

□ 广义瑞利商 (generalized Rayleigh quotient)

$$J = \frac{\mathbf{w}^T \mathbf{S}_b \mathbf{w}}{\mathbf{w}^T \mathbf{S}_w \mathbf{w}}$$

□ 令 $\mathbf{w}^T \mathbf{S}_w \mathbf{w} = 1$, 最大化广义瑞利商等价形式为

$$\begin{aligned} \min_{\mathbf{w}} \quad & -\mathbf{w}^T \mathbf{S}_b \mathbf{w} \\ \text{s.t.} \quad & \mathbf{w}^T \mathbf{S}_w \mathbf{w} = 1 \end{aligned}$$

□ 运用拉格朗日乘子法

$$\mathbf{S}_b \mathbf{w} = \lambda \mathbf{S}_w \mathbf{w}$$

二分类任务 - 线性判别分析

$$S_b w = \lambda S_w w$$

□ 同向向量

$$\frac{S_b w}{\downarrow} = \lambda \frac{(\mu_0 - \mu_1)}{\swarrow}$$

同向向量

□ 结果

$$w = S_w^{-1} (\mu_0 - \mu_1)$$

□ 求解

● 奇异值分解

$$S_w = U \Sigma V^T$$

二分类任务 - 线性判别分析

- 问题：二分类任务时，LDA为什么投影到直线（一维），而不能投影到超平面（多维）呢？

二分类任务 - 线性判别分析

□ 问题：二分类任务时，LDA为什么投影到直线（一维），而不能投影到超平面（多维）呢？

- 假设将样本投影到标准正交基为

$$\mathbf{W} = [\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_c] \in \mathbb{R}^{d \times c}$$

的 c 维超平面（线性子空间），则投影后的样本坐标为

$$x \Rightarrow W^T x$$

- 两类样本的均值在此超平面的投影坐标为

$$m_1 \Rightarrow W^T m_1$$

$$m_2 \Rightarrow W^T m_2$$

二分类任务 - 线性判别分析

- 投影后类均值之间的距离为

$$\begin{aligned} \|W^T(m_1 - m_2)\|_2^2 &= (m_1 - m_2)^T W W^T (m_1 - m_2) \\ &= \text{tr}[W^T(m_1 - m_2)(m_1 - m_2)^T W] \\ &= \text{tr}[W^T S_B W] \end{aligned}$$

- 故可以写成

$$\begin{aligned} \max_W \quad & \text{tr}[W^T S_B W] \\ \text{s.t.} \quad & \text{tr}[W^T S_W W] = 1 \end{aligned}$$

利用拉格朗日乘子法，得到

$$L(W, \Lambda) = -\text{tr}[W^T S_B W] + \text{tr}[\Lambda^T (W^T S_W W - I_c)]$$

二分类任务 - 线性判别分析

求导并令其为0:

$$\partial_W L(W, \Lambda) = -2S_B W + 2S_W W \Lambda = 0$$



$$S_B W = S_W W \Lambda$$

大部分情况下, S_W 是可逆的, 所以

$$S_W^{-1} S_B W = W \Lambda$$

对 $S_W^{-1} S_B$ 进行特征值分解, W 就是 c 个最大特征值的特征向量组成的矩阵。

二分类任务 - 线性判别分析

然而，由观察可知，

$$S_W^{-1} S_B = S_W^{-1} (m_1 - m_2)(m_1 - m_2)^T$$



$$\text{rank}(S_W^{-1} S_B) = 1$$

我们知道，秩为1的 $n \times n$ 矩阵最多只有1个非零特征值，或至少 $n-1$ 个零特征值。

因此，在选出的 c 个特征向量中，只有这个非零特征值对应的特征向量是我们想要的，另外对应于特征值0的 $c-1$ 个特征向量是没有意义的（即不影响目标函数，也不影响投影之后的点与点之间的距离）。

所以，对于二分类任务，**LDA**只用考虑对一条直线进行投影。

LDA推广 - 多分类任务

□ 全局散度矩阵

$$\begin{aligned}\mathbf{S}_t &= \mathbf{S}_b + \mathbf{S}_w \\ &= \sum_{i=1}^m (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T\end{aligned}$$

□ 类内散度矩阵

$$\mathbf{S}_w = \sum_{i=1}^N \mathbf{S}_{w_i}$$

其中

$$\mathbf{S}_{w_i} = \sum_{\mathbf{x} \in X_i} (\mathbf{x} - \boldsymbol{\mu}_i)(\mathbf{x} - \boldsymbol{\mu}_i)^T$$

□ 求解得

$$\begin{aligned}\mathbf{S}_b &= \mathbf{S}_t - \mathbf{S}_w \\ &= \sum_{i=1}^N m_i (\boldsymbol{\mu}_i - \boldsymbol{\mu})(\boldsymbol{\mu}_i - \boldsymbol{\mu})^T\end{aligned}$$

LDA推广 - 多分类任务

□ 类内散度矩阵 $\mathbf{S}_w = \sum_{i=1}^N \mathbf{S}_{w_i}$

其中 $\mathbf{S}_{w_i} = \sum_{\mathbf{x} \in X_i} (\mathbf{x} - \boldsymbol{\mu}_i)(\mathbf{x} - \boldsymbol{\mu}_i)^T$

□ 类间散度矩阵 $\mathbf{S}_b = \sum_{i=1}^N m_i (\boldsymbol{\mu}_i - \boldsymbol{\mu})(\boldsymbol{\mu}_i - \boldsymbol{\mu})^T$

□ p 个投影方向 $\mathbf{W} = [\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_p]$

● 最小化类内投影协方差之和 $\sum_{j \in p} \mathbf{w}_j^T \mathbf{S}_w \mathbf{w}_j = \text{tr}(\mathbf{W}^T \mathbf{S}_w \mathbf{W})$

● 最大化类间投影距离之和 $\sum_{j \in p} \mathbf{w}_j^T \mathbf{S}_b \mathbf{w}_j = \text{tr}(\mathbf{W}^T \mathbf{S}_b \mathbf{W})$

LDA推广 - 多分类任务

□ 优化目标

$$\max_{\mathbf{W}} \frac{\text{tr}(\mathbf{W}^T \mathbf{S}_b \mathbf{W})}{\text{tr}(\mathbf{W}^T \mathbf{S}_w \mathbf{W})}$$

其中 $\mathbf{W} \in \mathbb{R}^{d \times (N-1)}$



$$\mathbf{S}_b \mathbf{W} = \lambda \mathbf{S}_w \mathbf{W}$$

$\mathbf{W}$ 的闭式解则是 $\mathbf{S}_w^{-1} \mathbf{S}_b$ (其是 N 个秩为1的矩阵相加, 故它的秩最大为 N ; 又由于这 N 项中有一项可以被线性表达, 所以它的秩最大为 $N-1$) 的前 d' ($d' \leq N-1$) 个最大非零广义特征值所对应的特征向量组成的矩阵。

□ 多分类LDA将样本投影到 d' 维空间, d' 通常远小于数据原有的属性数 d , 因此LDA也被视为一种监督降维技术

多分类学习

□ 多分类学习方法

- 有些二分类学习方法可直接推广到多类
- 更多情形下，基于一些基本策略，利用二分类学习器解决多分类问题
(常用)
 - 对问题进行拆分，为拆出的每个二分类任务训练一个分类器
 - 对于每个分类器的预测结果进行集成以获得最终的多分类结果

□ 拆分策略

- 一对一 (One vs. One, OvO)
- 一对其余 (One vs. Rest, OvR)
- 多对多 (Many vs. Many, MvM)

多分类学习 - 一对一

□ 拆分阶段

- N个类别两两配对
 - $N(N-1)/2$ 个二类任务
- 各个二类任务学习分类器
 - $N(N-1)/2$ 个二类分类器

□ 测试阶段

- 新样本提交给所有分类器预测
 - $N(N-1)/2$ 个分类结果
- 投票产生最终分类结果
 - 被预测最多的类别为最终类别

多分类学习 - 一对其余




□ 任务拆分

- 某一类作为正例，其他反例
 - N 个二类任务
- 各个二类任务学习分类器
 - N 个二类分类器

□ 测试阶段

- 新样本提交给所有分类器预测
 - N 个分类结果
- 比较各分类器预测置信度
 - 置信度最大的类别作为最终类别

多分类学习 - 两种策略比较



多分类学习 - 两种策略比较

一对一

- 训练 $N(N-1)/2$ 个分类器，存储开销和测试时间大
- 训练只用两个类的样例，训练时间短

一对其余

- 训练 N 个分类器，存储开销和测试时间小
- 训练用到全部训练样例，训练时间长


预测性能取决于具体数据分布，多数情况下两者差不多

多分类学习 - 多对多

□ 多对多 (Many vs Many, MvM)

- 若干类作为正类，若干类作为反类

□ 纠错输出码 (Error Correcting Output Codes, ECOC)



多分类学习 - 多对多

纠错输出码(Error Correcting Output Codes, ECOC)

	f_1	f_2	f_3	f_4	f_5	海明距离	欧氏距离
$C_1 \rightarrow$	-1	+1	-1	+1	+1	3	$2\sqrt{3}$
$C_2 \rightarrow$	+1	-1	-1	+1	-1	4	4
$C_3 \rightarrow$	-1	+1	+1	-1	+1	1	2
$C_4 \rightarrow$	-1	-1	+1	+1	-1	2	$2\sqrt{2}$
测试示例 $\rightarrow$	-1	-1	+1	-1	+1		

(a) 二元 ECOC 码

[Dietterich and Bakiri,1995]

	f_1	f_2	f_3	f_4	f_5	f_6	f_7	海明距离	欧氏距离
$C_1 \rightarrow$	-1	-1	+1	+1	-1	+1	+1	4	4
$C_2 \rightarrow$	-1	0	0	0	+1	-1	0	2	2
$C_3 \rightarrow$	+1	+1	-1	-1	-1	+1	-1	5	$2\sqrt{5}$
$C_4 \rightarrow$	-1	+1	0	+1	-1	0	+1	3	$\sqrt{10}$
测试示例 $\rightarrow$	-1	+1	+1	-1	+1	-1	+1		

(b) 三元 ECOC 码

[Allwein et al. 2000]

- ECOC编码对分类器错误有一定容忍和修正能力，编码越长、纠错能力越强
- 对同等长度的编码，理论上来说，任意两个类别之间的编码距离越远，则纠错能力越强

类别不平衡问题

□ 类别不平衡 (class imbalance)

- 不同类别训练样例数相差很大情况 (假设正类为小类)

类别平衡正例预测 $\frac{y}{1-y} > 1$  $\frac{y}{1-y} > \frac{m^+}{m^-}$ 正负类比例

□ 三大主要技术:

- 欠采样 (undersampling)
 - 去除一些反例使正反例数目接近 (EasyEnsemble [Liu et al.,2009])
- 过采样 (oversampling)
 - 增加一些正例使正反例数目接近 (SMOTE [Chawla et al.2002])
- 阈值移动 (threshold-moving)

$$\frac{y'}{1-y'} = \frac{y}{1-y} \times \frac{m^-}{m^+}$$

总结

□ 线性回归

- 最小二乘法（最小化均方误差）

□ 二分类任务

- 对数几率回归
 - 单位阶跃函数、对数几率函数、极大似然法
- 线性判别分析
 - 最大化广义瑞利商，并且考虑了多分类情形

□ 多分类学习

- 一对一
- 一对其余
- 多对多
 - 纠错输出码

□ 类别不平衡问题

- 基本策略：欠采样、过采样、阈值移动