

机器学习

Machine Learning

肖力

信息科学技术学院—6系

<https://faculty.ustc.edu.cn/xiaoli>

第6章：支持向量机

大纲

□ 间隔与支持向量

□ 对偶问题

□ 软间隔与正则化


□ 支持向量回归

□ 核函数

□ 核方法


引例

基本思想：在样本空间中寻找一个超平面，将不同类别的训练样本分开。




引例

-Q: 将训练样本分开的超平面可能有很多, 哪一个好呢?



引例

-Q: 将训练样本分开的超平面可能有很多, 哪一个好呢?



-A: 应选择“正中间”的超平面, 容忍性最好, 鲁棒性最高, 泛化能力最强.

间隔与支持向量

超平面方程: $\mathbf{w}^\top \mathbf{x} + b = 0$

- $\mathbf{w} = (w_1; w_2; \cdots; w_d) \in \mathbb{R}^d$ 为法向量, 它与超平面中任意向量都垂直, 决定了超平面的方向
- b 为位移项, 决定了超平面与原点之间的距离
- 任意点到超平面 $\mathbf{w}^\top \mathbf{x} + b = 0$ 的距离为 $r = \frac{|\mathbf{w}^\top \mathbf{x} + b|}{\|\mathbf{w}\|}$
- 超平面将空间分为两半, 法向量指向的那一半对应的一面为正面, 另一面则是反面, 即

$$\begin{cases} \text{正面} & , w^\top x + b > 0 \\ \text{平面上} & , w^\top x + b = 0 \\ \text{反面} & , w^\top x + b < 0 \end{cases}$$

间隔与支持向量

超平面方程: $\mathbf{w}^\top \mathbf{x} + b = 0$

假设此超平面能将所有训练样本 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$ 正确分类, 即若 $y_i = 1$, 则有 $\mathbf{w}^\top \mathbf{x}_i + b > 0$; 若 $y_i = -1$, 则有 $\mathbf{w}^\top \mathbf{x}_i + b < 0$

SVM基本思想用优化问题可表示为


$$\max_{\mathbf{w}, b} \min_i \frac{|\mathbf{w}^\top \mathbf{x}_i + b|}{\|\mathbf{w}\|} \quad \text{s.t.} \quad y_i(\mathbf{w}^\top \mathbf{x}_i + b) > 0$$

令 $\hat{r} = \min_i |\mathbf{w}^\top \mathbf{x}_i + b|$, 则上面等价于

$$\max_{\mathbf{w}, b} \frac{\hat{r}}{\|\mathbf{w}\|} \quad \text{s.t.} \quad y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq \hat{r}$$

间隔与支持向量

假设 $\mathbf{w}$ 和 $\mathbf{b}$ 按比例改变为 $\lambda\mathbf{w}$ 和 λb , 则 $\hat{r}$ 也相应地会变为 $\lambda\hat{r}$; 此时, 它可以产生一个等价的优化问题, 并且超平面还是原来的超平面。因此, 我们可以取 $\hat{r} = 1$



支持向量机基本型

□ 最大间隔：寻找参数 $\mathbf{w}$ 和 b , 使得 γ 最大.

$$\begin{aligned} \max_{\mathbf{w}, b} \quad & \frac{2}{\|\mathbf{w}\|} \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$



$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$

这就是支持向量机的基本型。

大纲

□ 间隔与支持向量

□ 对偶问题

□ 软间隔与正则化

□ 支持向量回归

□ 核函数

□ 核方法

对偶问题

□ 希望求解

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$

得到大间隔划分超平面所对应的模型

$$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$$

注意到此优化问题本身是一个凸二次规划问题，能直接使用现成的优化计算包求解。但是，当训练样本容量很大时，这些算法变得非常低效，以至于无法使用。

对偶问题

□ 拉格朗日乘子法可得到其对偶问题

- 第一步：引入拉格朗日乘子 $\alpha_i \geq 0$ 得到拉格朗日函数

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^m \alpha_i (y_i (\mathbf{w}^\top \mathbf{x}_i + b) - 1)$$

- 第二步：令 $L(\mathbf{w}, b, \boldsymbol{\alpha})$ 对 $\mathbf{w}$ 和 b 的偏导为零可得

$$\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i, \quad \sum_{i=1}^m \alpha_i y_i = 0.$$

- 第三步：回代入 $L(\mathbf{w}, b, \boldsymbol{\alpha})$

对偶问题

$$\begin{aligned} L(\mathbf{w}, b, \boldsymbol{\alpha}) &= \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^m \alpha_i (1 - y_i(\mathbf{w}' \mathbf{x}_i + b)) \\ &= \frac{1}{2} \mathbf{w}' \mathbf{w} + \sum_{i=1}^m (\alpha_i - \alpha_i y_i \mathbf{w}' \mathbf{x}_i + \alpha_i y_i b) \\ &= \frac{1}{2} \sum_{i=1}^m \alpha_i y_i \mathbf{w}' \mathbf{x}_i - \sum_{i=1}^m \alpha_i y_i \mathbf{w}' \mathbf{x}_i + \sum_{i=1}^m \alpha_i + \sum_{i=1}^m \alpha_i y_i b \\ &= \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \alpha_i y_i \mathbf{w}' \mathbf{x}_i \\ &= \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \alpha_i y_i \left(\sum_{j=1}^m \alpha_j y_j \mathbf{x}'_j \right) \mathbf{x}_i \\ &= \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}'_j \mathbf{x}_i \end{aligned}$$

对偶问题

- 支持向量机问题的对偶形式:

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i' \mathbf{x}_j \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \\ & \alpha_i \geq 0, \quad i = 1, 2, \dots, m. \end{aligned}$$

对偶问题

□ 拉格朗日乘子法可得到其对偶问题

- 第一步：引入拉格朗日乘子 $\alpha_i \geq 0$ 得到拉格朗日函数

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^m \alpha_i (y_i (\mathbf{w}^\top \mathbf{x}_i + b) - 1)$$

- 第二步：令 $L(\mathbf{w}, b, \boldsymbol{\alpha})$ 对 $\mathbf{w}$ 和 b 的偏导为零可得

$$\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i, \quad \sum_{i=1}^m \alpha_i y_i = 0.$$

- 第三步：回代

$$\begin{aligned} \min_{\boldsymbol{\alpha}} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i = 1, 2, \dots, m. \end{aligned}$$

求解对偶问题的方法 - SMO

- 一般地，每次只优化一个参数，固定其他参数，仅求当前在这个参数上优化问题的极值。但是约束条件 $\sum_{i=1}^m \alpha_i y_i = 0$ ，没法依次只变动一个参数，所以我们需要依次选取两个参数做优化。
- 基本思路：不断执行如下两个步骤直至收敛。
 - 第一步：选取一对需更新的变量 α_i 和 α_j 。
 - 第二步：固定 α_i 和 α_j 以外的参数，求解对偶问题更新 α_i 和 α_j 。

求解对偶问题的方法 - SMO

$$\begin{aligned} \min_{\alpha_i \geq 0} \quad & \frac{1}{2}(\alpha_i^2 y_i^2 \mathbf{x}_i^T \mathbf{x}_i + \alpha_j^2 y_j^2 \mathbf{x}_j^T \mathbf{x}_j) + \alpha_i \alpha_j y_i y_j - (\alpha_i + \alpha_j) \\ & + \alpha_i y_i \sum_{k \neq i, j} \alpha_k y_k \mathbf{x}_i^T \mathbf{x}_k + \alpha_j y_j \sum_{k \neq i, j} \alpha_k y_k \mathbf{x}_j^T \mathbf{x}_k \\ \text{s.t.} \quad & \alpha_i y_i + \alpha_j y_j = c \end{aligned}$$

其中, $c = -\sum_{k \neq i, j} \alpha_k y_k$. 可由约束条件得到 $\alpha_j = (c - \alpha_i y_i)/y_j$, 由此可以消去 α_j , 这时目标问题就被转换为只有一个约束条件 α_i 的优化问题。

用一个变量表示另一个变量, 回代入对偶问题可得一个单变量的二次规划, 该问题具有闭式解.

求解 $\mathbf{w}$ 和 b

□ 满足KKT条件：

$$\nabla_{\mathbf{w}} L(\mathbf{w}^*, b^*, \boldsymbol{\alpha}^*) = \mathbf{w}^* - \sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i = \mathbf{0}$$

$$\nabla_b L(\mathbf{w}^*, b^*, \boldsymbol{\alpha}^*) = - \sum_{i=1}^m \alpha_i^* y_i = 0$$

$$\alpha_i^* \geq 0$$

$$y_i f(\mathbf{x}_i) \geq 1$$

$$\alpha_i^* (y_i f(\mathbf{x}_i) - 1) = 0$$

求解 $\mathbf{w}$ 和 b

定理：设 $\boldsymbol{\alpha}^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_m^*)^T$ 是对偶问题的最优解，则存在下标 j ，使得 $\alpha_j^* > 0$ ，并可求得原问题的最优解为

$$\mathbf{w}^* = \sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i \quad b^* = y_j - \sum_{i=1}^m \alpha_i^* y_i (\mathbf{x}_i^T \mathbf{x}_j)$$

证明：基于KKT条件知， $\mathbf{w}^* = \sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i$ ，则其中至少有一个 $\alpha_j^* > 0$

反正法——假设 $\boldsymbol{\alpha}^* = \mathbf{0}$ ，则有 $\mathbf{w}^* = \mathbf{0}$ 。这明显不是原问题的最优解，故产生矛盾。

对 j ，有 $y_j(\mathbf{w}^{*T} \mathbf{x}_j + b^*) - 1 = 0$ 。由于 $y_j^2 = 1$ ，所以可得

$$b^* = y_j - \sum_{i=1}^m \alpha_i^* y_i (\mathbf{x}_i^T \mathbf{x}_j)。证毕！$$

求解 $\mathbf{w}$ 和 b

- 设 $S = \{i | \alpha_i > 0, i = 1, 2, \dots, m\}$. $\forall j \in S, y_j f(\mathbf{x}_j) - 1 = 0$. 于是:

$$y_j \left(\sum_{i \in S} \alpha_i y_i \langle \mathbf{x}_i, \mathbf{x}_j \rangle + b \right) - 1 = 0$$

- 方法一: $\forall j \in S,$

$$b = \frac{1}{y_j} - \sum_{i \in S} \alpha_i y_i \langle \mathbf{x}_i, \mathbf{x}_j \rangle.$$

即在所有的支持
向量上取平均

- 方法二(更稳健):

$$b = \frac{1}{|S|} \sum_{j \in S} \left(\frac{1}{y_j} - \sum_{i \in S} \alpha_i y_i \langle \mathbf{x}_i, \mathbf{x}_j \rangle \right).$$

解的稀疏性

□ 最终模型: $f(\mathbf{x}) = \mathbf{w}^{*T} \mathbf{x} + b^*$

□ 由KKT条件

$$\alpha_i^* \geq 0$$

$$y_i f(\mathbf{x}_i) \geq 1$$

$$\alpha_i^* (y_i f(\mathbf{x}_i) - 1) = 0$$

- 对任何样品 $(\mathbf{x}_i, y_i)$, 总有 $\alpha_i = 0$ 或者 $y_i f(\mathbf{x}_i) - 1 = 0$.
 - 若 $\alpha_i = 0$, 表示样品 $(\mathbf{x}_i, y_i)$ 在分类模型 $f(\mathbf{x})$ 中不起任何作用;
 - 若 $\alpha_i > 0$, 说明 $y_i f(\mathbf{x}_i) - 1 = 0$, 即样品 $(\mathbf{x}_i, y_i)$ 是支持向量.

解的稀疏性

□ 最终模型: $f(\mathbf{x}) = \mathbf{w}^{*T} \mathbf{x} + b^*$

□ 由KKT条件

$$\alpha_i^* \geq 0$$

$$y_i f(\mathbf{x}_i) \geq 1$$

$$\alpha_i^* (y_i f(\mathbf{x}_i) - 1) = 0$$

支持向量机解的稀疏性: 训练完成后, 大部分的训练样本都不需保留, 最终模型仅与支持向量有关.

简单例子

正例点 $x_1 = (3, 3)^T$, $x_2 = (4, 3)^T$ 负例点 $x_3 = (1, 1)^T$

解：对偶形式

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \\ &= \frac{1}{2} (18\alpha_1^2 + 25\alpha_2^2 + 2\alpha_3^2 + 42\alpha_1\alpha_2 - 12\alpha_1\alpha_3 - 14\alpha_2\alpha_3) - \alpha_1 - \alpha_2 - \alpha_3 \\ \text{s.t.} \quad & \alpha_1 + \alpha_2 - \alpha_3 = 0 \\ & \alpha_i \geq 0, \quad i = 1, 2, 3 \end{aligned}$$

将 $\alpha_3 = \alpha_1 + \alpha_2$ 带入目标函数并记为

$$s(\alpha_1, \alpha_2) = 4\alpha_1^2 + \frac{13}{2}\alpha_2^2 + 10\alpha_1\alpha_2 - 2\alpha_1 - 2\alpha_2$$

简单例子

- 对 α_1, α_2 求偏导数，并令其为0，易知 $s(\alpha_1, \alpha_2)$ 在 $\left(\frac{3}{2}, -1\right)^T$
- 取极值，但该点不满足约束条件 $\alpha_2 \geq 0$ ，所以最小值应在边界上达到
- 当 $\alpha_1 = 0$ 时，最小值 $s\left(0, \frac{2}{13}\right) = -\frac{2}{13}$
- 当 $\alpha_2 = 0$ 时，最小值 $s\left(\frac{1}{4}, 0\right) = -\frac{1}{4}$
- 于是 $s(\alpha_1, \alpha_2)$ 在 $\alpha_1 = \frac{1}{4}, \alpha_2 = 0$ 获得极小， $\alpha_3 = \alpha_1 + \alpha_2 = \frac{1}{4}$
- 这样 $\alpha_1^* = \alpha_3^* = \frac{1}{4}$ 对应的实例向量为支持向量

简单例子

计算得：

$$w_1^* = w_2^* = \frac{1}{2}$$
$$b^* = -2$$

分离超平面为：

$$\frac{1}{2}x^{(1)} + \frac{1}{2}x^{(2)} - 2 = 0$$

分类决策函数为：

$$f(x) = \text{sign}\left(\frac{1}{2}x^{(1)} + \frac{1}{2}x^{(2)} - 2\right)$$

大纲

□ 间隔与支持向量

□ 对偶问题

□ 软间隔与正则化


□ 支持向量回归

□ 核函数

□ 核方法

软间隔

- Q: 现实中, 很难确定合适的核函数使得训练样本在新特征空间中线性可分; 同时一个线性可分的结果也很难断定是否是由过拟合造成的.
- A: 前面的支持向量机形式要求所有训练样本满足约束, 即所有训练样本都必须划分正确, 这称为“硬间隔”, 而引入“软间隔”的概念, 则是允许某些样本不满足约束 $y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$.



0/1损失函数

- 基本想法：最大化间隔的同时，让不满足约束的样本应尽可能少。

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m l_{0/1}(y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1)$$

其中 $l_{0/1}$ 是“0/1损失函数”

$$l_{0/1} = \begin{cases} 1 & z < 0 \\ 0 & otherwise \end{cases}$$

- 显然，当C无穷大时，退化为最大化硬间隔；
- 存在的问题：0/1损失函数非凸、非连续，不易优化！

替代损失

□ 因此，通常用其他一些函数来代替 $l_{0/1}$ ，称为替代损失。


软间隔SVM

$$\ell_{\text{hinge}}(z) = \max(0, 1 - z)$$

$$\ell_{\log}(z) = \log(1 + \exp(-z))$$

$$\ell_{\exp}(z) = \exp(-z)$$

$$\ell_{0/1}(z) = \begin{cases} 1 & \text{if } z < 0 \\ 0 & \text{otherwise} \end{cases}$$



替代损失函数数学性质较好，一般是0/1损失函数的上界

软间隔支持向量机

- 带软间隔的SVM的基本形式(hinge损失函数):

原始问题

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i(\mathbf{w}^\top \mathbf{x}_i + b))$$

引入松弛变量

$$\begin{aligned} \min_{\mathbf{w}, b, \xi_i} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i \\ & \xi_i \geq 0, \quad i = 1, 2, \dots, m. \end{aligned}$$

软间隔支持向量机

$$L(\mathbf{w}, b, \alpha, \xi, \mu) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i + \sum_{i=1}^m \alpha_i (1 - \xi_i - y_i(\mathbf{w}' \mathbf{x}_i + b)) - \sum_{i=1}^m \mu_i \xi_i,$$

- 其中, $\alpha_i \geq 0$ 与 $\mu_i \geq 0$ 是拉格朗日乘子.
- $L(\mathbf{w}, b, \alpha, \xi, \mu)$ 对 $\mathbf{w}, b, \xi_i$ 求偏导并令它们等于0, 有

$$\begin{cases} \mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i, \\ 0 = \sum_{i=1}^m \alpha_i y_i, \\ C = \alpha_i + \mu_i. \end{cases}$$

软间隔支持向量机

对偶问题

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^{\top} \mathbf{x}_j - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, m. \end{aligned}$$

可以发现，上式与硬间隔支持向量机的对偶问题的唯一差别就在于对偶变量的约束不同：前者是 $0 \leq \alpha_i \leq C$ ，后者是 $0 \leq \alpha_i$ 。因此，可同样采样**SMO**算法求解上面的软间隔下的对偶问题。

求解 $\mathbf{w}$ 和 b

□ KKT条件:

$$\nabla_{\mathbf{w}} L(\mathbf{w}^*, b^*, \boldsymbol{\alpha}^*, \boldsymbol{\xi}^*, \boldsymbol{\mu}^*) = \mathbf{w}^* - \sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i = \mathbf{0}$$

$$\nabla_b L(\mathbf{w}^*, b^*, \boldsymbol{\alpha}^*, \boldsymbol{\xi}^*, \boldsymbol{\mu}^*) = - \sum_{i=1}^m \alpha_i^* y_i = 0$$

$$\nabla_{\boldsymbol{\xi}} L(\mathbf{w}^*, b^*, \boldsymbol{\alpha}^*, \boldsymbol{\xi}^*, \boldsymbol{\mu}^*) = C \cdot \mathbf{1} - \boldsymbol{\alpha}^* - \boldsymbol{\mu}^* = \mathbf{0}$$

$$\alpha_i^* \geq 0, \quad \mu_i^* \geq 0$$

$$y_i f(\mathbf{x}_i) - 1 + \xi_i^* \geq 0$$

$$\alpha_i^* (y_i f(\mathbf{x}_i) - 1 + \xi_i^*) = 0$$

$$\xi_i^* \geq 0, \quad \mu_i^* \xi_i^* = 0$$

求解 $\mathbf{w}$ 和 b

定理：设 $\boldsymbol{\alpha}^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_m^*)^T$ 是对偶问题的最优解，则存在下标 j ，使得 $\alpha_j^* > 0$ ，并可求得原问题的最优解为

$$\mathbf{w}^* = \sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i \quad b^* = y_j - \sum_{i=1}^m \alpha_i^* y_i (\mathbf{x}_i^T \mathbf{x}_j)$$

证明：基于KKT条件知， $\mathbf{w}^* = \sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i$ ，则其中至少有一个 $\alpha_j^* > 0$

反正法——假设 $\boldsymbol{\alpha}^* = \mathbf{0}$ ，则有 $\mathbf{w}^* = \mathbf{0}$ 。这明显不是原问题的最优解，故产生矛盾。

选择 j 使得 $\alpha_j^* > 0$ ，此时 $\xi_j^* = 0$ 。有 $y_j(\mathbf{w}^{*T} \mathbf{x}_j + b^*) - 1 = 0$

由于 $y_j^2 = 1$ ，所以可得 $b^* = y_j - \sum_{i=1}^m \alpha_i^* y_i (\mathbf{x}_i^T \mathbf{x}_j)$

解的稀疏性

□ 由KKT条件 $\alpha_i^* \geq 0, \mu_i^* \geq 0$

$$y_i f(\mathbf{x}_i) - 1 + \xi_i^* \geq 0$$

$$\alpha_i^* (y_i f(\mathbf{x}_i) - 1 + \xi_i^*) = 0$$

$$\xi_i^* \geq 0, \mu_i^* \xi_i^* = 0$$

- 若 $\alpha_i = 0$, 表示样品 $(\mathbf{x}_i, y_i)$ 在分类模型 $f(\mathbf{x})$ 中不起任何作用;
- 若 $\alpha_i > 0$, 说明 $y_i f(\mathbf{x}_i) - 1 + \xi_i = 0$, 样品 $(\mathbf{x}_i, y_i)$ 是支持向量.
 - $\alpha_i < C$, 则 $\mu_i > 0$, 于是 $\xi_i = 0$, 此时样品落于边界上;
 - $\alpha_i = C$, 则 $\mu_i = 0$,
 - $\xi_i \leq 1$ 则该样品落在最大间隔内部;
 - $\xi_i > 1$ 则分类错误.

解的稀疏性

□ 由KKT条件 $\alpha_i^* \geq 0, \mu_i^* \geq 0$

$$y_i f(\mathbf{x}_i) - 1 + \xi_i^* \geq 0$$

$$\alpha_i^* (y_i f(\mathbf{x}_i) - 1 + \xi_i^*) = 0$$

$$\xi_i^* \geq 0, \mu_i^* \xi_i^* = 0$$

根据KKT条件可推得最终模型仅与支持向量有关, 也即hinge损失函数依然保持了支持向量机解的稀疏性.

正则化

- 给定训练集 $D = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_m, y_m)\}$. 超平面分类器:

$$f(\mathbf{x}) = \mathbf{w}'\mathbf{x} + b.$$


思路	表达式
硬间隔	$\min_{\mathbf{w}, b} \frac{1}{2} \ \mathbf{w}\ ^2 + \infty \sum_{i=1}^m \ell_{\text{hinge}}(y_i f(\mathbf{x}_i) - 1)$
软间隔 + $\ell_{0/1}$	$\min_{\mathbf{w}, b} \frac{1}{2} \ \mathbf{w}\ ^2 + C \sum_{i=1}^m \ell_{0/1}(y_i f(\mathbf{x}_i) - 1)$
软间隔 + ℓ_{hinge}	$\min_{\mathbf{w}, b} \frac{1}{2} \ \mathbf{w}\ ^2 + C \sum_{i=1}^m \ell_{\text{hinge}}(y_i f(\mathbf{x}_i) - 1)$

- 三者共性:

$$\min \Omega(f) + C \sum_{i=1}^m \ell(f(\mathbf{x}_i), y_i).$$

正则化

- 支持向量机学习模型的更一般形式

$$\min_f \Omega(f) + C \sum_{i=1}^m l(f(\mathbf{x}_i), y_i)$$


结构风险, 描述模型的某些性质

经验风险, 描述模型与训练数据的契合程度

- 结构风险约束所获得某些性质的模型, 这为引入领域知识和用户意图提供途径; 再者, 该信息有助于削减假设空间, 从而降低模型过拟合风险。为此, 从经验风险最小化的角度来说, $\Omega(f)$ 称为正则化项。
- 通过替换上面两个部分, 可以得到许多其他学习模型
 - 对数几率回归(Logistic Regression)
 - 最小绝对收缩选择算子(LASSO)
 -

大纲

□ 间隔与支持向量

□ 对偶问题

□ 软间隔与正则化


□ 支持向量回归

□ 核函数

□ 核方法


支持向量回归

- 给定训练样本 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$, $\{y_i\}_{i=1}^m \in \mathbb{R}$
- 传统回归模型通常基于模型输出与真实输出之间的差别计算损失, 当且仅当它们完全相等时, 损失才为0; 与此不同, 支持向量回归允许模型输出和真实输出间存在 ϵ 的偏差.



损失函数

即仅当模型输出和真实输出之间的差别绝对值大于 ϵ 时才计算损失，这相当于训练样本落入中间 2ϵ 间隔带的样本不计算损失，从而使得模型获得稀疏性。



形式化

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \ell_{\epsilon}(f(\mathbf{x}_i) - y_i)$$

原始问题

$$\min_{\mathbf{w}, b, \xi_i, \hat{\xi}_i} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m (\xi_i + \hat{\xi}_i)$$

$$\text{s.t. } f(\mathbf{x}_i) - y_i \leq \epsilon + \xi_i$$

$$y_i - f(\mathbf{x}_i) \leq \epsilon + \hat{\xi}_i$$

$$\xi_i \geq 0, \hat{\xi}_i \geq 0, i = 1, 2, \dots, m$$



形式化

引入拉格朗日乘子 $\mu_i \geq 0, \hat{\mu}_i \geq 0, \alpha_i \geq 0, \hat{\alpha}_i \geq 0,$

$$\begin{aligned} L(\mathbf{w}, b, \alpha, \hat{\alpha}, \xi, \hat{\xi}, \mu, \hat{\mu}) \\ = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m (\xi_i + \hat{\xi}_i) - \sum_{i=1}^m \mu_i \xi_i - \sum_{i=1}^m \hat{\mu}_i \hat{\xi}_i \\ + \sum_{i=1}^m \alpha_i (f(\mathbf{x}_i) - y_i - \epsilon - \xi_i) + \sum_{i=1}^m \hat{\alpha}_i (y_i - f(\mathbf{x}_i) - \epsilon - \hat{\xi}_i) . \end{aligned}$$

再令 $L(\mathbf{w}, b, \alpha, \hat{\alpha}, \xi, \hat{\xi}, \mu, \hat{\mu})$ 对 $\mathbf{w}, b, \xi_i$ 和 $\hat{\xi}_i$ 的偏导为零可得

$$\begin{aligned} \mathbf{w} &= \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) \mathbf{x}_i , & C &= \alpha_i + \mu_i , \\ 0 &= \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) , & C &= \hat{\alpha}_i + \hat{\mu}_i . \end{aligned}$$

形式化

对偶问题

$$\begin{aligned} \max_{\boldsymbol{\alpha}, \hat{\boldsymbol{\alpha}}} & \sum_{i=1}^m y_i (\hat{\alpha}_i - \alpha_i) - \epsilon (\hat{\alpha}_i + \alpha_i) \\ & - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m (\hat{\alpha}_i - \alpha_i) (\hat{\alpha}_j - \alpha_j) \mathbf{x}_i^T \mathbf{x}_j \\ \text{s.t.} & \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) = 0 \\ & 0 \leq \alpha_i, \hat{\alpha}_i \leq C \end{aligned}$$

求解 w 和 b

□ 由KKT条件

$$\begin{cases} \alpha_i(f(\mathbf{x}_i) - y_i - \epsilon - \xi_i) = 0, \\ \hat{\alpha}_i(y_i - f(\mathbf{x}_i) - \epsilon - \hat{\xi}_i) = 0, \\ \alpha_i \hat{\alpha}_i = 0, \quad \xi_i \hat{\xi}_i = 0, \\ (C - \alpha_i)\xi_i = 0, \quad (C - \hat{\alpha}_i)\hat{\xi}_i = 0. \end{cases}$$

可以看出, 当且仅当 $f(\mathbf{x}_i) - y_i - \epsilon - \xi_i = 0$ 时 α_i 能取非零值, 当且仅当 $y_i - f(\mathbf{x}_i) - \epsilon - \hat{\xi}_i = 0$ 时 $\hat{\alpha}_i$ 能取非零值. 换言之, 仅当样本 $(\mathbf{x}_i, y_i)$ 不落入 ϵ -间隔带中, 相应的 α_i 和 $\hat{\alpha}_i$ 才能取非零值. 此外, 约束 $f(\mathbf{x}_i) - y_i - \epsilon - \xi_i = 0$ 和 $y_i - f(\mathbf{x}_i) - \epsilon - \hat{\xi}_i = 0$ 不能同时成立, 因此 α_i 和 $\hat{\alpha}_i$ 中至少有一个为零.

求解 $\mathbf{w}$ 和 b

$$\mathbf{w} = \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) \mathbf{x}_i, \text{ SVR的解形如}$$

$$f(\mathbf{x}) = \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) \mathbf{x}_i^T \mathbf{x} + b.$$

□ 由KKT条件可知, 对每个样本 $(\mathbf{x}_i, y_i)$ 都有 $(C - \alpha_i)\xi_i = 0$ 且 $\alpha_i(f(\mathbf{x}_i) - y_i - \epsilon - \xi_i) = 0$. 于是, 在得到 α_i 后, 若 $0 < \alpha_i < C$, 则必有 $\xi_i = 0$, 进而有 $b = y_i + \epsilon - \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) \mathbf{x}_i^T \mathbf{x}$.

实践中常采用一种更鲁棒的办法: 选取多个(或所有)满足条件 $0 < \alpha_i < C$ 的样本求解 b 后取平均值.

解的稀疏性

□ 由KKT条件

$$\begin{cases} \alpha_i(f(\mathbf{x}_i) - y_i - \epsilon - \xi_i) = 0, \\ \hat{\alpha}_i(y_i - f(\mathbf{x}_i) - \epsilon - \hat{\xi}_i) = 0, \\ \alpha_i \hat{\alpha}_i = 0, \quad \xi_i \hat{\xi}_i = 0, \\ (C - \alpha_i)\xi_i = 0, \quad (C - \hat{\alpha}_i)\hat{\xi}_i = 0. \end{cases}$$

$$f(\mathbf{x}) = \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) \mathbf{x}_i^T \mathbf{x} + b. \quad (6.53)$$

能使式(6.53)中的 $(\hat{\alpha}_i - \alpha_i) \neq 0$ 的样本即为 SVR 的支持向量, 它们必落在 ϵ -间隔带之外. 显然, SVR 的支持向量仅是训练样本的一部分, 即其解仍具有稀疏性.

大纲

□ 间隔与支持向量

□ 对偶问题

□ 软间隔与正则化


□ 支持向量回归

□ 核函数

□ 核方法

线性不可分


-Q: 以上我们均假设训练样本是线性可分的, 即存在一个超平面能将训练样本正确分类。



线性不可分

-Q: 以上我们均假设训练样本是线性可分的, 即存在一个超平面能将训练样本正确分类。然而, 现实任务中, 原始样本空间中也许并不存在一个能正确划分两类样本的超平面, 怎么办?

-A: 将样本从原始空间 (非线性变换) 映射到一个更高维的特征空间, 使得样本在这个特征空间内线性可分, 然后在新空间里用线性分类学习方法从训练数据中学习分类模型。



核支持向量机

- 映射前 x
- 映射后 $\phi(x)$

- 映射前划分超平面为

$$f(x) = w'x + b$$

- 映射后划分超平面为

$$f(x) = w'\phi(x) + b$$

- 映射前基本形式:

$$\begin{aligned} \min_{w,b} \quad & \frac{1}{2} \|w\|^2 \\ \text{s.t.} \quad & (1 - y_i(w'x_i + b)) \leq 0, i = 1, 2, \dots, m. \end{aligned}$$

- 映射后基本形式:

$$\begin{aligned} \min_{w,b} \quad & \frac{1}{2} \|w\|^2 \\ \text{s.t.} \quad & (1 - y_i(w'\phi(x_i) + b)) \leq 0, i = 1, 2, \dots, m. \end{aligned}$$

核支持向量机

□ 设样本 $\mathbf{x}$ 映射后的向量为 $\phi(\mathbf{x})$, 划分超平面为 $f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b$.

原始问题

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_i (\mathbf{w}^\top \phi(\mathbf{x}_i) + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$

对偶问题

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \boxed{\phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)} - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i = 1, 2, \dots, m. \end{aligned}$$

预测

$$f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b = \sum_{i=1}^m \alpha_i y_i \boxed{\phi(\mathbf{x}_i)^\top \phi(\mathbf{x})} + b$$

核函数

□ 基本想法：我们通常不知道映射 $\phi(\mathbf{x})$ 是什么，而是定义核函数。

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$$

即 $\mathbf{x}_i$ 与 $\mathbf{x}_j$ 在新特征空间的内积等于它们在原始样本空间中通过核函数 $\kappa(\mathbf{x}_i, \mathbf{x}_j)$ 计算而得，这样可避免直接计算高维甚至无穷维特征空间中的内积。

□ Mercer定理：任何一个对称函数所对应的核矩阵半正定，它就可以作为核函数。

定理 6.1 (核函数) 令 $\mathcal{X}$ 为输入空间, $\kappa(\cdot, \cdot)$ 是定义在 $\mathcal{X} \times \mathcal{X}$ 上的对称函数, 则 κ 是核函数当且仅当对于任意数据 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$, “核矩阵” (kernel matrix) $\mathbf{K}$ 总是半正定的:

$$\mathbf{K} = \begin{bmatrix} \kappa(\mathbf{x}_1, \mathbf{x}_1) & \cdots & \kappa(\mathbf{x}_1, \mathbf{x}_j) & \cdots & \kappa(\mathbf{x}_1, \mathbf{x}_m) \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ \kappa(\mathbf{x}_i, \mathbf{x}_1) & \cdots & \kappa(\mathbf{x}_i, \mathbf{x}_j) & \cdots & \kappa(\mathbf{x}_i, \mathbf{x}_m) \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ \kappa(\mathbf{x}_m, \mathbf{x}_1) & \cdots & \kappa(\mathbf{x}_m, \mathbf{x}_j) & \cdots & \kappa(\mathbf{x}_m, \mathbf{x}_m) \end{bmatrix}$$

核函数

□ 常常用核函数：

名称	表达式	参数
线性核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^\top \mathbf{x}_j$	
多项式核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^\top \mathbf{x}_j)^d$	$d \geq 1$ 为多项式的次数
高斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ ^2}{2\delta^2}\right)$	$\delta > 0$ 为高斯核的带宽(width)
拉普拉斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ }{\delta}\right)$	$\delta > 0$
Sigmoid核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^\top \mathbf{x}_j + \theta)$	$\tanh$ 为双曲正切函数, $\beta > 0, \theta < 0$

□ 还可核函数之间组合成新的核函数：若 $\mathbf{k}_1$ 和 $\mathbf{k}_2$ 为核函数，则

- ① 对任意正数 r_1 和 r_2 , $r_1 \mathbf{k}_1 + r_2 \mathbf{k}_2$
- ② 核函数的直积 $k_1 \otimes k_2(\mathbf{x}, \mathbf{z}) = k_1(\mathbf{x}, \mathbf{z})k_2(\mathbf{x}, \mathbf{z})$
- ③ 对任意函数 $g(\mathbf{x})$, $k(\mathbf{x}, \mathbf{z}) = g(\mathbf{x})k_1(\mathbf{x}, \mathbf{z})g(\mathbf{z})$

大纲

□ 间隔与支持向量

□ 对偶问题

□ 软间隔与正则化

□ 支持向量回归

□ 核函数

□ 核方法

表示定理

支持向量机
$$f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b = \sum_{i=1}^m \alpha_i y_i \kappa(\mathbf{x}_i, \mathbf{x}) + b$$

支持向量回归
$$f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b = \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) y_i \kappa(\mathbf{x}_i, \mathbf{x}) + b$$

结论：若不考虑偏移项，无论是支持向量机还是支持向量回归，学得的模型总可以表示成核函数的线性组合。

更一般的结论(表示定理)：对于任意单调增函数 Ω 和任意非负损失函数 l ，优化问题

$$\min_{h \in \mathbb{H}} F(h) = \Omega(\|h\|_{\mathbb{H}}) + l(h(\mathbf{x}_1), \dots, h(\mathbf{x}_m))$$

的解总可以写为
$$h^* = \sum_{i=1}^m \alpha_i \kappa(\cdot, \mathbf{x}_i).$$

核线性判别分析

□ 通过表示定理可以得到很多线性模型的“核化”版本

- 核SVM
- 核LDA
- 核PCA
-

□ 核LDA: 先将样本映射到高维特征空间 $h(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x})$, 然后在此特征空间中做线性判别分析, 即学习目标为

$$\max_{\mathbf{w}} J(\mathbf{w}) = \frac{\mathbf{w}^\top \mathbf{S}_b^\phi \mathbf{w}}{\mathbf{w}^\top \mathbf{S}_w^\phi \mathbf{w}}$$

其中 $\mathbf{S}_b^\phi$ 和 $\mathbf{S}_w^\phi$ 分别为训练样本在特征空间 $\mathbb{F}$ 中的类间散度矩阵和类内散度矩阵。

核线性判别分析

令 X_i 表示第 $i \in \{0, 1\}$ 类样本的集合, 其样本数为 m_i ;

第 i 类样本在特征空间 $\mathbb{F}$ 中的均值为 $\mu_i^\phi = \frac{1}{m_i} \sum_{\mathbf{x} \in X_i} \phi(\mathbf{x})$,

$$\mathbf{S}_b^\phi = (\mu_1^\phi - \mu_0^\phi)(\mu_1^\phi - \mu_0^\phi)^\top;$$

$$\mathbf{S}_w^\phi = \sum_{i=0}^1 \sum_{\mathbf{x} \in X_i} (\phi(\mathbf{x}) - \mu_i^\phi)(\phi(\mathbf{x}) - \mu_i^\phi)^\top.$$

通常我们难以知道映射 ϕ 的具体形式, 因此使用核函数 $\kappa(\mathbf{x}, \mathbf{x}_i) = \phi(\mathbf{x}_i)^\top \phi(\mathbf{x})$ 来隐式地表达这个映射和特征空间 $\mathbb{F}$ 。把 $J(\mathbf{w})$ 作为损失函数 ℓ , 再令 $\Omega \equiv 0$, 由表示定理, 函数 $h(\mathbf{x})$ 可写为:

$$h(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) = \sum_{i=1}^m \alpha_i \kappa(\mathbf{x}_i, \mathbf{x})$$

从而,
$$\mathbf{w} = \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i).$$

核线性判别分析

令 $\mathbf{K} \in \mathbb{R}^{m \times m}$ 为核函数 κ 所对应的核矩阵, $(\mathbf{K})_{ij} = \kappa(\mathbf{x}_i, \mathbf{x}_j)$ 。令 $\mathbf{l}_i \in \{1, 0\}^{m \times 1}$ 为第 i 类样本的指示向量, 即 $\mathbf{l}_i$ 的第 j 个分量为 1 当且仅当 $\mathbf{x}_j \in \mathbf{X}_i$, 否则 $\mathbf{l}_i$ 的第 j 个分量为 0。再令:

$$\hat{\mu}_0 = \frac{1}{m_0} \mathbf{K} \mathbf{l}_0$$

$$\hat{\mu}_1 = \frac{1}{m_1} \mathbf{K} \mathbf{l}_1$$

$$\mathbf{M} = (\hat{\mu}_0 - \hat{\mu}_1)(\hat{\mu}_0 - \hat{\mu}_1)^T$$

$$\mathbf{N} = \mathbf{K} \mathbf{K}^T - \sum_{i=0}^1 m_i \hat{\mu}_i \hat{\mu}_i^T$$

则我们有

$$\max_{\mathbf{w}} J(\mathbf{w}) = \frac{\mathbf{w}^\top \mathbf{S}_b^\phi \mathbf{w}}{\mathbf{w}^\top \mathbf{S}_w^\phi \mathbf{w}} \quad \longleftrightarrow \quad \max_{\boldsymbol{\alpha}} J(\boldsymbol{\alpha}) = \frac{\boldsymbol{\alpha}^\top \mathbf{M} \boldsymbol{\alpha}}{\boldsymbol{\alpha}^\top \mathbf{N} \boldsymbol{\alpha}}$$

核线性判别分析

$$\begin{aligned}\mathbf{w}^T \mathbf{S}_b^\phi \mathbf{w} &= \left(\sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i) \right)^T \cdot \mathbf{S}_b^\phi \cdot \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i) \\ &= \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i)^T \cdot \mathbf{S}_b^\phi \cdot \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i)\end{aligned}$$

$$\begin{aligned}\mathbf{S}_b^\phi &= (\mu_1^\phi - \mu_0^\phi)(\mu_1^\phi - \mu_0^\phi)^T \\ &= \left(\frac{1}{m_1} \sum_{\mathbf{x} \in X_1} \phi(\mathbf{x}) - \frac{1}{m_0} \sum_{\mathbf{x} \in X_0} \phi(\mathbf{x}) \right) \left(\frac{1}{m_1} \sum_{\mathbf{x} \in X_1} \phi(\mathbf{x}) - \frac{1}{m_0} \sum_{\mathbf{x} \in X_0} \phi(\mathbf{x}) \right)^T \\ &= \left(\frac{1}{m_1} \sum_{\mathbf{x} \in X_1} \phi(\mathbf{x}) - \frac{1}{m_0} \sum_{\mathbf{x} \in X_0} \phi(\mathbf{x}) \right) \left(\frac{1}{m_1} \sum_{\mathbf{x} \in X_1} \phi(\mathbf{x})^T - \frac{1}{m_0} \sum_{\mathbf{x} \in X_0} \phi(\mathbf{x})^T \right)\end{aligned}$$



$$\begin{aligned}\mathbf{w}^T \mathbf{S}_b^\phi \mathbf{w} &= \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i)^T \cdot \left(\frac{1}{m_1} \sum_{\mathbf{x} \in X_1} \phi(\mathbf{x}) - \frac{1}{m_0} \sum_{\mathbf{x} \in X_0} \phi(\mathbf{x}) \right) \left(\frac{1}{m_1} \sum_{\mathbf{x} \in X_1} \phi(\mathbf{x})^T - \frac{1}{m_0} \sum_{\mathbf{x} \in X_0} \phi(\mathbf{x})^T \right) \cdot \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i) \\ &= \left(\frac{1}{m_1} \sum_{\mathbf{x} \in X_1} \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i)^T \phi(\mathbf{x}) - \frac{1}{m_0} \sum_{\mathbf{x} \in X_0} \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i)^T \phi(\mathbf{x}) \right) \left(\frac{1}{m_1} \sum_{\mathbf{x} \in X_1} \sum_{i=1}^m \alpha_i \phi(\mathbf{x})^T \phi(\mathbf{x}_i) - \frac{1}{m_0} \sum_{\mathbf{x} \in X_0} \sum_{i=1}^m \alpha_i \phi(\mathbf{x})^T \phi(\mathbf{x}_i) \right)\end{aligned}$$

核线性判别分析

由于 $\kappa(\mathbf{x}_i, \mathbf{x}) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x})$ 为标量, 所以其转置等于本身, 也即


$$\kappa(\mathbf{x}_i, \mathbf{x}) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}) = (\phi(\mathbf{x}_i)^T \phi(\mathbf{x}))^T = \phi(\mathbf{x})^T \phi(\mathbf{x}_i) = \kappa(\mathbf{x}, \mathbf{x}_i)^T,$$

$$\begin{aligned}\mathbf{w}^T \mathbf{S}_b^\phi \mathbf{w} &= \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i)^T \cdot \left(\frac{1}{m_1} \sum_{\mathbf{x} \in X_1} \phi(\mathbf{x}) - \frac{1}{m_0} \sum_{\mathbf{x} \in X_0} \phi(\mathbf{x}) \right) \left(\frac{1}{m_1} \sum_{\mathbf{x} \in X_1} \phi(\mathbf{x})^T - \frac{1}{m_0} \sum_{\mathbf{x} \in X_0} \phi(\mathbf{x})^T \right) \cdot \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i) \\ &= \left(\frac{1}{m_1} \sum_{\mathbf{x} \in X_1} \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i)^T \phi(\mathbf{x}) - \frac{1}{m_0} \sum_{\mathbf{x} \in X_0} \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i)^T \phi(\mathbf{x}) \right) \left(\frac{1}{m_1} \sum_{\mathbf{x} \in X_1} \sum_{i=1}^m \alpha_i \phi(\mathbf{x})^T \phi(\mathbf{x}_i) - \frac{1}{m_0} \sum_{\mathbf{x} \in X_0} \sum_{i=1}^m \alpha_i \phi(\mathbf{x})^T \phi(\mathbf{x}_i) \right)\end{aligned}$$



$$\mathbf{w}^T \mathbf{S}_b^\phi \mathbf{w} = \left(\frac{1}{m_1} \sum_{i=1}^m \sum_{\mathbf{x} \in X_1} \alpha_i \kappa(\mathbf{x}_i, \mathbf{x}) - \frac{1}{m_0} \sum_{i=1}^m \sum_{\mathbf{x} \in X_0} \alpha_i \kappa(\mathbf{x}_i, \mathbf{x}) \right) \left(\frac{1}{m_1} \sum_{i=1}^m \sum_{\mathbf{x} \in X_1} \alpha_i \kappa(\mathbf{x}, \mathbf{x}_i) - \frac{1}{m_0} \sum_{i=1}^m \sum_{\mathbf{x} \in X_0} \alpha_i \kappa(\mathbf{x}, \mathbf{x}_i) \right)$$

$$\text{令 } \alpha = (\alpha_1; \alpha_2; \cdots; \alpha_m)^T \in \mathbb{R}^{m \times 1}$$



$$\begin{aligned}\mathbf{w}^T \mathbf{S}_b^\phi \mathbf{w} &= (\alpha^T \hat{\mu}_1 - \alpha^T \hat{\mu}_0) \cdot (\hat{\mu}_1^T \alpha - \hat{\mu}_0^T \alpha) \\ &= \alpha^T \cdot (\hat{\mu}_1 - \hat{\mu}_0) \cdot (\hat{\mu}_1^T - \hat{\mu}_0^T) \cdot \alpha \\ &= \alpha^T \cdot (\hat{\mu}_1 - \hat{\mu}_0) \cdot (\hat{\mu}_1 - \hat{\mu}_0)^T \cdot \alpha \\ &= \alpha^T \mathbf{M} \alpha\end{aligned}$$

核线性判别分析

$$\begin{aligned}\mathbf{w}^T \mathbf{S}_w^\phi \mathbf{w} &= \left(\sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i) \right)^T \cdot \mathbf{S}_w^\phi \cdot \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i) \\ &= \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i)^T \cdot \mathbf{S}_w^\phi \cdot \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i)\end{aligned}$$

$$\begin{aligned}\mathbf{S}_w^\phi &= \sum_{i=0}^1 \sum_{\mathbf{x} \in \mathbf{X}_i} \left(\phi(\mathbf{x}) - \mu_i^\phi \right) \left(\phi(\mathbf{x}) - \mu_i^\phi \right)^T \\ &= \sum_{i=0}^1 \sum_{\mathbf{x} \in \mathbf{X}_i} \left(\phi(\mathbf{x}) - \mu_i^\phi \right) \left(\phi(\mathbf{x})^T - \left(\mu_i^\phi \right)^T \right)\end{aligned}$$

$$= \sum_{i=0}^1 \sum_{\mathbf{x} \in \mathbf{X}_i} \left(\phi(\mathbf{x}) \phi(\mathbf{x})^T - \phi(\mathbf{x}) \left(\mu_i^\phi \right)^T - \mu_i^\phi \phi(\mathbf{x})^T + \mu_i^\phi \left(\mu_i^\phi \right)^T \right)$$

$$= \sum_{i=0}^1 \sum_{\mathbf{x} \in \mathbf{X}_i} \phi(\mathbf{x}) \phi(\mathbf{x})^T - \sum_{i=0}^1 \sum_{\mathbf{x} \in \mathbf{X}_i} \phi(\mathbf{x}) \left(\mu_i^\phi \right)^T - \sum_{i=0}^1 \sum_{\mathbf{x} \in \mathbf{X}_i} \mu_i^\phi \phi(\mathbf{x})^T + \sum_{i=0}^1 \sum_{\mathbf{x} \in \mathbf{X}_i} \mu_i^\phi \left(\mu_i^\phi \right)^T$$



$$\mathbf{S}_w^\phi = \sum_{\mathbf{x} \in D} \phi(\mathbf{x}) \phi(\mathbf{x})^T - 2 \left[m_0 \mu_0^\phi \left(\mu_0^\phi \right)^T + m_1 \mu_1^\phi \left(\mu_1^\phi \right)^T \right] + m_0 \mu_0^\phi \left(\mu_0^\phi \right)^T + m_1 \mu_1^\phi \left(\mu_1^\phi \right)^T$$

$$= \sum_{\mathbf{x} \in D} \phi(\mathbf{x}) \phi(\mathbf{x})^T - m_0 \mu_0^\phi \left(\mu_0^\phi \right)^T - m_1 \mu_1^\phi \left(\mu_1^\phi \right)^T$$

$$\begin{aligned}\sum_{i=0}^1 \sum_{\mathbf{x} \in \mathbf{X}_i} \phi(\mathbf{x}) \left(\mu_i^\phi \right)^T &= \sum_{\mathbf{x} \in \mathbf{X}_0} \phi(\mathbf{x}) \left(\mu_0^\phi \right)^T + \sum_{\mathbf{x} \in \mathbf{X}_1} \phi(\mathbf{x}) \left(\mu_1^\phi \right)^T \\ &= m_0 \mu_0^\phi \left(\mu_0^\phi \right)^T + m_1 \mu_1^\phi \left(\mu_1^\phi \right)^T\end{aligned}$$

$$\begin{aligned}\sum_{i=0}^1 \sum_{\mathbf{x} \in \mathbf{X}_i} \mu_i^\phi \phi(\mathbf{x})^T &= \sum_{i=0}^1 \mu_i^\phi \sum_{\mathbf{x} \in \mathbf{X}_i} \phi(\mathbf{x})^T \\ &= \mu_0^\phi \sum_{\mathbf{x} \in \mathbf{X}_0} \phi(\mathbf{x})^T + \mu_1^\phi \sum_{\mathbf{x} \in \mathbf{X}_1} \phi(\mathbf{x})^T \\ &= m_0 \mu_0^\phi \left(\mu_0^\phi \right)^T + m_1 \mu_1^\phi \left(\mu_1^\phi \right)^T\end{aligned}$$

核线性判别分析

$$\begin{aligned}
 \mathbf{w}^T \mathbf{S}_w^\phi \mathbf{w} &= \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i)^T \cdot \mathbf{S}_w^\phi \cdot \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i) \\
 &= \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i)^T \cdot \left(\sum_{\mathbf{x} \in D} \phi(\mathbf{x}) \phi(\mathbf{x})^T - m_0 \mu_0^\phi (\mu_0^\phi)^T - m_1 \mu_1^\phi (\mu_1^\phi)^T \right) \cdot \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i) \\
 &= \sum_{i=1}^m \sum_{j=1}^m \sum_{\mathbf{x} \in D} \alpha_i \phi(\mathbf{x}_i)^T \phi(\mathbf{x}) \phi(\mathbf{x})^T \alpha_j \phi(\mathbf{x}_j) - \sum_{i=1}^m \sum_{j=1}^m \alpha_i \phi(\mathbf{x}_i)^T m_0 \mu_0^\phi (\mu_0^\phi)^T \alpha_j \phi(\mathbf{x}_j) - \sum_{i=1}^m \sum_{j=1}^m \alpha_i \phi(\mathbf{x}_i)^T m_1 \mu_1^\phi (\mu_1^\phi)^T \alpha_j \phi(\mathbf{x}_j)
 \end{aligned}$$

$$\textcircled{1} \quad \sum_{i=1}^m \sum_{j=1}^m \sum_{\mathbf{x} \in D} \alpha_i \phi(\mathbf{x}_i)^T \phi(\mathbf{x}) \phi(\mathbf{x})^T \alpha_j \phi(\mathbf{x}_j) = \sum_{i=1}^m \sum_{j=1}^m \sum_{\mathbf{x} \in D} \alpha_i \alpha_j \kappa(\mathbf{x}_i, \mathbf{x}) \kappa(\mathbf{x}_j, \mathbf{x}) = \alpha^T \mathbf{K} \mathbf{K}^T \alpha$$

$$\begin{aligned}
 \textcircled{2} \quad \sum_{i=1}^m \sum_{j=1}^m \alpha_i \phi(\mathbf{x}_i)^T m_0 \mu_0^\phi (\mu_0^\phi)^T \alpha_j \phi(\mathbf{x}_j) &= m_0 \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j \phi(\mathbf{x}_i)^T \mu_0^\phi (\mu_0^\phi)^T \phi(\mathbf{x}_j) \\
 &= m_0 \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j \phi(\mathbf{x}_i)^T \left[\frac{1}{m_0} \sum_{\mathbf{x} \in X_0} \phi(\mathbf{x}) \right] \left[\frac{1}{m_0} \sum_{\mathbf{x} \in X_0} \phi(\mathbf{x}) \right]^T \phi(\mathbf{x}_j) \\
 &= m_0 \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j \left[\frac{1}{m_0} \sum_{\mathbf{x} \in X_0} \phi(\mathbf{x}_i)^T \phi(\mathbf{x}) \right] \left[\frac{1}{m_0} \sum_{\mathbf{x} \in X_0} \phi(\mathbf{x})^T \phi(\mathbf{x}_j) \right] \\
 &= m_0 \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j \left[\frac{1}{m_0} \sum_{\mathbf{x} \in X_0} \kappa(\mathbf{x}_i, \mathbf{x}) \right] \left[\frac{1}{m_0} \sum_{\mathbf{x} \in X_0} \kappa(\mathbf{x}_j, \mathbf{x}) \right] \\
 &= m_0 \alpha^T \hat{\mu}_0 \hat{\mu}_0^T \alpha
 \end{aligned}$$

$$\textcircled{3} \quad \sum_{i=1}^m \sum_{j=1}^m \alpha_i \phi(\mathbf{x}_i)^T m_1 \mu_1^\phi (\mu_1^\phi)^T \alpha_j \phi(\mathbf{x}_j) = m_1 \alpha^T \hat{\mu}_1 \hat{\mu}_1^T \alpha$$

核线性判别分析

$$\begin{aligned}\mathbf{w}^T \mathbf{S}_w^\phi \mathbf{w} &= \alpha^T \mathbf{K} \mathbf{K}^T \alpha - m_0 \alpha^T \hat{\mu}_0 \hat{\mu}_0^T \alpha - m_1 \alpha^T \hat{\mu}_1 \hat{\mu}_1^T \alpha \\ &= \alpha^T \cdot \left(\mathbf{K} \mathbf{K}^T - m_0 \hat{\mu}_0 \hat{\mu}_0^T - m_1 \hat{\mu}_1 \hat{\mu}_1^T \right) \cdot \alpha \\ &= \alpha^T \cdot \left(\mathbf{K} \mathbf{K}^T - \sum_{i=0}^1 m_i \hat{\mu}_i \hat{\mu}_i^T \right) \cdot \alpha \\ &= \alpha^T \mathbf{N} \alpha\end{aligned}$$

所以,

$$\max_{\mathbf{w}} J(\mathbf{w}) = \frac{\mathbf{w}^\top \mathbf{S}_b^\phi \mathbf{w}}{\mathbf{w}^\top \mathbf{S}_w^\phi \mathbf{w}} \iff \max_{\alpha} J(\alpha) = \frac{\alpha^\top \mathbf{M} \alpha}{\alpha^\top \mathbf{N} \alpha}$$

总结

- 支持向量机的“最大间隔”思想
- 对偶问题及其解的稀疏性
- 引入“软间隔”缓解特征空间中线性不可分的问题
- 将支持向量的思想应用到回归问题上得到支持向量回归
- 通过向高维空间映射解决线性不可分的问题
- 将核方法推广到其他学习模型