

机器学习

Machine Learning

肖力

信息科学技术学院—6系

<https://faculty.ustc.edu.cn/xiaoli>

第7章：贝叶斯分类器

章节目录

□ 贝叶斯决策论

□ 极大似然估计

□ 朴素贝叶斯分类器

□ 半朴素贝叶斯分类器

章节目录

□ 贝叶斯决策论

□ 极大似然估计

□ 朴素贝叶斯分类器

□ 半朴素贝叶斯分类器

概率知识

- 如果 X 和 Y 相互独立, 则有:

$$P(X, Y) = P(X)P(Y)$$

- 条件概率公式:

$$P(Y|X) = P(X, Y)/P(X)$$

- 全概率公式:

$$P(X) = \sum_k P(X|Y = Y_k)P(Y_k)$$

其中 $\sum_k P(Y_k) = 1$

- 由上述推出贝叶斯公式:

$$P(Y_k|X) = \frac{P(X|Y_k)P(Y_k)}{\sum_k P(X|Y = Y_k)P(Y_k)}$$

先验概率与后验概率

- 现有训练集 D , 其中每一个对象 $x = (x_1, x_2, \dots, x_n)$ 分别对应数据库属性 $A_1, A_2, \dots, A_n$. 令 H 是某种假设.
 - $P(H)$ 称为先验概率(prior probability).
 - $P(H|x)$ 称为后验概率(posterior probability), 或者在 x 条件下 H 的后验概率.

简言之，先验概率是指在没有任何观测数据的情况下，对某个事件或参数的概率估计。后验概率是指获得新的观测数据之后，对某个事件或参数的概率估计。后验概率是根据先验概率和新的观测数据来计算得到的，它反映了在新的信息下对事件或参数的重新评估。

先验概率与后验概率

- 例如, 假设训练集 D 中的对象为包含两个属性age和income的顾客. 而 x 是一位35岁的顾客, 其收入为4万美元.
- 令 H 为某种假设, 如顾客将购买计算机.
- 则 $P(H|x)$ 反映当我们知道顾客的年龄和收入时, 顾客将购买计算机的概率.
- $P(H)$ 表示任意顾客准备购买计算机的概率, 而不管他们的年龄和收入如何.

贝叶斯决策论

□ 贝叶斯决策论 (Bayesian decision theory) 是在概率框架下实施决策的基本方法。

- 在分类问题情况下，在所有相关概率都已知的理想情形下，贝叶斯决策考虑如何基于这些概率和误判损失来选择最优的类别标记。

□ 假设有 N 种可能的类别标记，即 $y = \{c_1, c_2, \dots, c_N\}$, λ_{ij} 是将一个真实标记为 c_j 的样本误分类为 c_i 所产生的损失。基于后验概率 $P\{c_i | \mathbf{x}\}$ 可获得将样本 $\mathbf{x}$ 分类为 c_i 所产生的期望损失 (expected loss)，即在样本上的“条件风险” (conditional risk)

$$R(c_i | \mathbf{x}) = \sum_{j=1}^N \lambda_{ij} P(c_j | \mathbf{x})$$

可将最小的 $R(c_i | \mathbf{x})$ 的对应的类标签赋予 $\mathbf{x}$ 。即把 $\arg \min_{c \in y} R(c | \mathbf{x})$ 赋予 $\mathbf{x}$ 。

贝叶斯决策论——例子

- 现有一个西瓜, 根据以往经验: 有8成可能这是一个好瓜. 你认为这是一个好瓜还是坏瓜?
- 再根据经验, 将一个坏瓜误识别为好瓜, 损失10元. 将一个好瓜误识别为坏瓜, 损失2元. 你认为这是一个好瓜还是坏瓜?

贝叶斯决策论——例子

- 现有一个西瓜, 根据以往经验: 有8成可能这是一个好瓜. 你认为这是一个好瓜还是坏瓜?
- 再根据经验, 将一个坏瓜误识别为好瓜, 损失10元. 将一个好瓜误识别为坏瓜, 损失2元. 你认为这是一个好瓜还是坏瓜?
- 假设有 N 种可能的类别标记, 即 $\mathcal{Y} = \{c_1, c_2, \dots, c_N\}$.
 - 以西瓜为例: $\mathcal{Y} = \{c_1, c_2\}$, $c_1 = \text{好瓜}$, $c_2 = \text{坏瓜}$, $\mathcal{Y} = \{\text{好瓜}, \text{坏瓜}\}$
- $\lambda_{i,j}$ 是将一个真实标记为 c_j 的对象分类为 c_i 所产生的损失.
 - 以西瓜为例: $\lambda_{1,1} = 0$, $\lambda_{1,2} = 10$, $\lambda_{2,1} = 2$, $\lambda_{2,2} = 0$.
- 后验概率 $P(c_i|\mathbf{x})$
 - 以西瓜为例: $P(\text{好瓜}|\mathbf{x}) = 0.8$, $P(\text{坏瓜}|\mathbf{x}) = 0.2$.

贝叶斯决策论——例子

- $y = \{\text{好瓜}, \text{坏瓜}\}$, $\lambda_{1,1} = 0$, $\lambda_{1,2} = 10$, $\lambda_{2,1} = 2$, $\lambda_{2,2} = 0$.
- 已知某瓜 x , 根据以往经验: $P(\text{好瓜}|x) = 0.8$, $P(\text{坏瓜}|x) = 0.2$.
- 应如何对 x 进行分类? 即你认为这是一个好瓜还是坏瓜?
- 将 x 分类为好瓜的期望损失:
 - $R(\text{好瓜}|x) = \lambda_{1,1} \cdot P(\text{好瓜}|x) + \lambda_{1,2} \cdot P(\text{坏瓜}|x) = 2$;
- 将 x 分类为坏瓜的期望损失:
 - $R(\text{坏瓜}|x) = \lambda_{2,1} \cdot P(\text{好瓜}|x) + \lambda_{2,2} \cdot P(\text{坏瓜}|x) = 1.6$.
- 由于 $R(\text{坏瓜}|x) < R(\text{好瓜}|x)$, x 是一个坏瓜!

贝叶斯决策论——例子

- $y = \{\text{好瓜}, \text{坏瓜}\}$, $\lambda_{1,1} = 0$, $\lambda_{1,2} = 10$, $\lambda_{2,1} = 2$, $\lambda_{2,2} = 0$.
- 已知某瓜 x , 根据以往经验: $P(\text{好瓜}|x) = 0.85$, $P(\text{坏瓜}|x) = 0.15$.
- 应如何对 x 进行分类? 即你认为这是一个好瓜还是坏瓜?
- 将 x 分类为好瓜的期望损失:
 - $R(\text{好瓜}|x) = \lambda_{1,1} \cdot P(\text{好瓜}|x) + \lambda_{1,2} \cdot P(\text{坏瓜}|x) = 1.5$;
- 将 x 分类为坏瓜的期望损失:
 - $R(\text{坏瓜}|x) = \lambda_{2,1} \cdot P(\text{好瓜}|x) + \lambda_{2,2} \cdot P(\text{坏瓜}|x) = 1.7$.
- 由于 $R(\text{好瓜}|x) < R(\text{坏瓜}|x)$, x 是一个好瓜!

贝叶斯决策论

- 为寻找一个判定准则 $h: \mathcal{X} \rightarrow \mathcal{Y}$ 以最小化**总体风险**:

$$R(h) = E[R(h(\mathbf{x})|\mathbf{x})] = E[R(c|\mathbf{x})],$$

贝叶斯决策论

- 为寻找一个判定准则 $h: \mathcal{X} \rightarrow \mathcal{Y}$ 以最小化**总体风险**:

$$R(h) = E[R(h(\mathbf{x})|\mathbf{x})] = E[R(c|\mathbf{x})],$$

- 显然，对每个样本 $\mathbf{x}$ ，若 h 能最小化条件风险 $R(h(\mathbf{x}) | \mathbf{x})$ ，则总体风险 $R(h)$ 也将被最小化。

贝叶斯决策论

- 为寻找一个判定准则 $h: \mathcal{X} \rightarrow \mathcal{Y}$ 以最小化**总体风险**:

$$R(h) = E[R(h(\mathbf{x})|\mathbf{x})] = E[R(c|\mathbf{x})],$$

□ 显然, 对每个样本 $\mathbf{x}$, 若 h 能最小化条件风险 $R(h(\mathbf{x}) | \mathbf{x})$, 则总体风险 $R(h)$ 也将被最小化。

- 只需对 $\forall \mathbf{x} \in \mathcal{X}$, 选择那个能使条件风险 $R(c|\mathbf{x})$ 最小的类别标记, 即

$$h^*(\mathbf{x}) = \arg \min_{c \in \mathcal{Y}} R(c|\mathbf{x}).$$

- 这称为贝叶斯判定准则(Bayes decision rule).
- 此时, h^* 也被称为贝叶斯最优分类器(Bayes optimal classifier), 与之对应的总体风险 $R(h^*)$ 称为贝叶斯风险 (Bayes risk).

贝叶斯决策论

□ 具体来说，若目标是最小化分类错误率，则误判损失 λ_{ij} 可写为

$$\lambda_{i,j} \begin{cases} 0, & \text{if } i = j; \\ 1, & \text{otherwise,} \end{cases} \quad (7.4)$$

贝叶斯决策论

□ 具体来说，若目标是最小化分类错误率，则误判损失 λ_{ij} 可写为

$$\lambda_{i,j} \begin{cases} 0, & \text{if } i = j; \\ 1, & \text{otherwise,} \end{cases} \quad (7.4)$$

□ 此时条件风险

$$R(c \mid \mathbf{x}) = 1 - P(c \mid \mathbf{x}) \quad (7.5)$$

贝叶斯决策论

□ 具体来说，若目标是最小化分类错误率，则误判损失 λ_{ij} 可写为

$$\lambda_{i,j} \begin{cases} 0, & \text{if } i = j; \\ 1, & \text{otherwise,} \end{cases} \quad (7.4)$$

□ 此时条件风险

$$R(c | \mathbf{x}) = 1 - P(c | \mathbf{x}) \quad (7.5)$$

□ 于是，最小化分类错误率的贝叶斯最优分类器为

$$h^*(\mathbf{x}) = \arg \min_{c \in \mathcal{Y}} R(c|\mathbf{x}) = \arg \min_{c \in \mathcal{Y}} (-P(c|\mathbf{x})).$$

贝叶斯决策论

□ 具体来说，若目标是最小化分类错误率，则误判损失 λ_{ij} 可写为

$$\lambda_{i,j} \begin{cases} 0, & \text{if } i = j; \\ 1, & \text{otherwise,} \end{cases} \quad (7.4)$$

□ 此时条件风险

$$R(c \mid \mathbf{x}) = 1 - P(c \mid \mathbf{x}) \quad (7.5)$$

□ 于是，最小化分类错误率的贝叶斯最优分类器为

$$h^*(x) = \operatorname{argmax}_{c \in y} P(c \mid x) \quad (7.6)$$

- 即对每个样本 $\mathbf{x}$ ，选择能使后验概率 $P(c \mid \mathbf{x})$ 最大的类别标记。

贝叶斯决策论

- 不难看出，使用贝叶斯判定准则来最小化决策风险，首先要获得后验概率 $P(c | \mathbf{x})$ 。
- 然而，在现实中通常难以直接获得。机器学习所要实现的是基于有限的训练样本尽可能准确地估计出后验概率 $P(c | \mathbf{x})$ 。
- 大体来说，主要有两种策略：
 - 判别式模型 (discriminative models)
 - 给定 $\mathbf{x}$ ，通过直接建模 $P(c | \mathbf{x})$ ，来预测 c
 - 决策树，BP神经网络，支持向量机
 - 生成式模型 (generative models)
 - 先对联合概率分布 $P(\mathbf{x}, c)$ 建模，再由此获得 $P(c | \mathbf{x})$

贝叶斯决策论

□ 生成式模型

$$P(c \mid \mathbf{x}) = \frac{P(\mathbf{x}, c)}{P(\mathbf{x})} \quad (7.7)$$

贝叶斯决策论

□ 生成式模型

$$P(c | \mathbf{x}) = \frac{P(\mathbf{x}, c)}{P(\mathbf{x})} \quad (7.7)$$

□ 基于贝叶斯定理, $P(c | \mathbf{x})$ 可写成

$$P(c | \mathbf{x}) = \frac{P(c)P(\mathbf{x} | c)}{P(\mathbf{x})} \quad (7.8)$$

贝叶斯决策论

□ 生成式模型

$$P(c | \mathbf{x}) = \frac{P(\mathbf{x}, c)}{P(\mathbf{x})} \quad (7.7)$$

□ 基于贝叶斯定理， $P(c | \mathbf{x})$ 可写成

$$P(c | \mathbf{x}) = \frac{P(c)P(\mathbf{x} | c)}{P(\mathbf{x})} \quad (7.8)$$

先验概率
样本空间中各类样本所占的
比例，可通过各类样本出现
的频率估计（大数定理）

贝叶斯决策论

□ 生成式模型

$$P(c | \mathbf{x}) = \frac{P(\mathbf{x}, c)}{P(\mathbf{x})} \quad (7.7)$$

□ 基于贝叶斯定理， $P(c | \mathbf{x})$ 可写成

$$P(c | \mathbf{x}) = \frac{P(c)P(\mathbf{x} | c)}{P(\mathbf{x})} \quad (7.8)$$

先验概率
样本空间中各类样本所占的比例，可通过各类样本出现的频率估计（大数定理）

“证据” (evidence)
因子，与类标记无关

贝叶斯决策论

□ 生成式模型

$$P(c | \mathbf{x}) = \frac{P(\mathbf{x}, c)}{P(\mathbf{x})} \quad (7.7)$$

□ 基于贝叶斯定理， $P(c | \mathbf{x})$ 可写成

$$P(c | \mathbf{x}) = \frac{P(c)P(\mathbf{x} | c)}{P(\mathbf{x})} \quad (7.8)$$


先验概率
样本空间中各类样本所占的比例，可通过各类样本出现的频率估计（大数定理）

样本 $\mathbf{x}$ 相对于类标记 c 的“类条件概率”（class-conditional probability），或称“似然”。

“证据”（evidence）
因子，与类标记无关

贝叶斯决策论

- 东北大学人工智能专业2019级学生共100人
- 其中男生60人，女生40人，具体身高分布如下图所示：



- 若某学生身高为165公分，预测该生性别。

贝叶斯决策论

► 最大后验概率分类准则

- 设男生为 ω_1 类，女生为 ω_2 类，根据身高数据，则有：

$$p(165|\omega_1) \approx \frac{6}{60} = 0.10; \quad p(165|\omega_2) \approx \frac{14}{40} = 0.35$$

- 根据全概率公式： $p(165) = 0.10 \times 0.6 + 0.35 \times 0.4 = 0.20$
- 根据贝叶斯公式，有：

$$P(\omega_1|165) = \frac{p(165|\omega_1)P(\omega_1)}{p(165)} = \frac{0.10 \times 0.6}{0.20} = 0.3$$

$$P(\omega_2|165) = \frac{p(165|\omega_2)P(\omega_2)}{p(165)} = \frac{0.35 \times 0.4}{0.20} = 0.7$$

- 由于 $P(\omega_2|165) > P(\omega_1|165)$ ，根据最大后验概率分类准则。
- 预测该学生为女生。

贝叶斯决策论

- 因此，估计 $P(c | \mathbf{x})$ 的问题就转化为如何基于训练数据 $\mathbf{D}$ 来估计先验概率 $P(c)$ 和似然（或类条件概率） $P(\mathbf{x} | c)$ 。
- 对 $P(\mathbf{x} | c)$ 来说，由于它涉及关于 $\mathbf{x}$ 的所有属性的联合概率，直接根据样本出现的频率来估计将会遇到严重的困难。例如，假设样本的 d 个属性都是二值的，则样本空间将有 2^d 种可能得取值，在现实应用中，这个值往往远大于训练样本总数，也就是说，很多样本取值在训练集中根本没有出现，从而直接使用频率来估计 $P(\mathbf{x} | c)$ 显然不可行。

章节目录

□ 贝叶斯决策论

□ 极大似然估计

□ 朴素贝叶斯分类器

□ 半朴素贝叶斯分类器

极大似然估计

极大似然估计

概念：总体 X 的分布**已知**，参数 θ 未知。已知一组样本观测值

$$x_1, x_2, \dots, x_n.$$

参数 θ 的选择应有利于样本观测值的发生，即让这组数据发生的

概率**达到最大**。

极大似然估计

步骤:

➤ 似然函数: $L(x_1, x_2, \dots, x_n; \theta) = \begin{cases} \prod_{i=1}^n f(x_i; \theta), & f(x; \theta) \text{ 为 } X \text{ 的概率密度} \\ \prod_{i=1}^n p(X = x_i; \theta), & p(x; \theta) \text{ 为 } X \text{ 的分布律} \end{cases}$

➤ θ 的极大似然估计值 $\hat{\theta}(x_1, x_2, \dots, x_n)$

$$L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta)$$

➤ 求解似然方程 $\frac{d \ln L(\theta)}{d\theta} = 0$

极大似然估计

- 估计类条件概率的常用策略：先假定其具有某种确定的概率分布形式，再基于训练样本对概率分布的参数进行估计。
- 具体地，记关于类别 C 的类条件概率为 $P(\mathbf{x} | c)$ ，
 - 假设 $P(\mathbf{x} | c)$ 具有确定的形式并且被参数 θ_c 唯一确定，则我们的任务就是利用训练集 D 估计参数 θ_c
 - 为明确起见，我们将 $P(\mathbf{x} | c)$ 记为 $P(\mathbf{x} | \theta_c)$

极大似然估计

□ 令 D_c 表示训练集中第 c 类样本组合的集合，假设这些样本是独立同分布的，则参数 θ_c 对于数据集 D_c 的似然是

$$P(D_c | \theta_c) = \prod_{\mathbf{x} \in D_c} P(\mathbf{x} | \theta_c) \quad (7.9)$$

- 对 θ_c 进行极大似然估计，寻找能最大化似然 $P(D_c | \theta_c)$ 的参数值 $\hat{\theta}_c$ 。直观上看，极大似然估计是试图在 θ_c 所有可能的取值中，找到一个使数据出现的“可能性”最大值。

极大似然估计

□ 令 D_c 表示训练集中第 c 类样本组合的集合，假设这些样本是独立同分布的，则参数 θ_c 对于数据集 D_c 的似然是

$$P(D_c | \theta_c) = \prod_{\mathbf{x} \in D_c} P(\mathbf{x} | \theta_c) \quad (7.9)$$

- 对 θ_c 进行极大似然估计，寻找能最大化似然 $P(D_c | \theta_c)$ 的参数值 $\hat{\theta}_c$ 。直观上看，极大似然估计是试图在 θ_c 所有可能的取值中，找到一个使数据出现的“可能性”最大值。

□ 式 (7.9) 的连乘操作易造成下溢，通常使用对数似然(log-likelihood)

$$\begin{aligned} LL(\theta_c) &= \log P(D_c | \theta_c) \\ &= \sum_{\mathbf{x} \in D_c} \log P(\mathbf{x} | \theta_c) \end{aligned} \quad (7.10)$$

□ 此时参数 θ_c 的极大似然估计 $\hat{\theta}_c$ 为 $\hat{\theta}_c = \operatorname{argmax}_{\theta_c} LL(\theta_c)$ (7.11)

极大似然估计

□ 例如，在连续属性情形下，假设概率密度函数 $p(\mathbf{x} \mid c) \sim N(\boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c)$ ，则参数 $\boldsymbol{\mu}_c$ 和 $\boldsymbol{\Sigma}_c$ 的极大似然估计为

$$\hat{\boldsymbol{\mu}}_c = \frac{1}{|D_c|} \sum_{\mathbf{x} \in D_c} \mathbf{x} \quad (7.12)$$

$$\hat{\boldsymbol{\Sigma}}_c = \frac{1}{|D_c|} \sum_{\mathbf{x} \in D_c} (\mathbf{x} - \hat{\boldsymbol{\mu}}_c)(\mathbf{x} - \hat{\boldsymbol{\mu}}_c)^T \quad (7.13)$$

□ 也就是说，通过极大似然法得到的正态分布均值就是样本均值，方差就是 $(\mathbf{x} - \hat{\boldsymbol{\mu}}_c)(\mathbf{x} - \hat{\boldsymbol{\mu}}_c)^T$ 的均值，这显然是一个符合直觉的结果。

极大似然估计

- 一个均值为 μ , 协方差为 Σ 的多元正态分布的概率密度函数为:

$$f(\mathbf{x}, \mu, \Sigma) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} e^{-\frac{1}{2} (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu)}$$

设 $\{\mathbf{x}_i\}, i = 1 \sim N$ 是符合该密度函数的 N 个样本, 满足独立同分布

对数似然函数计算可得:

$$E(\mu, \Sigma) = \sum_{i=1}^N \ln f(\mathbf{x}_i, \mu, \Sigma) = -\frac{Nd}{2} \ln(2\pi) - \frac{N}{2} \ln |\Sigma| - \frac{1}{2} \sum_{i=1}^N (\mathbf{x}_i - \mu)^T \Sigma^{-1} (\mathbf{x}_i - \mu)$$

然后, 分别求对数似然函数关于两个参数 μ 和 Σ 的偏导, 并令为0

$$\frac{\partial E}{\partial \mu} = 0 \quad \frac{\partial E}{\partial \Sigma} = 0$$

极大似然估计

关于 μ 的最大似然估计

$$\begin{aligned} & -\frac{1}{2} \frac{\partial}{\partial \boldsymbol{\mu}} \left\{ \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x}_n - \boldsymbol{\mu}) \right\} \\ &= -\frac{1}{2} \sum_{n=1}^N [-2 \boldsymbol{\Sigma}^{-1} (\mathbf{x}_n - \boldsymbol{\mu})] = 0 \\ &\Rightarrow \hat{\boldsymbol{\mu}}_{ML} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n \end{aligned}$$

$$\frac{\partial \mathbf{x}^T \mathbf{A} \mathbf{x}}{\partial \mathbf{x}} = [\mathbf{A} + \mathbf{A}^T] \mathbf{x}$$

- 高斯分布均值的最大似然估计等于样本的均值。

极大似然估计

关于 Σ 的最大似然估计

- 似然函数关于 Σ 的偏导：设 $\boldsymbol{\theta} = \boldsymbol{\Sigma}^{-1}$


$$\begin{aligned} |\mathbf{A}^{-1}| &= |\mathbf{A}|^{-1} \\ \frac{\partial \mathbf{x}^T \mathbf{Y} \mathbf{x}}{\partial \mathbf{Y}} &= \mathbf{x} \mathbf{x}^T \\ \frac{1}{|\boldsymbol{\theta}|} \frac{\partial |\boldsymbol{\theta}|}{\partial \boldsymbol{\theta}} &= [\boldsymbol{\theta}^{-1}]^T \end{aligned}$$

$$\begin{aligned} & \frac{\partial}{\partial \boldsymbol{\theta}} \left\{ \frac{N}{2} \log |\boldsymbol{\theta}| - \frac{1}{2} \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu})^T \boldsymbol{\theta} (\mathbf{x}_n - \boldsymbol{\mu}) \right\} \\ &= \frac{N}{2} \frac{1}{|\boldsymbol{\theta}|} \frac{\partial |\boldsymbol{\theta}|}{\partial \boldsymbol{\theta}} - \frac{1}{2} \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu}) (\mathbf{x}_n - \boldsymbol{\mu})^T = 0 \\ &\Rightarrow [\hat{\boldsymbol{\theta}}_{ML}^{-1}]^T = \frac{1}{N_1} \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu}) (\mathbf{x}_n - \boldsymbol{\mu})^T \\ &\Rightarrow \hat{\boldsymbol{\Sigma}}_{ML} = \frac{1}{N} \sum_{n=1}^N (\mathbf{x}_n - \hat{\boldsymbol{\mu}}) (\mathbf{x}_n - \hat{\boldsymbol{\mu}})^T \end{aligned}$$

- 高斯分布协方差的最大似然估计等于所有训练模式的协方差。

极大似然估计

■ 需注意的是，这种参数化的方法虽能使类条件概率估计变得相对简单，但估计结果的准确性严重依赖于所假设的概率分布形式是否符合潜在的真实数据分布。例如下图真实数据分布为双峰分布，若采取单峰的高斯分布进行估计，则准确性较低。



章节目录

□ 贝叶斯决策论

□ 极大似然估计

□ 朴素贝叶斯分类器

□ 半朴素贝叶斯分类器

朴素贝叶斯分类器

□ 估计后验概率 $P(c | \mathbf{x})$ 主要困难：类条件概率 $P(\mathbf{x} | c)$ 是所有属性上的联合概率难以从有限的训练样本估计获得。

- 例如： d 个二值属性 $\rightarrow 2^d$ 可能取值， $2^d \gg$ 样本数 m

□ 为避开这个障碍，朴素贝叶斯分类器(Naïve Bayes Classifier)采用了“属性条件独立性假设”：**对已知类别**，假设所有属性互相独立（换言之，假设每个属性独立地对分类结果发生影响）。

□ 基于属性条件独立性假设，(7.8)可重写为

$$P(c | \mathbf{x}) = \frac{P(c)P(\mathbf{x} | c)}{P(\mathbf{x})} = \frac{P(c)}{P(\mathbf{x})} \prod_{i=1}^d P(x_i | c) \quad (7.14)$$

- 其中 d 为属性数目， x_i 为 $\mathbf{x}$ 在第 i 个属性上的取值。

朴素贝叶斯分类器

$$\arg \max_{c \in \mathcal{Y}} P(c|\mathbf{x}) \stackrel{nb}{=} \arg \max_{c \in \mathcal{Y}} \left(\frac{P(c)}{P(\mathbf{x})} \prod_{i=1}^d P(x_i|c) \right)$$

朴素贝叶斯分类器

$$\arg \max_{c \in \mathcal{Y}} P(c|\mathbf{x}) \stackrel{nb}{=} \arg \max_{c \in \mathcal{Y}} \left(\frac{P(c)}{P(\mathbf{x})} \prod_{i=1}^d P(x_i|c) \right)$$

由于对所有类别来说 $P(x)$ 相同，因此基于式 (7.6) 的贝叶斯判定准则有

$$h_{nb}(\mathbf{x}) = \operatorname{argmax}_{c \in \mathcal{Y}} P(c) \prod_{i=1}^d P(x_i | c) \quad (7.15)$$

- 这就是朴素贝叶斯分类器的表达式

朴素贝叶斯分类器

□ 朴素贝叶斯分类器的训练器的训练过程就是基于训练集 D 估计类先验概率 $P(c)$ 并为每个属性估计条件概率 $P(x_i | c)$ 。

- 令 D_c 表示训练集 D 中第 c 类样本组合的集合，若有充足的独立同分布样本，则可容易地估计出类先验概率

$$P(c) = \frac{|D_c|}{|D|}$$

朴素贝叶斯分类器

□ 朴素贝叶斯分类器的训练器的训练过程就是基于训练集 D 估计类先验概率 $P(c)$ 并为每个属性估计条件概率 $P(x_i | c)$ 。

- 令 D_c 表示训练集 D 中第 c 类样本组合的集合，若有充足的独立同分布样本，则可容易地估计出类先验概率

$$P(c) = \frac{|D_c|}{|D|}$$

- 对离散属性而言，令 D_{c,x_i} 表示 D_c 中在第 i 个属性上取值为 x_i 的样本组成的集合，则条件概率 $P(x_i | c)$ 可估计为

$$P(x_i | c) = \frac{|D_{c,x_i}|}{|D_c|}$$

- 对连续属性而言可考虑概率密度函数，假定 $p(x_i | c) \sim N(\mu_{c,i}, \sigma_{c,i}^2)$ ，其中 $\mu_{c,i}$ 和 $\sigma_{c,i}^2$ 分别是第 c 类样本在第 i 个属性上取值的均值和方差，则

$$f(x_i | c) = \frac{1}{\sqrt{2\pi}\sigma_{c,i}} \exp\left(-\frac{(x_i - \mu_{c,i})^2}{2\sigma_{c,i}^2}\right)$$

朴素贝叶斯分类器

- 例子：用西瓜数据集3.0训练一个朴素贝叶斯分类器，对测试例“测1”进行分类（p151，西瓜数据集 p84 表4.3）

色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.657	0.430	?

- 由朴素贝叶斯分类器, 只需比较 $P(\text{好瓜} = \text{是}) \prod_{i=1}^8 P(x_i | \text{好瓜} = \text{是})$
与 $P(\text{好瓜} = \text{否}) \prod_{i=1}^8 P(x_i | \text{好瓜} = \text{否})$.

朴素贝叶斯分类器

$$P(\text{好瓜} = \text{是}) \prod_{i=1}^8 P(x_i | \text{好瓜} = \text{是})$$

■ $P(\text{好瓜} = \text{是}) \times$
 $P(\text{色泽} = \text{青绿} | \text{好瓜} = \text{是}) \times P(\text{根蒂} = \text{蜷缩} | \text{好瓜} = \text{是}) \times$
 $P(\text{敲声} = \text{浊响} | \text{好瓜} = \text{是}) \times P(\text{纹理} = \text{清晰} | \text{好瓜} = \text{是}) \times$
 $P(\text{脐部} = \text{凹陷} | \text{好瓜} = \text{是}) \times P(\text{触感} = \text{硬滑} | \text{好瓜} = \text{是}) \times$
 $P(\text{密度} = 0.657 | \text{好瓜} = \text{是}) \times P(\text{含糖率} = 0.430 | \text{好瓜} = \text{是})$
 $= 0.123$

色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.657	0.430	?

朴素贝叶斯分类器

$$P(\text{好瓜} = \text{否}) \prod_{i=1}^8 P(x_i | \text{好瓜} = \text{否})$$

■ $P(\text{好瓜} = \text{否}) \times$
 $P(\text{色泽} = \text{青绿} | \text{好瓜} = \text{否}) \times P(\text{根蒂} = \text{蜷缩} | \text{好瓜} = \text{否}) \times$
 $P(\text{敲声} = \text{浊响} | \text{好瓜} = \text{否}) \times P(\text{纹理} = \text{清晰} | \text{好瓜} = \text{否}) \times$
 $P(\text{脐部} = \text{凹陷} | \text{好瓜} = \text{否}) \times P(\text{触感} = \text{硬滑} | \text{好瓜} = \text{否}) \times$
 $P(\text{密度} = 0.657 | \text{好瓜} = \text{否}) \times P(\text{含糖率} = 0.430 | \text{好瓜} = \text{否})$
 $= 1.747 \times 10^{-4}$

色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.657	0.430	?

朴素贝叶斯分类器

估计 $P(c)$ ■ 令 D_c 表示训练集 D 中第 c 类样品组成的集合,

$$P(c) = \frac{|D_c|}{|D|}$$

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

朴素贝叶斯分类器

估计 $P(c)$ 令 D_c 表示训练集 D 中第 c 类样品组成的集合,

$$P(c) = \frac{|D_c|}{|D|}$$

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	硬挺	清脆	清晰	平坦	软粘	0.556	0.215	是
6	青绿	硬挺	清脆	清晰	平坦	软粘	0.403	0.237	是
7	乌黑	硬挺	清脆	模糊	平坦	硬滑	0.481	0.149	是
8	乌黑	硬挺	清脆	模糊	平坦	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	凹陷	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

■ $P(\text{好瓜} = \text{是}) = \frac{8}{17} = 0.471$

■ $P(\text{好瓜} = \text{否}) = \frac{9}{17} = 0.529$

朴素贝叶斯分类器

估计 $P(x_i | c)$ 对离散属性而言, 令 D_{c,x_i} 表示 D_c 中在第 i 个属性上取值为 x_i 的样品组成的集合,

$$P(x_i | c) = \frac{|D_{c,x_i}|}{|D_c|}$$

色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.657	0.430	?

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

朴素贝叶斯分类器

估计 $P(x_i | c)$ 对离散属性而言, 令 D_{c,x_i} 表示 D_c 中在第 i 个属性上取值为 x_i 的样品组成的集合,

$$P(x_i | c) = \frac{|D_{c,x_i}|}{|D_c|}$$

色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.657	0.430	?

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.403	0.337	是
7	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.705	0.359	是
8	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.705	0.359	是
9	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.705	0.359	否
10	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.705	0.359	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

▪ $P(\text{色泽} = \text{青绿} | \text{好瓜} = \text{是}) = \frac{3}{8} = 0.375$

▪ $P(\text{色泽} = \text{青绿} | \text{好瓜} = \text{否}) = \frac{3}{9} = 0.333$

朴素贝叶斯分类器

估计 $P(x_i | c)$ 对离散属性而言, 令 D_{c,x_i} 表示 D_c 中在第 i 个属性上取值为 x_i 的样品组成的集合,

$$P(x_i | c) = \frac{|D_{c,x_i}|}{|D_c|}$$

色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.657	0.430	?

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷							是
8	乌黑	稍蜷							是
9	乌黑	稍蜷							否
10	青绿	硬挺							否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

▪ $P(\text{根蒂} = \text{蜷缩} | \text{好瓜} = \text{是}) = \frac{5}{8} = 0.625$

▪ $P(\text{根蒂} = \text{蜷缩} | \text{好瓜} = \text{否}) = \frac{3}{9} = 0.333$

朴素贝叶斯分类器

- 对连续属性而言, 需要估计条件概率密度 $f(x_i|c)$.
- 两个任务
 - 任务一, 找到条件密度函数 $f(x_i|c)$ 的函数形式;
 - 任务二, 求 $f(x_i|c)$ 在待分类样品第 i 个属性处的值 $f(x_i|c)$.

色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.657	0.430	?

朴素贝叶斯分类器

- 假设概率密度函数 $f(x_i|c) \sim N(\mu_{c,i}, \sigma_{c,i}^2)$, 其中 $\mu_{c,i}$ 和 $\sigma_{c,i}^2$ 分别是第 c 类样品在第 i 个属性上取值的样本均值和样本方差,

$$f(x_i|c) = \frac{1}{\sqrt{2\pi}\sigma_{c,i}} \exp\left(-\frac{(x_i - \mu_{c,i})^2}{2\sigma_{c,i}^2}\right).$$

色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.657	0.430	?

朴素贝叶斯分类器

色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.657	0.430	?

$$f(\text{含糖率} = 0.430 | \text{好瓜} = \text{是}) = \frac{1}{\sqrt{2\pi} \cdot 0.101} \exp\left(-\frac{(0.430 - 0.279)^2}{2 \cdot 0.101^2}\right) = 1.292$$

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

朴素贝叶斯分类器

色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.657	0.430	?

$$f(\text{含糖率} = 0.430 | \text{好瓜} = \text{否}) = \frac{1}{\sqrt{2\pi} \cdot 0.108} \exp\left(-\frac{(0.430 - 0.154)^2}{2 \cdot 0.108^2}\right) = 0.141$$

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

拉普拉斯修正

- 若某个属性值在训练集中没有与某个类同时出现过，则直接计算会出现问题。比如“敲声=清脆”测试例，训练集中好瓜类中没有该样例，因此连乘式计算的概率值为0，无论其他属性上明显像好瓜，分类结果都是“好瓜=否”，这显然不合理。

拉普拉斯修正

- 若某个属性值在训练集中没有与某个类同时出现过，则直接计算会出现问题。比如“敲声=清脆”测试例，训练集中好瓜类中没有该样例，因此连乘式计算的概率值为0，无论其他属性上明显像好瓜，分类结果都是“好瓜=否”，这显然不合理。
- 为了避免其他属性携带的信息被训练集中未出现的属性值“抹去”，在估计概率值时通常要进行“拉普拉斯修正”
 - 令 N 表示训练集 D 中可能的类别数， N_i 表示第 i 个属性可能的取值数，则式 (7.16)和 (7.17)分别修正为

$$\hat{P}(c) = \frac{|D_c| + 1}{|D| + N} \quad (7.19)$$

$$\hat{P}(x_i | c) = \frac{|D_{c,x_i}| + 1}{|D_c| + N_i} \quad (7.20)$$

拉普拉斯修正

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

$$\hat{P}(\text{好瓜} = \text{是}) = \frac{8 + 1}{17 + 2} \approx 0.474, \quad \hat{P}(\text{好瓜} = \text{否}) = \frac{9 + 1}{17 + 2} \approx 0.526.$$

$$\hat{P}_{\text{青绿}|\text{是}} = \hat{P}(\text{色泽} = \text{青绿} | \text{好瓜} = \text{是}) = \frac{3 + 1}{8 + 3} \approx 0.364,$$

$$\hat{P}_{\text{青绿}|\text{否}} = \hat{P}(\text{色泽} = \text{青绿} | \text{好瓜} = \text{否}) = \frac{3 + 1}{9 + 3} \approx 0.333.$$

$$\hat{P}_{\text{清脆}|\text{是}} = \hat{P}(\text{敲声} = \text{清脆} | \text{好瓜} = \text{是}) = \frac{0 + 1}{8 + 3} \approx 0.091.$$

拉普拉斯修正

- 拉普拉斯修正避免了因训练样本不充分而导致概率估值为零的问题，同时保证了每个值都在0到1的范围，又保证了最终和为1的概率性质。当训练集变大时，修正过程所引入的先验的影响也会逐渐变得可忽略，使得估值渐趋向于实际概率值。
- 现实任务中，朴素贝叶斯分类器的使用有多种方式。例如，若任务对预测速度要求高，则对给定训练集，可将朴素贝叶斯分类器涉及的所有概率估值事先计算好存储起来，在预测时只需“查表”即可进行判断；若任务数据更替频繁，则可采用“懒惰学习”(lazy learning)方式，先不进行任何训练，待收到预测请求时再根据当前数据集进行概率估值。

章节目录

□ 贝叶斯决策论

□ 极大似然估计

□ 朴素贝叶斯分类器

□ 半朴素贝叶斯分类器

半朴素贝叶斯分类器

- ❑ 为了降低贝叶斯公式中估计后验概率的困难，朴素贝叶斯分类器采用的属性条件独立性假设，但在现实任务中这个假设往往很难成立。于是，对属性条件独立假设记性一定程度的放松，由此产生了一类称为“半朴素贝叶斯分类器”。
- ❑ 半朴素贝叶斯分类器的基本想法是适当考虑一部分属性间的相互依赖信息，从而既不需进行完全联合概率计算，又不至于彻底忽略了比较强的属性依赖关系。

半朴素贝叶斯分类器

- 半朴素贝叶斯分类器最常用的一种策略：“独依赖估计” (One-Dependent Estimator, ODE)，假设每个属性在类别之外最多仅依赖一个其他属性，即

$$P(c | x) \propto P(c) \prod_{i=1}^d P(x_i | c, pa_i)$$

- 其中 pa_i 为属性 x_i 所依赖的属性，称为 x_i 的父属性
- 对每个属性 x_i ，若其父属性 pa_i 已知，则可同样采用朴素贝叶斯分类器中估计类条件概率的方法来估计概率值 $P(x_i | c, pa_i)$ ，于是问题的关键转化为如何确定每个属性的父属性，不同的做法产生不同的独依赖分类器。

半朴素贝叶斯分类器

#	大小	颜色	形状	标签
1	小	青色	非规则	否
2	大	红色	非规则	是
3	大	红色	圆形	是
4	大	青色	圆形	否
5	大	青色	非规则	否
6	小	红色	圆形	是
7	大	青色	非规则	否
8	小	红色	非规则	否
9	小	青色	圆形	否
10	大	红色	圆形	是

待预测的样本见下：

#	大小	颜色	形状	标签
11	大	青色	圆形	?

半朴素贝叶斯分类器

采用拉普拉斯修正后的先验概率 $P(c)$ 的计算公式:

$$\hat{P}(c) = \frac{|D_c| + 1}{|D| + N}$$

基于类 c 和类外的依赖属性 pa_i 的条件概率计算公式如下:

$$\hat{P}(x_i | c, pa_i) = \frac{|D_{c,pa_i,x_i}| + 1}{|D_{c,pa_i}| + N_i}$$

属性的依赖关系定义如下:

- 大小的依赖属性为: 形状, 且属性取值为大时依赖形状为圆形;
- 颜色不存在依赖属性;
- 形状的依赖属性为大小, 且属性取值为圆形时依赖大小为大;

半朴素贝叶斯分类器

#	大小	颜色	形状	标签
1	小	青色	非规则	否
2	大	红色	非规则	是
3	大	红色	圆形	是
4	大	青色	圆形	否
5	大	青色	非规则	否
6	小	红色	圆形	是
7	大	青色	非规则	否
8	小	红色	非规则	否
9	小	青色	圆形	否
10	大	红色	圆形	是

则先验概率 $P(c)$,

$$P(c = \text{好果}) = (4+1) / (10+2) = 5/12$$

$$P(c = \text{一般}) = (6+1) / (10+2) = 7/12$$

半朴素贝叶斯分类器

#	大小	颜色	形状	标签
1	小	青色	非规则	否
2	大	红色	非规则	是
3	大	红色	圆形	是
4	大	青色	圆形	否
5	大	青色	非规则	否
6	小	红色	圆形	是
7	大	青色	非规则	否
8	小	红色	非规则	否
9	小	青色	圆形	否
10	大	红色	圆形	是

带有依赖属性的类条件概率：

$P(\text{大小=大} \mid \text{c=好果}, \text{形状=圆形}) = (2+1)/(3+2) = 3/5$

$P(\text{颜色=青色} \mid \text{c=好果}) = (0+1)/(4+2) = 1/6$

$P(\text{形状=圆形} \mid \text{c=好果}, \text{大小=大}) = (2+1)/(3+2) = 3/5$

$P(\text{大小=大} \mid \text{c=一般}, \text{形状=圆形}) = (1+1)/(2+2) = 2/4$

$P(\text{颜色=青色} \mid \text{c=一般}) = (5+1)/(6+2) = 6/8$

$P(\text{形状=圆形} \mid \text{c=一般}, \text{大小=大}) = (1+1)/(3+2) = 2/5$

半朴素贝叶斯分类器

#	大小	颜色	形状	标签
1	小	青色	非规则	否
2	大	红色	非规则	是
3	大	红色	圆形	是
$P(c=\text{好果}) * P(\text{大小}=\text{大} c=\text{好果}, \text{形状}=\text{圆形}) * P(\text{颜色}=\text{青色} c=\text{好果}) * P(\text{形状}=\text{圆形} c=\text{好果}, \text{大小}=\text{大})$ $= 5/12 * 3/5 * 1/6 * 3/5$ $= 0.025$				
7	大	青色	非规则	否
8	小	红色	非规则	否
$P(c=\text{一般}) * P(\text{大小}=\text{大} c=\text{一般}, \text{形状}=\text{圆形}) * P(\text{颜色}=\text{红色} c=\text{一般}) * P(\text{形状}=\text{圆形} c=\text{一般}, \text{大小}=\text{大})$ $= 7/12 * 2/4 * 6/8 * 2/5$ $= 0.0875$				

待预测的样本见下:

#	大小	颜色	形状	标签
11	大	青色	圆形	?

SPODE

□ 最直接的做法是假设所有属性都依赖于同一属性，称为“超父” (super-parent)，然后通过交叉验证等模型选择方法来确定超父属性，由此形成了SPODE (Super-Parent ODE)方法。




图7.1 朴素贝叶斯分类器与两种半朴素分类器所考虑的属性依赖关系

□ 在图7.1 (b)中， x_1 是超父属性。

SPODE

将属性 x_i 作为超父属性

$$\begin{aligned} P(c|x) &= \frac{P(x, c)}{P(x)} \\ &= \frac{P(c, x_i) P(x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_d \mid c, x_i)}{P(x)} \end{aligned}$$

$$\propto P(c, x_i) P(x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_d \mid c, x_i)$$

$$= P(c, x_i) \prod_{j=1}^d P(x_j | c, x_i)$$

采用属性条件独立性假设

TAN

□ TAN (Tree augmented Naïve Bayes) [Friedman et al., 1997] 则在最大带权生成树 (Maximum weighted spanning tree) 算法 [Chow and Liu, 1968] 的基础上, 通过以下步骤将属性间依赖关系简约为图7.1 (c)。

- 计算任意两个属性之间的条件互信息

$$I(x_i, x_j | y) = \sum_{x_i, x_j; c \in y} P(x_i, x_j | c) \log \frac{P(x_i, x_j | c)}{P(x_i | c)P(x_j | c)}$$

- 以属性为结点构建完全图, 任意两个结点之间边的权重设为 $I(x_i, x_j | y)$
- 构建此完全图的最大带权生成树, 挑选根变量, 将边设为有向;
- 加入类别节点 y , 增加从 y 到每个属性的有向边。

AODE

□ AODE (Averaged One-Dependent Estimator) [Webb et al. 2005] 是一种基于集成学习机制、更为强大的分类器。

- 尝试将每个属性作为超父构建 SPODE
- 将具有足够训练数据支撑的SPODE集成起来作为最终结果

$$P(c \mid \mathbf{x}) \propto \sum_{i=1; |D_{x_i}| \geq m'}^d P(c, x_i) \prod_{j=1}^d P(x_j \mid c, x_i)$$

其中, D_{x_i} 是在第 i 个属性上取值 x_i 的样本的集合, m' 为阈值常数

$$\hat{P}(c, x_i) = \frac{|D_{c, x_i}| + 1}{|D| + N \times N_i} \quad \hat{P}(x_j \mid c, x_i) = \frac{|D_{c, x_i, x_j}| + 1}{|D_{c, x_i}| + N_j}$$

其中, N 是 D 中可能的类别数, N_i 是在第 i 个属性的取值数, D_{c, x_i} 是类别为 c 且在第 i 个属性上取值为 x_i 的样本集合。

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

$$\hat{P}(c, x_i) = \frac{|D_{c, x_i}| + 1}{|D| + N \times N_i}$$

$$\hat{P}(x_j \mid c, x_i) = \frac{|D_{c, x_i, x_j}| + 1}{|D_{c, x_i}| + N_j}$$

$$\hat{P}_{\text{是, 浊响}} = \hat{P}(\text{好瓜} = \text{是}, \text{敲声} = \text{浊响}) = \frac{6 + 1}{17 + 3 \times 2} = 0.304$$

$$\hat{P}_{\text{凹陷}|\text{是, 浊响}} = \hat{P}(\text{脐部} = \text{凹陷} \mid \text{好瓜} = \text{是}, \text{敲声} = \text{浊响}) = \frac{3 + 1}{6 + 3} = 0.444 .$$

小结

□ 贝叶斯决策论

□ 极大似然估计

□ 朴素贝叶斯分类器

□ 半朴素贝叶斯分类器