

机器学习

Machine Learning

肖力

信息科学技术学院—6系

<https://faculty.ustc.edu.cn/xiaoli>

第8章：集成学习

集成学习


- 个体与集成
- Boosting
 - Adaboost
- Bagging与随机森林
- 结合策略
 - 平均法
 - 投票法
 - 学习法
- 多样性
 - 误差-分歧分解
 - 多样性度量
 - 多样性扰动

集成学习

- 个体与集成
- Boosting
 - Adaboost
- Bagging与随机森林
- 结合策略
 - 平均法
 - 投票法
 - 学习法
- 多样性
 - 误差-分歧分解
 - 多样性度量
 - 多样性扰动


个体与集成

- 集成学习(ensemble learning)通过构建并结合多个学习器来完成学习任务



个体与集成

- 集成学习(ensemble learning)通过构建并结合多个学习器来完成学习任务



- 同质集成：个体学习器类型相同；个体学习器称为基学习器
- 异质集成：个体学习器类型不同；个体学习器称为组件学习器

个体与集成

- 一般经验，如果把好坏不等的东西掺在一起，那么通常结果会是比最坏的要好一些，比最好的要坏一些。集成学习把多个学习器结合起来，目的是可获得比单一学习器更好的泛化性能，那怎么做呢？

个体与集成

- 一般经验，如果把好坏不等的东西掺在一起，那么通常结果会是比最坏的要好一些，比最好的要坏一些。集成学习把多个学习器结合起来，目的是可获得比单一学习器更好的泛化性能，那怎么做呢？
- 考虑一个简单的例子，在二分类问题中，假定三个分类器在三个测试样本上的表现如下图所示，其中√表示分类正确，×表示分类错误，集成的结果通过投票法产生（少数服从多数）。

	测试例1	测试例2	测试例3
h_1	√	√	×
h_2	×	√	√
h_3	√	×	√
集成	√	√	√

(a) 集成提升性能

	测试例1	测试例2	测试例3
h_1	√	√	×
h_2	√	√	×
h_3	√	√	×
集成	√	√	×

(b) 集成不起作用

	测试例1	测试例2	测试例3
h_1	√	×	×
h_2	×	√	×
h_3	×	×	√
集成	×	×	×

(c) 集成起负作用

- 结论：要获得好的集成，个体学习器应“好而不同”，即个体学习器要有一定的“准确性”，并且要有“多样性”。

个体与集成 - 简单分析

- 考虑二分类问题 $y \in \{-1, +1\}$ 和真实函数 $y = f(\mathbf{x})$.
- 设有 T 个基分类器 $h_1, h_2, \dots, h_T$. 假设它们相互独立且错误率均为:

$$P(h_i(\mathbf{x}) \neq f(\mathbf{x})) = \epsilon, i = 1, 2, \dots, T.$$

- 假设集成通过简单投票法结合 T 个分类器, 若有超过半数的基分类器正确, 则分类就正确

$$F(\mathbf{x}) = \text{sign} \left(\sum_{i=1}^T h_i(\mathbf{x}) \right)$$

个体与集成 - 简单分析

- 考虑二分类问题 $y \in \{-1, +1\}$ 和真实函数 $y = f(\mathbf{x})$.
- 设有 T 个基分类器 $h_1, h_2, \dots, h_T$. 假设它们相互独立且错误率均为:

$$P(h_i(\mathbf{x}) \neq f(\mathbf{x})) = \epsilon, i = 1, 2, \dots, T.$$

- 假设集成通过简单投票法结合 T 个分类器, 若有超过半数的基分类器正确, 则分类就正确

$$F(\mathbf{x}) = \text{sign}\left(\sum_{i=1}^T h_i(\mathbf{x})\right)$$

- 由Hoeffding不等式可得集成的错误率为:

$$\begin{aligned} P(F(\mathbf{x}) \neq f(\mathbf{x})) &= \sum_{k=0}^{\lfloor T/2 \rfloor} \binom{T}{k} (1-\epsilon)^k \epsilon^{T-k} \\ &\leq \exp\left(-\frac{1}{2}T(1-2\epsilon)^2\right) \end{aligned}$$

个体与集成 - 简单分析

由基分类器相互独立，假设随机变量 X 为 T 个基分类器分类正确的次数，因此随机变量 X 服从二项分布： $X \sim \mathcal{B}(T, 1 - \epsilon)$ ，设 x_i 为每一个分类器分类正确的次数，则 $x_i \sim \mathcal{B}(1, 1 - \epsilon) \ i = 1\ 2\ 3 \dots T$ ，那么有

$$X = \sum_{i=1}^T x_i \quad \mathbb{E}(X) = \sum_{i=1}^T \mathbb{E}(x_i) = (1 - \epsilon)T$$

个体与集成 - 简单分析

由基分类器相互独立, 假设随机变量 X 为 T 个基分类器分类正确的次数, 因此随机变量 X 服从二项分布: $X \sim \mathcal{B}(T, 1 - \epsilon)$, 设 x_i 为每一个分类器分类正确的次数, 则 $x_i \sim \mathcal{B}(1, 1 - \epsilon) \ i = 1 \ 2 \ 3 \ \dots \ T$, 那么有

$$X = \sum_{i=1}^T x_i \quad \mathbb{E}(X) = \sum_{i=1}^T \mathbb{E}(x_i) = (1 - \epsilon)T$$

$$P(H(x) \neq f(x)) = P(X \leq \lfloor T/2 \rfloor) \leq P(X \leq T/2)$$

$$= P \left[X - (1 - \epsilon)T \leq \frac{T}{2} - (1 - \epsilon)T \right]$$

$$= P \left[X - (1 - \epsilon)T \leq -\frac{T}{2} (1 - 2\epsilon) \right]$$

$$= P \left[\sum_{i=1}^T x_i - \sum_{i=1}^T \mathbb{E}(x_i) \leq -\frac{T}{2} (1 - 2\epsilon) \right]$$

$$= P \left[\frac{1}{T} \sum_{i=1}^T x_i - \frac{1}{T} \sum_{i=1}^T \mathbb{E}(x_i) \leq -\frac{1}{2} (1 - 2\epsilon) \right]$$

个体与集成 - 简单分析

根据 Hoeffding 不等式知

$$P\left(\frac{1}{m}\sum_{i=1}^m x_i - \frac{1}{m}\sum_{i=1}^m \mathbb{E}(x_i) \leq -\delta\right) \leq \exp(-2m\delta^2)$$

令 $\delta = \frac{(1-2\epsilon)}{2}$, $m = T$ 得

$$\begin{aligned} P(H(x) \neq f(x)) &= \sum_{k=0}^{\lfloor T/2 \rfloor} \binom{T}{k} (1-\epsilon)^k \epsilon^{T-k} \\ &\leq \exp\left(-\frac{1}{2}T(1-2\epsilon)^2\right) \end{aligned}$$

个体与集成 - 简单分析

$$P(F(\mathbf{x}) \neq f(\mathbf{x})) = \sum_{k=0}^{\lfloor T/2 \rfloor} \binom{T}{k} (1-\epsilon)^k \epsilon^{T-k} \\ \leq \exp\left(-\frac{1}{2}T(1-2\epsilon)^2\right)$$

- 上式显示，在一定条件下，随着集成分类器数目的增加，集成的错误率将指数级下降，最终趋向于0

$T \backslash \epsilon$	0.45	0.40	0.35	0.20
5	0.4069	0.3174	0.2352	0.0579
51	0.2359	0.0735	0.0138	8.13×10^{-7}
101	0.1562	0.0209	9.87×10^{-4}	8.42×10^{-12}
201	0.0774	0.0021	6.52×10^{-6}	1.23×10^{-21}
501	0.0124	3.03×10^{-6}	3.05×10^{-12}	6.64×10^{-51}

个体与集成 - 简单分析

- 上面的分析有一个关键假设：基学习器的误差相互独立
- 在现实任务中，个体学习器是为解决同一个问题训练出来的，它们显然不可能互相独立
- 事实上，个体学习器的“准确性”和“多样性”本身就存在冲突
- 如何产生“好而不同”的个体学习器是集成学习研究的核心
- 根据个体学习器的生成方式，集成学习方法大致可分为两大类：
 - 个体学习器间存在强依赖关系、必须串行生成的序列化方法；如，**Boosting**
 - 个体学习器间不存在强依赖关系、可同时生成的并行化方法；如，**Bagging**和随机森林

集成学习


- 个体与集成
- Boosting
 - Adaboost
- Bagging与随机森林
- 结合策略
 - 平均法
 - 投票法
 - 学习法
- 多样性
 - 误差-分歧分解
 - 多样性度量
 - 多样性扰动

Boosting

- **弱学习器**: 预测结果比随机猜测略好的学习模型
- **强学习器**: 预测结果明显比随机猜测好的学习模型
- Boosting是一族可将弱学习器提升为强学习器的算法.
- 这族算法的工作机制类似:
 - 先从初始训练集 D 训练出一个基学习器;
 - 再根据基学习器的表现对训练样品分布进行调整, 使得先前基学习器做错的训练样品在后续受到更多关注, 然后基于调整后的样品分布来训练下一个基学习器;
 - 如此重复进行, 直至基学习器数目达到事先指定的值 T , 最终将这 T 个基学习器进行加权结合.

Boosting

- 串行逐个增加个体学习器，逐步提升集成学习系统的性能



Boosting - AdaBoost算法

□ Boosting族算法最著名的代表是AdaBoost

输入: 训练集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$;
基学习算法 $\mathcal{L}$;
训练轮数 T .

过程:

```
1:  $\mathcal{D}_1(\mathbf{x}) = 1/m$ .  
2: for  $t = 1, 2, \dots, T$  do  
3:    $h_t = \mathcal{L}(D, \mathcal{D}_t)$ ;  
4:    $\epsilon_t = P_{\mathbf{x} \sim \mathcal{D}_t}(h_t(\mathbf{x}) \neq f(\mathbf{x}))$ ;  
5:   if  $\epsilon_t > 0.5$  then break  
6:    $\alpha_t = \frac{1}{2} \ln \left( \frac{1-\epsilon_t}{\epsilon_t} \right)$ ;  
7:    $\mathcal{D}_{t+1}(\mathbf{x}) = \frac{\mathcal{D}_t(\mathbf{x})}{Z_t} \times \begin{cases} \exp(-\alpha_t), & \text{if } h_t(\mathbf{x}) = f(\mathbf{x}) \\ \exp(\alpha_t), & \text{if } h_t(\mathbf{x}) \neq f(\mathbf{x}) \end{cases}$   
    $= \frac{\mathcal{D}_t(\mathbf{x}) \exp(-\alpha_t f(\mathbf{x}) h_t(\mathbf{x}))}{Z_t}$   
8: end for  
输出:  $H(\mathbf{x}) = \text{sign} \left( \sum_{t=1}^T \alpha_t h_t(\mathbf{x}) \right)$ 
```

$$E(X) = \sum_{k=1}^{\infty} x_k p_k$$

$\mathcal{D}_t$ P

$$Z_t = \mathbb{E}_{\mathbf{x} \sim \mathcal{D}_t} [e^{-f(\mathbf{x}) \alpha_t h_t(\mathbf{x})}]$$

1. 初始化样本权重分布 (m 样本个数)
2. 循环直到到达规定的训练轮数 T (无误)
3. 基于分布 $\mathcal{D}_t$ 从数据集 D 中训练出分类器 h_t
4. 估计 h_t 的误差
5. 误差要小于 0.5 才有意义
6. 确定分类器 h_t 的权重, 最小化误差
7. 更新样本分布, 其中 Z_t 是规范化因子, 以确保 $\mathcal{D}_{t+1}$ 是一个分布, 保证每次权值总和为 1
8. 得到集成学习器


AdaBoost推导——损失函数

- Adaboost采用面向二分类问题的加法模型假设

- 给定训练集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$. 考虑二分类问题 $y \in \{-1, +1\}$ 和真实函数 $y = f(x)$.

- 求某种最优分类器 $\text{sign}(H(x))$, 其中: $H(x) = \sum_{t=1}^T \alpha_t h_t(x)$.

- 设 x 的分布为 D , 若定义指数损失函数为: $\ell_{\text{exp}}(H|D) = E_{x \sim D}(e^{-f(x)H(x)})$.



AdaBoost推导——损失函数

▪ 欲求 $\min_H \ell_{\text{exp}}(H|\mathcal{D})$

$$\begin{aligned}\ell_{\text{exp}}(H|\mathcal{D}) &= \mathbb{E}_{\mathbf{x} \sim \mathcal{D}} [e^{-f(\mathbf{x})H(\mathbf{x})}] \\&= \sum_{\mathbf{x} \in \mathcal{D}} \mathcal{D}(\mathbf{x}) e^{-f(\mathbf{x})H(\mathbf{x})} \\&= \sum_{i=1}^{|\mathcal{D}|} \mathcal{D}(\mathbf{x}_i) (e^{-H(\mathbf{x}_i)} \mathbb{I}(f(\mathbf{x}_i) = 1) + e^{H(\mathbf{x}_i)} \mathbb{I}(f(\mathbf{x}_i) = -1)) \\&= \sum_{i=1}^{|\mathcal{D}|} (e^{-H(\mathbf{x}_i)} \mathcal{D}(\mathbf{x}_i) \mathbb{I}(f(\mathbf{x}_i) = 1) + e^{H(\mathbf{x}_i)} \mathcal{D}(\mathbf{x}_i) \mathbb{I}(f(\mathbf{x}_i) = -1)) \\&= \sum_{i=1}^{|\mathcal{D}|} (e^{-H(\mathbf{x}_i)} P(f(\mathbf{x}_i) = 1 | \mathbf{x}_i) + e^{H(\mathbf{x}_i)} P(f(\mathbf{x}_i) = -1 | \mathbf{x}_i))\end{aligned}$$

AdaBoost推导——损失函数

当对 $H(x_i)$ 求导时，求和号中只有含 x_i 项不为 0，由求导公式

$$\frac{\partial e^{-H(\mathbf{x})}}{\partial H(\mathbf{x})} = -e^{-H(\mathbf{x})} \quad \frac{\partial e^{H(\mathbf{x})}}{\partial H(\mathbf{x})} = e^{H(\mathbf{x})}$$

- 目标函数求偏导, 有

$$\frac{\partial \ell_{\text{exp}}(H|\mathcal{D})}{\partial H(\mathbf{x})} = -e^{-H(\mathbf{x})} P(f(\mathbf{x}) = 1|\mathbf{x}) + e^{H(\mathbf{x})} P(f(\mathbf{x}) = -1|\mathbf{x})$$

- 令上式为0, 解得

$$H(\mathbf{x}) = \frac{1}{2} \ln \left(\frac{P(f(\mathbf{x}) = 1|\mathbf{x})}{P(f(\mathbf{x}) = -1|\mathbf{x})} \right)$$

AdaBoost推导——损失函数

- 通过最小化 ℓ_{exp} 得到

$$H(\mathbf{x}) = \frac{1}{2} \ln \left(\frac{P(f(\mathbf{x}) = 1|\mathbf{x})}{P(f(\mathbf{x}) = -1|\mathbf{x})} \right)$$

- 分类结果:

$$\begin{aligned} \text{sign}(H(\mathbf{x})) &= \text{sign} \left\{ \frac{1}{2} \ln \left(\frac{P(f(\mathbf{x}) = 1|\mathbf{x})}{P(f(\mathbf{x}) = -1|\mathbf{x})} \right) \right\} \\ &= \begin{cases} 1, & P(f(\mathbf{x}) = 1|\mathbf{x}) > P(f(\mathbf{x}) = -1|\mathbf{x}) \\ -1, & P(f(\mathbf{x}) = -1|\mathbf{x}) > P(f(\mathbf{x}) = 1|\mathbf{x}) \end{cases} \\ &= \arg \max_{y \in \{-1, 1\}} P(f(\mathbf{x}) = y|\mathbf{x}) \end{aligned}$$

最大后验概率分类准则

- 则通过最小化 ℓ_{exp} 得到的分类器 $\text{sign}(H(\mathbf{x}))$ 能够最小化分类错误率.

AdaBoost推导—— h_t

前向分步优化：逐个增加个体学习器，分解简化优化问题

- 假设现在已经进行完成了前 $t - 1$ 轮, 此时 $H_{t-1}(x) = \sum_{k=1}^{t-1} \alpha_k h_k(x)$.
在第 t 轮结束以后, $H_t(x) = H_{t-1}(x) + \alpha_t h_t(x)$,
- 在第 t 轮中, 我们将训练基学习器 h_t , 计算 α_t 和分布 D_{t+1} .

第 t 轮迭代应该求解如下优化问题从而得到 α_t 和 $h_t(x)$:

$$(\alpha_t, h_t(x)) = \arg \min_{\alpha, h} \ell_{\text{exp}} (H_{t-1} + \alpha h \mid \mathcal{D})$$

对于该问题, 先对于固定的任意 $\alpha > 0$, 求解 $h_t(x)$; 得到 $h_t(x)$ 后再求 α_t

AdaBoost推导—— h_t

前向分步优化：逐个增加个体学习器，分解简化优化问题

- 假设现在已经进行完成了前 $t - 1$ 轮, 此时 $H_{t-1}(x) = \sum_{k=1}^{t-1} \alpha_k h_k(x)$.
在第 t 轮结束以后, $H_t(x) = H_{t-1}(x) + \alpha_t h_t(x)$,
- 在第 t 轮中, 我们将训练基学习器 h_t , 计算 α_t 和分布 D_{t+1} .

第 t 轮迭代应该求解如下优化问题从而得到 α_t 和 $h_t(x)$:

$$(\alpha_t, h_t(x)) = \arg \min_{\alpha, h} \ell_{\exp} (H_{t-1} + \alpha h \mid \mathcal{D})$$

对于该问题, 先对于固定的任意 $\alpha > 0$, 求解 $h_t(x)$; 得到 $h_t(x)$ 后再求 α_t

- h_t 应使 $H_{t-1}(x) + \alpha h_t(x)$ 的指数损失函数达到最小:

$$h_t = \arg \min_h \ell_{\exp} (H_{t-1}(x) + \alpha h(x) \mid \mathcal{D}). \quad \alpha_t \text{暂时未知, 用常数 } c > 0 \text{ 替代}$$

AdaBoost推导—— h_t

▪ 损失:

$$\begin{aligned}\ell_{\text{exp}}(H_{t-1}(\mathbf{x}) + ch(\mathbf{x})|\mathcal{D}) &= E_{\mathbf{x} \sim \mathcal{D}}(e^{-f(\mathbf{x})(H_{t-1}(\mathbf{x}) + ch(\mathbf{x}))}) \\ &= E_{\mathbf{x} \sim \mathcal{D}}(e^{-f(\mathbf{x})H_{t-1}(\mathbf{x})} e^{-cf(\mathbf{x})h(\mathbf{x})}) \\ &\approx E_{\mathbf{x} \sim \mathcal{D}}\left(e^{-f(\mathbf{x})H_{t-1}(\mathbf{x})} \left(1 - cf(\mathbf{x})h(\mathbf{x}) + c^2/2\right)\right)\end{aligned}$$

▪ 于是:

$$\begin{aligned}h_t &= \arg \min_h \ell_{\text{exp}}(H_{t-1}(\mathbf{x}) + ch(\mathbf{x})|\mathcal{D}) \\ &= \arg \min_h E_{\mathbf{x} \sim \mathcal{D}}\left(e^{-f(\mathbf{x})H_{t-1}(\mathbf{x})} \left(1 - cf(\mathbf{x})h(\mathbf{x}) + c^2/2\right)\right) \\ &= \arg \max_h E_{\mathbf{x} \sim \mathcal{D}}\left(e^{-f(\mathbf{x})H_{t-1}(\mathbf{x})} f(\mathbf{x})h(\mathbf{x})\right)\end{aligned}$$

AdaBoost推导—— h_t

- 进一步化简:
$$\begin{aligned} h_t &= \arg \max_h E_{x \sim \mathcal{D}} \left(e^{-f(x)H_{t-1}(x)} f(x)h(x) \right) \\ &= \arg \max_h E_{x \sim \mathcal{D}} \left(\frac{e^{-f(x)H_{t-1}(x)}}{E_{x \sim \mathcal{D}}(e^{-f(x)H_{t-1}(x)})} f(x)h(x) \right) \\ &= \arg \max_h E_{x \sim \mathcal{D}_t} (f(x)h(x)), \end{aligned}$$

其中 $\mathcal{D}_t(x) = \frac{e^{-f(x)H_{t-1}(x)}}{E_{x \sim \mathcal{D}}(e^{-f(x)H_{t-1}(x)})} \mathcal{D}(x)$ 为权重(分布).

- 由于 $f(x)h(x) = 1 - 2 \times \mathbb{I}(f(x) \neq h(x))$, 由 $f(x), h(x) \in \{-1, +1\}$
$$\begin{aligned} h_t &= \arg \max_h E_{x \sim \mathcal{D}_t} (f(x)h(x)) \\ &= \arg \max_h E_{x \sim \mathcal{D}_t} (1 - 2 \times \mathbb{I}(f(x) \neq h(x))) \end{aligned}$$

AdaBoost推导—— h_t

- 进一步化简:
$$\begin{aligned} h_t &= \arg \max_h E_{x \sim \mathcal{D}} \left(e^{-f(x)H_{t-1}(x)} f(x)h(x) \right) \\ &= \arg \max_h E_{x \sim \mathcal{D}} \left(\frac{e^{-f(x)H_{t-1}(x)}}{E_{x \sim \mathcal{D}}(e^{-f(x)H_{t-1}(x)})} f(x)h(x) \right) \\ &= \arg \max_h E_{x \sim \mathcal{D}_t} (f(x)h(x)), \end{aligned}$$

其中 $\mathcal{D}_t(x) = \frac{e^{-f(x)H_{t-1}(x)}}{E_{x \sim \mathcal{D}}(e^{-f(x)H_{t-1}(x)})} \mathcal{D}(x)$ 为权重(分布).

- 由于 $f(x)h(x) = 1 - 2 \times \mathbb{I}(f(x) \neq h(x))$,
$$\begin{aligned} h_t &= \arg \max_h E_{x \sim \mathcal{D}_t} (f(x)h(x)) \\ &= \arg \min_h E_{x \sim \mathcal{D}_t} \left(\mathbb{I}(f(x) \neq h(x)) \right) \end{aligned}$$

AdaBoost推导—— h_t

$$\begin{aligned} \blacksquare \text{进一步化简: } h_t &= \arg \max_h E_{x \sim \mathcal{D}} \left(e^{-f(x)H_{t-1}(x)} f(x)h(x) \right) \\ &= \arg \max_h E_{x \sim \mathcal{D}} \left(\frac{e^{-f(x)H_{t-1}(x)}}{E_{x \sim \mathcal{D}}(e^{-f(x)H_{t-1}(x)})} f(x)h(x) \right) \\ &= \arg \max_h E_{x \sim \mathcal{D}_t} (f(x)h(x)), \end{aligned}$$

其中 $\mathcal{D}_t(x) = \frac{e^{-f(x)H_{t-1}(x)}}{E_{x \sim \mathcal{D}}(e^{-f(x)H_{t-1}(x)})} \mathcal{D}(x)$ 为权重(分布).

$$\blacksquare \text{由于 } f(x)h(x) = 1 - 2 \times \mathbb{I}(f(x) \neq h(x)),$$

$$\begin{aligned} h_t &= \arg \max_h E_{x \sim \mathcal{D}_t} (f(x)h(x)) \\ &= \arg \min_h P_{x \sim \mathcal{D}_t} (f(x) \neq h(x)) = \mathfrak{L}(D, \mathcal{D}_t) \end{aligned}$$

$\mathcal{D}_t$ 分布下 $h_t(x)$ 的错误分类概率

AdaBoost推导—— α_t

□ 当基分类器 h_t 基于分布 D_t 产生后，该基分类器的权重 α_t 应使得 $\alpha_t h_t$ 最小化指数损失函数

▪ 记 $\epsilon_t = P_{x \sim D_t}(f(x) \neq h_t(x))$.

▪ 优化形式:
$$\begin{aligned}\alpha_t &= \arg \min_{\alpha} \ell_{\text{exp}}(H_{t-1}(x) + \alpha h_t(x) | \mathcal{D}) \\ &= \arg \min_{\alpha} E_{x \sim \mathcal{D}} \left(e^{-f(x)H_{t-1}(x)} e^{-\alpha f(x)h_t(x)} \right) \\ &= \arg \min_{\alpha} E_{x \sim D_t} \left(e^{-\alpha f(x)h_t(x)} \right)\end{aligned}$$

$$\begin{aligned}& \mathbb{E}_{x \sim D_t} [e^{-f(x)\alpha_t h_t(x)}] \\ &= \mathbb{E}_{x \sim D_t} [e^{-\alpha_t} \mathbb{I}(f(x) = h_t(x)) + e^{\alpha_t} \mathbb{I}(f(x) \neq h_t(x))] \\ &= e^{-\alpha_t} P_{x \sim D_t}(f(x) = h_t(x)) + e^{\alpha_t} P_{x \sim D_t}(f(x) \neq h_t(x)) \\ &= e^{-\alpha_t} (1 - \epsilon_t) + e^{\alpha_t} \epsilon_t \quad \text{其中 } \epsilon_t = P_{x \sim D_t}(h_t(x) \neq f(x))\end{aligned}$$

AdaBoost推导—— α_t

□ 当基分类器 h_t 基于分布 D_t 产生后, 该基分类器的权重 α_t 应使得 $\alpha_t h_t$ 最小化指数损失函数

▪ 记 $\epsilon_t = P_{x \sim D_t}(f(x) \neq h_t(x))$.

▪ 优化形式:
$$\begin{aligned}\alpha_t &= \arg \min_{\alpha} \ell_{\text{exp}}(H_{t-1}(x) + \alpha h_t(x) | \mathcal{D}) \\ &= \arg \min_{\alpha} E_{x \sim \mathcal{D}}(\mathbf{e}^{-f(x)H_{t-1}(x)} \mathbf{e}^{-\alpha f(x)h(x)}) \\ &= \arg \min_{\alpha} E_{x \sim D_t}(\mathbf{e}^{-\alpha f(x)h(x)})\end{aligned}$$

▪ 求导,
$$\frac{\partial E_{x \sim D_t}(\mathbf{e}^{-\alpha f(x)h(x)})}{\partial \alpha} = -\mathbf{e}^{-\alpha}(1 - \epsilon_t) + \mathbf{e}^{\alpha}\epsilon_t = 0$$

▪ 可得: $\alpha_t = \frac{1}{2} \ln \frac{1 - \epsilon_t}{\epsilon_t}$ 个体学习器 h_t 的最优加权系数 α_t 取决于 h_t 的错误率 ϵ_t

AdaBoost推导—— D_{t+1}

$$\mathcal{D}_t(\mathbf{x}) = \frac{e^{-f(\mathbf{x})H_{t-1}(\mathbf{x})}}{E_{\mathbf{x} \sim \mathcal{D}}(e^{-f(\mathbf{x})H_{t-1}(\mathbf{x})})} \mathcal{D}(\mathbf{x})$$

▪ 由于 $H_t(\mathbf{x}) = H_{t-1}(\mathbf{x}) + \alpha_t h_t(\mathbf{x})$,

$$\begin{aligned}\mathcal{D}_{t+1}(\mathbf{x}) &= \frac{e^{-f(\mathbf{x})H_t(\mathbf{x})}}{E_{\mathbf{x} \sim \mathcal{D}}(e^{-f(\mathbf{x})H_t(\mathbf{x})})} \mathcal{D}(\mathbf{x}) = \frac{e^{-f(\mathbf{x})(H_{t-1}(\mathbf{x}) + \alpha_t h_t(\mathbf{x}))}}{E_{\mathbf{x} \sim \mathcal{D}}(e^{-f(\mathbf{x})H_t(\mathbf{x})})} \mathcal{D}(\mathbf{x}) \\ &= e^{-f(\mathbf{x})\alpha_t h_t(\mathbf{x})} \frac{e^{-f(\mathbf{x})H_{t-1}(\mathbf{x})} \mathcal{D}(\mathbf{x})}{E_{\mathbf{x} \sim \mathcal{D}}(e^{-f(\mathbf{x})H_t(\mathbf{x})})} \\ &= e^{-f(\mathbf{x})\alpha_t h_t(\mathbf{x})} \mathcal{D}_t(\mathbf{x}) \frac{E_{\mathbf{x} \sim \mathcal{D}}(e^{-f(\mathbf{x})H_{t-1}(\mathbf{x})})}{E_{\mathbf{x} \sim \mathcal{D}}(e^{-f(\mathbf{x})H_t(\mathbf{x})})}\end{aligned}$$

▪ 先让 $\mathcal{D}_{t+1}(\mathbf{x}) = \mathcal{D}_t(\mathbf{x})e^{-f(\mathbf{x})\alpha_t h_t(\mathbf{x})}$, 然后规范化.

AdaBoost推导—— D_{t+1}

$$Z_t = \mathbb{E}_{\mathbf{x} \sim \mathcal{D}_t} [e^{-f(\mathbf{x})\alpha_t h_t(\mathbf{x})}]$$

$$\mathcal{D}_t(\mathbf{x}) = \frac{e^{-f(\mathbf{x})H_{t-1}(\mathbf{x})}}{E_{\mathbf{x} \sim \mathcal{D}}(e^{-f(\mathbf{x})H_{t-1}(\mathbf{x})})} \mathcal{D}(\mathbf{x})$$

▪ 由于 $H_t(\mathbf{x}) = H_{t-1}(\mathbf{x}) + \alpha_t h_t(\mathbf{x})$,

$$\begin{aligned} \mathcal{D}_{t+1}(\mathbf{x}) &= \frac{e^{-f(\mathbf{x})H_t(\mathbf{x})}}{E_{\mathbf{x} \sim \mathcal{D}}(e^{-f(\mathbf{x})H_t(\mathbf{x})})} \mathcal{D}(\mathbf{x}) = \frac{e^{-f(\mathbf{x})(H_{t-1}(\mathbf{x}) + \alpha_t h_t(\mathbf{x}))}}{E_{\mathbf{x} \sim \mathcal{D}}(e^{-f(\mathbf{x})H_t(\mathbf{x})})} \mathcal{D}(\mathbf{x}) \\ &= e^{-f(\mathbf{x})\alpha_t h_t(\mathbf{x})} \frac{e^{-f(\mathbf{x})H_{t-1}(\mathbf{x})} \mathcal{D}(\mathbf{x})}{E_{\mathbf{x} \sim \mathcal{D}}(e^{-f(\mathbf{x})H_t(\mathbf{x})})} \\ &= e^{-f(\mathbf{x})\alpha_t h_t(\mathbf{x})} \mathcal{D}_t(\mathbf{x}) \frac{E_{\mathbf{x} \sim \mathcal{D}}(e^{-f(\mathbf{x})H_{t-1}(\mathbf{x})})}{E_{\mathbf{x} \sim \mathcal{D}}(e^{-f(\mathbf{x})H_t(\mathbf{x})})} \end{aligned}$$

▪ 先让 $\mathcal{D}_{t+1}(\mathbf{x}) = \mathcal{D}_t(\mathbf{x})e^{-f(\mathbf{x})\alpha_t h_t(\mathbf{x})}$, 然后规范化.

AdaBoost小结

► Adaboost的思路

- 思路：个体损失+个体权重+串行训练+样本重赋权
 - 个体损失： $h_t(x)$ 的错误率需小于50%；
 - 个体权重： $h_t(x)$ 的权重 α_t 尽量保证总体性能最优；
 - 串行训练：基于 $H_{t-1}(x)$ 的结果训练 $h_t(x)$
 - 样本重赋权：为不同样本 x_i 分配不同的权重 $D_t(x_i)$

AdaBoost小结

► 核心公式

- 1. 为基学习器 h_t 设计一个学习算法 $\mathcal{L}(h; X, Y, \mathcal{D})$
- 2. 设第一个基学习器 $h_{t=1}(x) = H_{t=1}(x)$
- 3. 对于第 t 次迭代, 基于第 $t-1$ 次迭代时的 $H_{t-1}(x)$ 和 $\mathcal{D}_{t-1}(x)$, 根据递推式计算样本权重 $\mathcal{D}_t(x)$;

$$\mathcal{D}_t(x) = \mathcal{D}_{t-1}(x) e^{-f(x)\alpha_{t-1}h_{t-1}(x)} \frac{\mathbb{E}_{x \sim \mathcal{D}}[e^{-f(x)H_{t-2}(x)}]}{\mathbb{E}_{x \sim \mathcal{D}}[e^{-f(x)H_{t-1}(x)}]}$$

常数, 与 x 无关
不影响分布 $\mathcal{D}_t(x)$

$$\mathcal{D}_t(x_i) = \frac{\mathcal{D}_{t-1}(x_i) \exp(-\alpha_{t-1}y_i h_{t-1}(x_i))}{Z_{t-1}}$$

归一化系数: $Z_{t-1} = \sum_i \mathcal{D}_{t-1}(x_i) \exp(-\alpha_{t-1}y_i h_{t-1}(x_i))$

- 4. 根据 $\mathcal{D}_t(x)$, 学得基学习器 $h_t(x)$, 算出学习器权重 α_t

$$h_t^* = \underset{h_t}{\operatorname{argmin}} \{P_{x \sim \mathcal{D}_t}(h_t(x) \neq f(x))\} = \underset{h_t}{\operatorname{argmin}} \{\epsilon_t\}; \quad \alpha_t^* = \frac{1}{2} \ln \left(\frac{1 - \epsilon_t}{\epsilon_t} \right);$$

AdaBoost小结

▶ 算法流程

输入	训练集: $\{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}, y_i \in \{+1, -1\}$ 基学习器优化算法 $\mathcal{Q}(h; X, Y, \mathcal{D})$ 训练轮数 T
1	样本权重初始化 $\mathcal{D}_1(x) = [\omega_i^{(t)} i = 1, \dots, N; t = 1] = [\frac{1}{N}, \dots, \frac{1}{N}]$
2	for $t = 1, 2, \dots, T$:
3	$h_t = \mathcal{Q}(h; X, Y, \mathcal{D}_t(X))$
4	$\epsilon_t = P_{x \sim \mathcal{D}_t}(h_t(x_i) \neq y_i) = \sum_{i=1}^N \omega_i I(h_t(x_i) \neq y_i)$
5	if $\epsilon_t > 0.5$ then break
6	基分类器权重: $\alpha_t = \frac{1}{2} \ln \left(\frac{1 - \epsilon_t}{\epsilon_t} \right)$
7	更新样本权重: $\mathcal{D}_{t+1}(x) = \frac{\mathcal{D}_t(x) \exp(-\alpha_t y_i h_t(x_i))}{Z_t}$
输出	$H(x) = \text{sign}(\sum_{t=1}^T \alpha_t h_t(x))$

Boosting – AdaBoost例子

例题——利用Adaboost对简单一维数据分类

▶ 已知条件:

- 给定如表所示训练数据

序号	1	2	3	4	5
x	1	2	3	4	5
y	1	-1	-1	1	1

- 假设弱分类器是以 v 为阈值的分类器
- 阈值 v 应使分类器在训练集上的加权分类误差率 ϵ_t 最低。

▶ 求:

- 使用Adaboost算法, 给出集成分类器的学习过程和结果。

Boosting – AdaBoost例子

► 计算流程——步骤1：初始化样本权重

- 给定如表所示训练数据

输入	训练集: $\{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}, y_i \in \{+1, -1\}$ 基学习器优化算法 $\mathcal{Q}(h; X, Y, \mathcal{D})$ 训练轮数 T
1	样本权重初始化 $\mathcal{D}_1(x) = [\omega_i^{(t)} i = 1, \dots, N; t = 1] = [\frac{1}{N}, \dots, \frac{1}{N}]$
2	for $t = 1, 2, \dots, T$:
3	$h_t = \mathcal{Q}(h; X, Y, \mathcal{D}_t(X))$
4	$\epsilon_t = P_{x \sim \mathcal{D}_t}(h_t(x_i) \neq y_i) = \sum_{i=1}^N \omega_i I(h_t(x_i) \neq y_i)$
5	if $\epsilon_t > 0.5$ then break
6	基分类器权重: $\alpha_t = \frac{1}{2} \ln \left(\frac{1-\epsilon_t}{\epsilon_t} \right)$
7	更新样本权重: $\mathcal{D}_{t+1}(x) = \frac{\mathcal{D}_t(x) \exp(-\alpha_t y_i h_t(x_i))}{Z_t}$
输出	$H(x) = \text{sign}(\sum_{t=1}^T \alpha_t h_t(x))$

Boosting – AdaBoost例子

► 步骤1：初始化样本权重

- 首先初始化样本权重：

$$\omega_i = \frac{1}{N} = \frac{1}{5} = 0.2, i = 1, \dots, 5$$

- 训练集的样本初始化权重为：

$$\begin{aligned}\mathcal{D}_1 &= [\omega_1^{(1)}, \omega_2^{(1)}, \omega_3^{(1)}, \omega_4^{(1)}, \omega_5^{(1)}] \\ &= [0.2, 0.2, 0.2, 0.2, 0.2]\end{aligned}$$

Boosting – AdaBoost例子

► 计算流程——步骤3/4: 学习个体分类器/计算误差

输入	训练集: $\{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}, y_i \in \{+1, -1\}$
	基学习器优化算法 $\mathcal{Q}(h; X, Y, \mathcal{D})$
	训练轮数 T
1	样本权重初始化 $\mathcal{D}_1(x) = [\omega_i^{(t)} i = 1, \dots, N; t = 1] = [\frac{1}{N}, \dots, \frac{1}{N}]$
$t = 1$ 2	for $t = 1, 2, \dots, T$:
3	$h_t = \mathcal{Q}(h; X, Y, \mathcal{D}_t(X))$
4	$\epsilon_t = P_{x \sim \mathcal{D}_t}(h_t(x_i) \neq y_i) = \sum_{i=1}^N \omega_i I(h_t(x_i) \neq y_i)$
5	if $\epsilon_t > 0.5$ then break
6	基分类器权重: $\alpha_t = \frac{1}{2} \ln\left(\frac{1-\epsilon_t}{\epsilon_t}\right)$
7	更新样本权重: $\mathcal{D}_{t+1}(x) = \frac{\mathcal{D}_t(x) \exp(-\alpha_t y_i h_t(x_i))}{Z_t}$
输出	$H(x) = \text{sign}(\sum_{t=1}^T \alpha_t h_t(x))$

Boosting – AdaBoost例子

► 第一个基分类器 h_1

- 根据训练集 X 分布, 令 $v = 0.5, 1.5, 2.5, 3.5, 4.5, 5.5$

$$h_t(x) = \text{sign}(x - v) \Rightarrow h_1(x) = \text{sign}(x - 3.5), \epsilon_1 = 0.2$$

加权
误差
最小

v	$f(x)$ $h(x)$	y_1 $h(x_1)$	y_2 $h(x_2)$	y_3 $h(x_3)$	y_4 $h(x_4)$	y_5 $h(x_5)$	错分 样本	样本 权重	加权 误差 ϵ
0.5	f h	+1 +1	-1 +1	-1 +1	+1 +1	+1 +1	2, 3	$\frac{1}{5}, \frac{1}{5}$	0.4
1.5	f h	+1 -1	-1 +1	-1 +1	+1 +1	+1 +1	1, 2, 3	$\frac{1}{5}, \frac{1}{5}, \frac{1}{5}$	0.6
2.5	f h	+1 -1	-1 -1	-1 +1	+1 +1	+1 +1	1, 3	$\frac{1}{5}, \frac{1}{5}$	0.4
3.5	f h	+1 -1	-1 -1	-1 -1	+1 +1	+1 +1	1	$\frac{1}{5}$	0.2
4.5	f h	+1 -1	-1 -1	-1 -1	+1 -1	+1 +1	1, 4	$\frac{1}{5}, \frac{1}{5}$	0.4
5.5	f h	+1 -1	-1 -1	-1 -1	+1 -1	+1 -1	1, 4, 5	$\frac{1}{5}, \frac{1}{5}, \frac{1}{5}$	0.6

Boosting – AdaBoost例子

► 计算流程——步骤6/7: 更新分类器和样本权重

输入	训练集: $\{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_N, y_N)\}, y_i \in \{+1, -1\}$ 基学习器优化算法 $\mathcal{Q}(h; X, Y, \mathcal{D})$ 训练轮数 T
1	样本权重初始化 $\mathcal{D}_1(\mathbf{x}) = [\omega_i^{(t)} i = 1, \dots, N; t = 1] = [\frac{1}{N}, \dots, \frac{1}{N}]$
2	for $t = 1, 2, \dots, T$:
3	$h_t = \mathcal{Q}(h; X, Y, \mathcal{D}_t(X))$
4	$\epsilon_t = P_{\mathbf{x} \sim \mathcal{D}_t}(h_t(\mathbf{x}_i) \neq y_i) = \sum_{i=1}^N \omega_i I(h_t(\mathbf{x}_i) \neq y_i)$
5	if $\epsilon_t > 0.5$ then break
$t = 1$ ► 6	基分类器权重: $\alpha_t = \frac{1}{2} \ln \left(\frac{1 - \epsilon_t}{\epsilon_t} \right)$
7	更新样本权重: $\mathcal{D}_{t+1}(\mathbf{x}) = \frac{\mathcal{D}_t(\mathbf{x}) \exp(-\alpha_t y_i h_t(\mathbf{x}_i))}{Z_t}$
输出	$H(\mathbf{x}) = \text{sign}(\sum_{t=1}^T \alpha_t h_t(\mathbf{x}))$

Boosting – AdaBoost例子

► 第一次权重更新

- 基分类器 h_1 权重 α_1 计算: $\alpha_1 = \frac{1}{2} \ln \frac{1 - \epsilon_1}{\epsilon_1} = \frac{1}{2} \ln \frac{1 - 0.2}{0.2} = \ln 2$

- 样本权重 $\mathcal{D}_2$ 的计算:

$$Z_1 = \sum_{i=1}^5 \omega_i^{(1)} e^{-\alpha_1 y_i h_1(x_i)} = \frac{1}{5} e^{-(\ln 2) * 1 * (-1)} + \frac{1}{5} e^{-(\ln 2) * 1 * 1} \times 4 = 0.8$$

$$\omega_i^{(2)} = \frac{\omega_i^{(1)}}{Z_1} e^{-\alpha_1 y_i h_1(x_i)} = \begin{cases} 0.25 * e^{-(\ln 2) * 1 * (-1)} = \frac{1}{2}, & i = 1 \\ 0.25 * e^{-(\ln 2) * 1 * (+1)} = \frac{1}{8}, & i \neq 1 \end{cases}$$

- 更新后的样本权重: $\mathcal{D}_2 = \left[\frac{1}{2}, \frac{1}{8}, \frac{1}{8}, \frac{1}{8}, \frac{1}{8} \right]$

Boosting – AdaBoost例子

► 计算流程——第二轮循环

输入	训练集: $\{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_N, y_N)\}, y_i \in \{+1, -1\}$	
	基学习器优化算法 $\mathcal{L}(h; X, Y, \mathcal{D})$	
	训练轮数 T	
$t = 2$	1	样本权重初始化 $\mathcal{D}_1(\mathbf{x}) = [\omega_i^{(t)} i = 1, \dots, N; t = 1] = [\frac{1}{N}, \dots, \frac{1}{N}]$
	2	for $t = 1, 2, \dots, T$:
	3	$h_t = \mathcal{L}(h; X, Y, \mathcal{D}_t(X))$
	4	$\epsilon_t = P_{\mathbf{x} \sim \mathcal{D}_t}(h_t(\mathbf{x}_i) \neq y_i) = \sum_{i=1}^N \omega_i I(h_t(\mathbf{x}_i) \neq y_i)$
	5	if $\epsilon_t > 0.5$ then break
	6	基分类器权重: $\alpha_t = \frac{1}{2} \ln \left(\frac{1-\epsilon_t}{\epsilon_t} \right)$
	7	更新样本权重: $\mathcal{D}_{t+1}(\mathbf{x}) = \frac{\mathcal{D}_t(\mathbf{x}) \exp(-\alpha_t y_i h_t(\mathbf{x}_i))}{Z_t}$
输出	$H(\mathbf{x}) = \text{sign}(\sum_{t=1}^T \alpha_t h_t(\mathbf{x}))$	

Boosting – AdaBoost例子

► 第二个基分类器 h_2

- 根据新的 $\mathcal{D}_2$ 重新计算加权平均误差，找出最优的 $h_2^*(x)$

$$h_t(x) = \text{sign}(x - v) \Rightarrow h_2(x) = \text{sign}(x - 0.5), \epsilon_2 = 0.25$$

加权
误差
最小

v	$f(x)$ $h(x)$	y_1 $h(x_1)$	y_2 $h(x_2)$	y_3 $h(x_3)$	y_4 $h(x_4)$	y_5 $h(x_5)$	错分样本	样本权重	加权误差 ϵ
0.5	f h	+1 +1	-1 +1	-1 +1	+1 +1	+1 +1	2, 3	$\frac{1}{8}, \frac{1}{8}$	0.25
1.5	f h	+1 -1	-1 +1	-1 +1	+1 +1	+1 +1	1, 2, 3	$\frac{1}{2}, \frac{1}{8}, \frac{1}{8}$	0.75
2.5	f h	+1 -1	-1 -1	-1 +1	+1 +1	+1 +1	1, 3	$\frac{1}{2}, \frac{1}{8}$	0.625
3.5	f h	+1 -1	-1 -1	-1 -1	+1 +1	+1 +1	1	$\frac{1}{2}$	0.5
4.5	f h	+1 -1	-1 -1	-1 -1	+1 -1	+1 +1	1, 4	$\frac{1}{2}, \frac{1}{8}$	0.625
5.5	f h	+1 -1	-1 -1	-1 -1	+1 -1	+1 -1	1, 4, 5	$\frac{1}{2}, \frac{1}{8}, \frac{1}{8}$	0.75

Boosting – AdaBoost例子

► 计算流程——步骤6/7: 第二轮更新权重

输入	训练集: $\{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}, y_i \in \{+1, -1\}$ 基学习器优化算法 $\mathcal{Q}(h; X, Y, \mathcal{D})$ 训练轮数 T
1	样本权重初始化 $\mathcal{D}_1(x) = [\omega_i^{(t)} i = 1, \dots, N; t = 1] = [\frac{1}{N}, \dots, \frac{1}{N}]$
2	for $t = 1, 2, \dots, T$:
3	$h_t = \mathcal{Q}(h; X, Y, \mathcal{D}_t(X))$
4	$\epsilon_t = P_{x \sim \mathcal{D}_t}(h_t(x_i) \neq y_i) = \sum_{i=1}^N \omega_i I(h_t(x_i) \neq y_i)$
5	if $\epsilon_t > 0.5$ then break
$t = 2$ ► 6	基分类器权重: $\alpha_t = \frac{1}{2} \ln \left(\frac{1 - \epsilon_t}{\epsilon_t} \right)$
7	更新样本权重: $\mathcal{D}_{t+1}(x) = \frac{\mathcal{D}_t(x) \exp(-\alpha_t y_i h_t(x_i))}{Z_t}$
输出	$H(x) = \text{sign}(\sum_{t=1}^T \alpha_t h_t(x))$

Boosting – AdaBoost例子

► 第二轮更新权重

- 基分类器权重 α_t 计算: $\alpha_2 = \frac{1}{2} \ln \frac{1 - \epsilon_2}{\epsilon_2} = \frac{1}{2} \ln \frac{1 - 0.25}{0.25} = \frac{1}{2} \ln 3 = \ln \sqrt{3}$

- 样本权重 $\mathcal{D}_3$ 的计算:

$$Z_2 = \sum_{i=1}^5 \omega_i^{(2)} e^{-\alpha_2 y_i h_2(x_i)} = \frac{1}{2} e^{-(\ln \sqrt{3}) * 1 * 1} + \frac{1}{8} e^{-(\ln \sqrt{3}) * (-1) * 1} + \dots$$

$$= \frac{1}{2} \cdot \frac{1}{\sqrt{3}} + \frac{1}{8} \cdot \sqrt{3} + \frac{1}{8} \cdot \sqrt{3} + \frac{1}{8} \cdot \frac{1}{\sqrt{3}} + \frac{1}{8} \cdot \frac{1}{\sqrt{3}} = \frac{\sqrt{3}}{2}$$

$$\omega_i^{(3)} = \frac{\omega_i^{(2)}}{Z_2} e^{-\alpha_2 y_i h_2(x_i)}, \quad i = 1, 2, 3, 4, 5$$

- 更新后的样本权重: $\mathcal{D}_3 = \left[\frac{1}{3}, \frac{1}{4}, \frac{1}{4}, \frac{1}{12}, \frac{1}{12} \right]$

Boosting – AdaBoost例子

► 计算流程——第三轮循环

输入	训练集: $\{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}, y_i \in \{+1, -1\}$ 基学习器优化算法 $\mathcal{Q}(h; X, Y, \mathcal{D})$ 训练轮数 T
1	样本权重初始化 $\mathcal{D}_1(x) = [\omega_i^{(t)} i = 1, \dots, N; t = 1] = [\frac{1}{N}, \dots, \frac{1}{N}]$
$t = 3$ 2	for $t = 1, 2, \dots, T$:
3	$h_t = \mathcal{Q}(h; X, Y, \mathcal{D}_t(X))$
4	$\epsilon_t = P_{x \sim \mathcal{D}_t}(h_t(x_i) \neq y_i) = \sum_{i=1}^N \omega_i I(h_t(x_i) \neq y_i)$
5	if $\epsilon_t > 0.5$ then break
6	基分类器权重: $\alpha_t = \frac{1}{2} \ln \left(\frac{1 - \epsilon_t}{\epsilon_t} \right)$
7	更新样本权重: $\mathcal{D}_{t+1}(x) = \frac{\mathcal{D}_t(x) \exp(-\alpha_t y_i h_t(x_i))}{Z_t}$
输出	$H(x) = \text{sign}(\sum_{t=1}^T \alpha_t h_t(x))$

Boosting – AdaBoost例子

► 基分类器第三轮训练

- 根据新的 $\mathcal{D}_3$ 重新计算加权平均误差，找出最优的 $h_3^*(x)$

$$h_t(x) = \text{sign}(x - v) \quad h_3 = \text{sign}(x - 3.5), \epsilon_3 = 0.33$$

与 h_1 重复，且不是最优！

加权
误差
最小

v	$f(x)$ $h(x)$	y_1 $h(x_1)$	y_2 $h(x_2)$	y_3 $h(x_3)$	y_4 $h(x_4)$	y_5 $h(x_5)$	错分样 本	样本 权重	加权 误差 ϵ_t
0.5	f	+1	-1	-1	+1	+1	2, 3	$\frac{1}{4}, \frac{1}{4}$	0.5
	h	+1	+1	+1	+1	+1			
1.5	f	+1	-1	-1	+1	+1	1, 2, 3	$\frac{1}{3}, \frac{1}{4}, \frac{1}{4}$	0.83
	h	-1	+1	+1	+1	+1			
2.5	f	+1	-1	-1	+1	+1	1, 3	$\frac{1}{3}, \frac{1}{4}$	0.58
	h	-1	-1	+1	+1	+1			
3.5	f	+1	-1	-1	+1	+1	1	$\frac{1}{3}$	0.33
	h	-1	-1	-1	+1	+1			
4.5	f	+1	-1	-1	+1	+1	1, 4	$\frac{1}{3}, \frac{1}{12}$	0.42
	h	-1	-1	-1	-1	+1			
5.5	f	+1	-1	-1	+1	+1	1, 4, 5	$\frac{1}{3}, \frac{1}{12}, \frac{1}{12}$	0.5
	h	-1	-1	-1	-1	-1			

Boosting – AdaBoost例子

► 基分类器第三轮训练

- 根据新的 D_2 重新计算加权平均误差，找出最优的 $h_3^*(x)$

$$h_t(x) = \text{sign}(v - x)$$

$$h_3^*(x) = \text{sign}(1.5 - x), \quad \epsilon_3 = 1/6$$

$$\alpha_3 = \frac{1}{2} \ln \frac{1 - \epsilon_3}{\epsilon_3} = \frac{1}{2} \ln 5 = \ln \sqrt{5}$$

加权
误差
最小

v	$f(x)$ $h(x)$	y_1 $h(x_1)$	y_2 $h(x_2)$	y_3 $h(x_3)$	y_4 $h(x_4)$	y_5 $h(x_5)$	错分样本	样本权重	加权误差 ϵ_t
0.5	f	+1	-1	-1	+1	+1	1, 4, 5	$\frac{1}{3}, \frac{1}{12}, \frac{1}{12}$	0.5
	h	-1	-1	-1	-1	-1			
1.5	f	+1	-1	-1	+1	+1	4, 5	$\frac{1}{12}, \frac{1}{12}$	0.17
	h	+1	-1	-1	-1	-1			
2.5	f	+1	-1	-1	+1	+1	2, 4, 5	$\frac{1}{4}, \frac{1}{12}, \frac{1}{12}$	0.42
	h	+1	+1	-1	-1	-1			
3.5	f	+1	-1	-1	+1	+1	2, 3, 4, 5	$\frac{1}{4}, \frac{1}{4}, \frac{1}{12}, \frac{1}{12}$	0.67
	h	+1	+1	+1	-1	-1			
4.5	f	+1	-1	-1	+1	+1	2, 3, 5	$\frac{1}{4}, \frac{1}{4}, \frac{1}{12}$	0.58
	h	+1	+1	+1	+1	-1			
5.5	f	+1	-1	-1	+1	+1	2, 3	$\frac{1}{4}, \frac{1}{4}$	0.5
	h	+1	+1	+1	+1	+1			

Boosting – AdaBoost例子

▶ 计算过程汇总

t	ω_1	ω_2	ω_3	ω_4	ω_5	$h_t(x)$	ϵ_t	α_t
1	$\frac{1}{5}$	$\frac{1}{5}$	$\frac{1}{5}$	$\frac{1}{5}$	$\frac{1}{5}$	$\text{sign}(x - 3.5)$	0.2	$\ln 2$
2	$\frac{1}{2}$	$\frac{1}{8}$	$\frac{1}{8}$	$\frac{1}{8}$	$\frac{1}{8}$	$\text{sign}(x - 0.5)$	0.25	$\ln \sqrt{3}$
3	$\frac{1}{3}$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{12}$	$\frac{1}{12}$	$\text{sign}(1.5 - x)$	0.167	$\ln \sqrt{5}$

- 集成分类器为：


$$H(x) = \ln(2) \text{sign}(x - 3.5) + \ln \sqrt{3} \text{sign}(x - 0.5) + \ln \sqrt{5} \text{sign}(1.5 - x)$$

$$H(x_1) = -\ln 2 + \ln \sqrt{3} + \ln \sqrt{5} > 0; H(x_2) = -\ln 2 + \ln \sqrt{3} - \ln \sqrt{5} < 0;$$

$$H(x_4) = +\ln 2 + \ln \sqrt{3} - \ln \sqrt{5} > 0; H(x_3) = -\ln 2 + \ln \sqrt{3} - \ln \sqrt{5} < 0;$$

$$H(x_5) = +\ln 2 + \ln \sqrt{3} - \ln \sqrt{5} > 0; \text{分类结果完全正确!}$$

Boosting – AdaBoost图示




❑ 集成后的线性分类器可区分非线性可分数据

Boosting – AdaBoost总结

AdaBoost (Adaptive Boosting, 自适应增强), 其自适应在于: 前一个基本分类器分错的样本会得到加强, 加权后的全体样本再次被用来训练下一个基本分类器。同时, 在每一轮中加入一个新的弱分类器, 直达到达到某个预定的足够小的错误率或达到预先指定的最大迭代次数。

后一个模型的训练永远是在前一个模型的基础上完成!



集成学习

- 个体与集成
- Boosting
 - Adaboost
- Bagging与随机森林
- 结合策略
 - 平均法
 - 投票法
 - 学习法
- 多样性
 - 误差-分歧分解
 - 多样性度量
 - 多样性扰动

Bagging与随机森林

□ 个体学习器不存在强依赖关系，进行并行式集成；

—Boosting：串行提升，为每个样本分配不同的权重

—Bagging：并行学习，从原始样本集中生成不同的子集

□ 通过对训练样本采样，产生若干个不同的子集，再从每个数据子集中训练出一个基学习器。这样，由于训练数据不同，我们获得的基学习器可望具有比较大的差异。

- 如果采样出的每个子集都完全不同，则每个基学习器只用到了小部分训练数据，甚至不足以进行有效学习，无法保证产生比较好的基学习器；
- 如果采样出的子集间的重叠样本过多，则基学习器将过于相似。

□ 为此，考虑使用相互有交叠的采样子集。

Bagging策略

- Bagging是并行式集成学习方法的代表，它直接基于自助采样法（Bootstrap sampling）


▶ 采样方法

- **Bootstrap：有放回的统一抽样**

- 每个个体分类器的每次采样均从含 N 个样本的原始数据集抽取

- $N \rightarrow \infty$ 时，样本未被抽到概率为 $\lim_{N \rightarrow \infty} \left(1 - \frac{1}{N}\right)^N = \frac{1}{e} \approx 0.368$

- Out-Of-Bag (OOB)，未被抽到的样本可以作为验证集



Bagging算法

基本算法



算法步骤

- 通过对原始数据集的自助采样生成样本子集，抽取 T 轮得到 T 个子集；
- 每次使用一个子集训练一个模型，共得 T 个模型；
- **模型集成**
 - 分类问题**：采用投票方式得到分类结果
 - 回归问题**： T 个模型均值作为最后结果

Bagging算法

□ Bagging = Bootstrap AGGREGatING

输入: 训练集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$;
基学习算法 $\mathcal{L}$;
训练轮数 T .

过程:

```
1: for  $t = 1, 2, \dots, T$  do  
2:    $h_t = \mathcal{L}(D, \mathcal{D}_{bs})$   
3: end for
```

输出: $H(\mathbf{x}) = \arg \max_{y \in \mathcal{Y}} \sum_{t=1}^T \mathbb{I}(h_t(\mathbf{x}) = y)$

Bagging算法特点

□ Bagging是一个很高效的集成学习算法

- 假定基学习器的计算复杂度为 $O(m)$ ，采样与投票/平均过程的复杂度为 $O(s)$ ，则bagging的复杂度大致为 $T(O(m)+O(s))$
- 由于 $O(s)$ 很小且 T 是一个不大的常数
- 因此训练一个bagging集成与直接使用基学习器的复杂度同阶

□ 可使用包外估计：由自助采样法可知，每个基学习器只使用了初始训练集中约63.2%的样本，剩下约36.8%的样本可用作验证集来对泛化性能进行“包外估计”。

Bagging-包外估计

- $H^{oob}(x)$ 表示对样本 x 的包外预测，即仅考虑那些未使用样本 x 训练的基学习器在 x 上的预测 D_t 表示 h_t 实际使用的训练样本集

$$H^{oob}(\mathbf{x}) = \arg \max_{y \in \mathcal{Y}} \sum_{t=1}^T \mathbb{I}(h_t(\mathbf{x}) = y) \cdot \mathbb{I}(\mathbf{x} \notin D_t)$$

- Bagging泛化误差的包外估计为：

$$\epsilon^{oob} = \frac{1}{|D|} \sum_{(\mathbf{x}, y) \in D} \mathbb{I}(H^{oob}(\mathbf{x}) \neq y)$$


- 事实上，包外样本还有许多其他用途。例如，当基学习器是决策树时，可使用包外样本来辅助剪枝。

随机森林

随机森林是Bagging的一个扩展变体。它是在以决策树为基学习器构建Bagging集成的基础上，进一步在决策树的训练过程中引入随机属性选择。

▶ 算法要点概述

- 随机森林是Bagging的一种典型算法
- 采用Bagging策略建立多棵决策树
- 每棵决策树使用完整训练集的一个随机子集生成
- 每棵决策树的节点分裂使用完整特征集的一个随机子集
- 多棵决策树投票选出待预测样本所属的类型



随机森林

▶ 算法结构

• 第一：采样

- Bagging $\Rightarrow$ Bootstrap $\Rightarrow$ 随机样本子集
- 特征集 $\Rightarrow$ 从完整特征(属性)集中随机抽取一个子集

• 第二：学习

- 利用当前样本子集和特征子集，训练一棵决策树

• 第三：预测

- 单个决策树根据输入样本得到预测结果；
- Aggregating：根据每棵树的预测结果，用投票法产生最终结果

随机森林

▶ 算法流程


- **假设**
 - 样本数量为 N
 - 样本属性数量为 d
- **流程**
 - 1) Bootstrap法抽 N 个样本形成第 t 个样本子集 $D_t = \{X_t, Y_t\}$
 - 2) 将 D_t 作为当前决策树 Tr_t 的训练样本集
 - 3) 随机选取 m 个属性 ($m < d$) 作为决策树 Tr_t 的特征集
 - 4) 根据算法(通常为无后剪枝的CART) 生成 Tr_t
 - 5) 按照1) --4) 生成大量决策树, 构成随机森林 (可并行)
 - 6) 预测样本时, 通过投票法集成所有决策树的结果, 进行预测。

随机森林与Bagging区别

- ❑ 随机森林对Bagging只是做了小改动，但是与Bagging中基学习器的“多样性”仅通过样本扰动（通过对初始训练样本采样）而来不同，随机森林中基学习器的多样性不仅来着样本的扰动，还来自属性的扰动，这使得最终集成的泛化性能可通过个体学习器之间差异度的增加而进一步提升。
- ❑ 随机森林的训练效率常优于Bagging，因为在个体决策树的构建过程中，Bagging使用的是“确定型”决策树，在选择划分属性时要对结点的所有属性进行考察，而随机森林使用的“随机型”决策树则只需考察一个属性子集。

随机森林——例子

- 总共 $d = 6$ 个属性, $k = \lfloor \log_2 d \rfloor = \lfloor \sqrt{d} \rfloor = 2$.



随机森林——例子

随机森林利用某一个人的年龄、性别、教育情况、工作领域以及住宅地共**5**个属性来预测他的收入层次。

	Band 1 : Below \$40,000
收入层次 :	Band 2: \$40,000 – 150,000
	Band 3: More than \$150,000

这里假设森林中有**5**棵树，我们取 **$k=1$** ，即每棵树对应为由根据一个不同的属性划分而来。

随机森林——例子

CART 1 : Variable Age

	Salary Band	1	2	3
Age	Below 18	90%	10%	0%
	19-27	85%	14%	1%
	28-40	70%	23%	7%
	40-55	60%	35%	5%
	More than 55	70%	25%	5%

CART 2 : Variable Gender

	Salary Band	1	2	3
Gender	Male	70%	27%	3%
	Female	75%	24%	1%

随机森林——例子

CART 3 : Variable Education

	Salary Band	1	2	3
Education	<=High School	85%	10%	5%
	Diploma	80%	14%	6%
	Bachelors	77%	23%	0%
	Master	62%	35%	3%

CART 4 : Variable Residence

	Salary Band	1	2	3
Residence	Metro	70%	20%	10%
	Non-Metro	65%	20%	15%

CART 5 : Variable Industry

	Salary Band	1	2	3
Industry	Finance	65%	30%	5%
	Manufacturing	60%	35%	5%
	Others	75%	20%	5%

随机森林——例子

我们要预测的某人的信息如下：

1. Age : 35 years ;
2. Gender : Male ;
3. Highest Educational Qualification : Diploma holder;
4. Industry : Manufacturing;
5. Residence : Metro.

根据这5棵树的分类结果，可以得到这个人的收入层次预测：

CART	Band	1	2	3
Age	28-40	70%	23%	7%
Gender	Male	70%	27%	3%
Education	Diploma	80%	14%	6%
Industry	Manufacturing	60%	35%	5%
Residence	Metro	70%	20%	10%
Final probability		70%	24%	6%


此人的收入层次70%是一等，24%是二等，6%是三等，所以认定此人属于一等收入层次。

集成学习

- 个体与集成
- Boosting
 - Adaboost
- Bagging与随机森林
- 结合策略
 - 平均法
 - 投票法
 - 学习法
- 多样性
 - 误差-分歧分解
 - 多样性度量
 - 多样性扰动

结合策略

□ 学习器的组合可以从三个方面带来好处



- 从统计方面，由于学习任务的假设空间往往很大，可有多个假设在训练集上达到同等性能，此时若使用单学习器可能因误选而导致泛化性能不佳，结合多个学习器则会减少这一风险。
- 从计算方面，学习往往会陷入局部极小，有的局部极小点所对应的泛化性能可能很差，而通过多次运行之后进行结合，可降低陷入糟糕的局部极小点的风险。
- 从表示方面，某些学习任务的真实假设可能不在当前学习算法所考虑的假设空间中，此时若使用单学习器则肯定无效，而通过结合多个学习器，由于相应的假设空间有所扩大，有可能学得更好的近似。

结合策略 - 平均法

假定集成包含 T 个基学习器 $\{h_1, h_2, \dots, h_T\}$, 其中 h_i 在示例 $\mathbf{x}$ 上的输出为 $h_i(\mathbf{x})$.

对数值型输出 $h_i(\mathbf{x}) \in \mathbb{R}$, 最常见的结合策略是使用平均法 (averaging).

□ 简单平均法

$$H(\mathbf{x}) = \frac{1}{T} \sum_{i=1}^T h_i(\mathbf{x}).$$

□ 加权平均法

$$H(\mathbf{x}) = \sum_{i=1}^T w_i h_i(\mathbf{x}), \quad w_i \geq 0 \quad \text{and} \quad \sum_{i=1}^T w_i = 1.$$

结合策略 - 平均法

- 简单平均法是加权平均法的特例 $w_i = 1/T$
- 加权平均法的权重一般是从训练数据中学习而得，现实任务中的训练样本通常不充分或存在噪声，这将使得学出的权重不完全可靠。尤其对规模比较大的集成来说，要学习的权重比较多，较容易导致过拟合。因此，实验和应用均显示出，加权平均法未必一定优于简单平均法。
- 一般而言，在个体学习器性能相差较大时宜使用加权平均法，而在个体学习器性能相近时宜使用简单平均法。

结合策略 - 投票法

对分类任务来说, 学习器 h_i 将从类别标记集合 $\{c_1, c_2, \dots, c_N\}$ 中预测出一个标记, 最常见的结合策略是使用投票法(voting)

$h_i^j(\mathbf{x})$ 是 h_i 在类别标记 c_j 上的输出.

□ 绝对多数投票法 (majority voting)

$$H(\mathbf{x}) = \begin{cases} c_j & \text{if } \sum_{i=1}^T h_i^j(\mathbf{x}) > \frac{1}{2} \sum_{k=1}^l \sum_{i=1}^T h_i^k(\mathbf{x}) \\ \text{rejection} & \text{otherwise.} \end{cases}$$

□ 相对多数投票法 (plurality voting)

$$H(\mathbf{x}) = c_{\arg \max_j \sum_{i=1}^T h_i^j(\mathbf{x})}$$

□ 加权投票法 (weighted voting)

$$H(\mathbf{x}) = c_{\arg \max_j \sum_{i=1}^T w_i h_i^j(\mathbf{x})} \quad w_i \geq 0, \sum_{i=1}^T w_i = 1.$$

结合策略 - 投票法

- ❑ 绝对多数投票法提供了“拒绝预测”选项，这在可靠性要求较高的学习任务宜适用，但若学习任务要求必须提供预测结果，则绝对多数投票法将退化为相对多数投票法。因此，在不允许拒绝预测的任务中，绝对多数、相对多数投票法统称为多数投票法。

结合策略 - 投票法

- 绝对多数投票法提供了“拒绝预测”选项，这在可靠性要求较高的学习任务宜适用，但若学习任务要求必须提供预测结果，则绝对多数投票法将退化为相对多数投票法。因此，在不允许拒绝预测的任务中，绝对多数、相对多数投票法统称为多数投票法。
- 个体学习器输出值的类型
 - 1) 类标记 $h_i^j(\mathbf{x}) \in \{0, 1\}$ 硬投票 (hard voting)
 - 2) 类概率 $h_i^j(\mathbf{x}) \in [0, 1]$ 软投票 (soft voting)
 - 不同类型的 $h_i^j(\mathbf{x})$ 值不能混用。
 - 若基学习器的类型不同，则其类概率值不能直接进行比较；此时，通常将类概率输出转化为类标记输出（例如将类概率输出最大的 $h_i^j(\mathbf{x})$ 设为1，其他设为0），然后再投票。

结合策略 - 学习法

- ❑ 当训练数据很多时，一种更为强大的结合策略是使用“学习法”，即通过另一个学习器来进行基学习器结合。
- ❑ **Stacking**是学习法的典型代表。这里，把个体学习器称为初级学习器，用于结合的学习器称为次级学习器或元学习器。
- ❑ **Stacking**先从初始数据集训练出初级学习器，然后生成一个新的数据集用于训练次级学习器，在这个新数据集中，初级学习器的输出被当做样本的输入特征，而初始样本的标记仍被当做样本标记。

结合策略 - 学习法

在训练阶段, 次级训练集是利用初级学习器产生的, 若直接用初级学习器的训练集来产生次级训练集, 则过拟合风险会比较大; 因此, 一般是通过使用交叉验证或留一法这样的方式, 用训练初级学习器未使用的样本来产生次级学习器的训练样本. 以 k 折交叉验证为例, 初始训练集 D 被随机划分为 k 个大小相似的集合 $D_1, D_2, \dots, D_k$. 令 D_j 和 $\bar{D}_j = D \setminus D_j$ 分别表示第 j 折的测试集和训练集. 给定 T 个初级学习算法, 初级学习器 $h_t^{(j)}$ 通过在 $\bar{D}_j$ 上使用第 t 个学习算法而得. 对 D_j 中每个样本 $\mathbf{x}_i$, 令 $z_{it} = h_t^{(j)}(\mathbf{x}_i)$, 则由 $\mathbf{x}_i$ 所产生的次级训练样例的示例部分为 $\mathbf{z}_i = (z_{i1}; z_{i2}; \dots; z_{iT})$, 标记部分为 y_i . 于是, 在整个交叉验证过程结束后, 从这 T 个初级学习器产生的次级训练集是 $D' = \{(\mathbf{z}_i, y_i)\}_{i=1}^m$, 然后 D' 将用于训练次级学习器.

集成学习

- 个体与集成
- Boosting
 - Adaboost
- Bagging与随机森林
- 结合策略
 - 平均法
 - 投票法
 - 学习法
- 多样性
 - 误差-分歧分解
 - 多样性度量
 - 多样性扰动

多样性 - 误差-分歧分解

- 欲构建泛化能力强的集成，个体学习器应“好而不同”。假定个体学习器 $h_1, h_2, \dots, h_T$ 通过加权平均法结合产生的集成来完成回归学习任务 $f : \mathbb{R}^d \mapsto \mathbb{R}$.

- 定义学习器 h_i 的分歧(ambiguity):

$$A(h_i | \mathbf{x}) = (h_i(\mathbf{x}) - H(\mathbf{x}))^2$$

- 集成的分歧:

$$\begin{aligned}\bar{A}(h | \mathbf{x}) &= \sum_{i=1}^T w_i A(h_i | \mathbf{x}) \\ &= \sum_{i=1}^T w_i (h_i(\mathbf{x}) - H(\mathbf{x}))^2\end{aligned}$$

多样性 - 误差-分歧分解

- ❑ 分歧项代表了个体学习器在样本 $\mathbf{x}$ 上的不一致性，即在一定程度上反映了个体学习器的多样性。
- ❑ 个体学习器 h_i 和集成 H 的平方误差分别为

$$E(h_i | \mathbf{x}) = (f(\mathbf{x}) - h_i(\mathbf{x}))^2$$

$$E(H | \mathbf{x}) = (f(\mathbf{x}) - H(\mathbf{x}))^2$$

多样性 - 误差-分歧分解

- 令 $\bar{E}(h \mid \mathbf{x}) = \sum_{i=1}^T w_i \cdot E(h_i \mid \mathbf{x})$ 表示个体学习器误差的加权均值，则有

$$\begin{aligned}\bar{A}(h \mid \mathbf{x}) &= \sum_{i=1}^T w_i E(h_i \mid \mathbf{x}) - E(H \mid \mathbf{x}) \\ &= \bar{E}(h \mid \mathbf{x}) - E(H \mid \mathbf{x}) .\end{aligned}$$

- 上式对所有样本 $\mathbf{x}$ 均成立，令 $p(\mathbf{x})$ 表示样本的概率密度，则在全样本上有

$$\sum_{i=1}^T w_i \int A(h_i \mid \mathbf{x}) p(\mathbf{x}) d\mathbf{x} = \sum_{i=1}^T w_i \int E(h_i \mid \mathbf{x}) p(\mathbf{x}) d\mathbf{x} - \int E(H \mid \mathbf{x}) p(\mathbf{x}) d\mathbf{x}$$

多样性 - 误差-分歧分解

- 个体学习器 h_i 在全样本上的泛化误差和分歧项分别为：

$$E_i = \int E(h_i | \mathbf{x}) p(\mathbf{x}) d\mathbf{x}$$

$$A_i = \int A(h_i | \mathbf{x}) p(\mathbf{x}) d\mathbf{x}$$

- 集成的泛化误差为：

$$E = \int E(H | \mathbf{x}) p(\mathbf{x}) d\mathbf{x}$$

- 令 $\bar{E} = \sum_{i=1}^T w_i E_i$ 表示个体学习器泛化误差的加权均值，
 $\bar{A} = \sum_{i=1}^T w_i A_i$ 表示个体学习器的加权分歧值，有

$$E = \bar{E} - \bar{A}$$

表明：个体学习器准确性越高、多样性越大，则集成越好

多样性 - 多样性度量

- 多样性度量(diversity measure)用于度量集成中个体分类器的多样化程度。典型做法是考虑个体分类器的两两相似/不相似性
- 对于二分类问题，分类器 h_i 与 h_j 的预测结果列联表为

	$h_i = +1$	$h_i = -1$
$h_j = +1$	a	c
$h_j = -1$	b	d

$$a + b + c + d = m$$

多样性 - 多样性度量

□ 常见的多样性度量

- 不合度量(Disagreement Measure)

$$dis_{ij} = \frac{b + c}{m}$$

dis_{ij} 的值域为 $[0, 1]$. 值越大则多样性越大.

- 相关系数(Correlation Coefficient)

$$\rho_{ij} = \frac{ad - bc}{\sqrt{(a + b)(a + c)(c + d)(b + d)}}$$

ρ_{ij} 的值域为 $[-1, 1]$. 若 h_i 与 h_j 无关, 则值为 0; 若 h_i 与 h_j 正相关则值为正, 否则为负.

多样性 - 多样性度量

□ 常见的多样性度量

- Q-统计量(Q-Statistic)

$$Q_{ij} = \frac{ad - bc}{ad + bc} \quad |Q_{ij}| \geq |\rho_{ij}|$$

- κ -统计量(Kappa-Statistic)


$$\kappa = \frac{p_1 - p_2}{1 - p_2} \quad \begin{array}{l} p_1 = \frac{a + d}{m}, \\ p_2 = \frac{(a + b)(a + c) + (c + d)(b + d)}{m^2} \end{array}$$

p_1 是两个分类器取得一致的概率;
 p_2 是两个分类器偶然达成一致的的概率


若分类器 h_i 与 h_j 在 D 上完全一致, 则 $\kappa = 1$; 若它们仅是偶然达成一致, 则 $\kappa = 0$. κ 通常为非负值, 仅在 h_i 与 h_j 达成一致的甚至低于偶然性的情况下取负值.

多样性 - 多样性度量

□ κ - 误差图



(a) AdaBoost 集成



(b) Bagging 集成

显然, 数据点云的位置越高, 则个体分类器准确性越低;
点云的位置越靠右, 则个体学习器的多样性越小.

多样性 - 多样性增强

□ 常见的增强个体学习器的多样性的方法

- 数据样本扰动
- 输入属性扰动
- 输出表示扰动
- 算法参数扰动
- 混合扰动：不同的多样性增强机制同时使用

多样性 - 多样性增强 - 数据样本扰动

- 数据样本扰动通常是基于采样法从原始训练样本集中产生出不同的样本子集，然后再利用不同的样本子集训练出不同的个体学习器。

- Bagging中的自助采样
- AdaBoost中的序列采样

数据样本扰动对“不稳定基学习器”很有效，但对稳定基学习器效果不明显

- 对数据样本的扰动敏感的基学习器(不稳定基学习器)

- 决策树，神经网络等

- 对数据样本的扰动不敏感的基学习器(稳定基学习器)

- 线性学习器，支持向量机，朴素贝叶斯，k近邻等

多样性 - 多样性增强 - 输入属性扰动

- 输入属性扰动通常是从初始属性集中抽取若干个属性子集（子空间），然后利用不同的属性子集训练出不同的个体学习器，比如随机森林。
- 对包含大量冗余属性的数据在子空间中训练个体学习器不仅能产生多样性大的个体，还会因属性数的减少而大幅节省时间开销，同时性能也不至于太差。
- 若数据只包含少量属性，或者冗余属性很少，则不宜使用输入属性扰动法。

多样性 - 多样性增强 - 输出表示扰动

- 输入表示扰动通常是对训练样本的类标记稍作变动：从
 - 翻转法：随机改变一些训练样本的标记
 - 输出调制法：将分类输出转化为回归输出后构建个体学习器
 - 还可以将原任务拆解为多个可同时求解的子任务：如ECOC法利用纠错输出码将多分类任务拆解为一系列二分类任务来训练基学习器

- 输出表示扰动法对类数足够多的数据集有效，但若数据集包含的类数较少，则不宜使用。

多样性 - 多样性增强 - 算法参数扰动

- ❑ 算法参数扰动通常是通过随机设置不同的参数来训练差别较大的个体学习器。比如，神经网络的隐层神经元数、初始连接权重等。
- ❑ 对参数较少的算法，可通过将其学习过程中某些环节用其他类似方式代替，从而达到扰动的目的。例如，可将决策树使用属性选择机制换成其他属性选择机制。

多样性 - 多样性增强 - 混合扰动

- 混合扰动是指在同一个集成算法中同时使用上述多种扰动方法。比如，随机森林就同时使用了训练样本扰动和输入属性扰动。

本章总结

□ 个体与集成



“好而不同”

- 好：个体学习器应至少为弱学习器
- 不同：不同个体学习器的预测结果存在多样性

□ 个体分类器学习存在的两种典型策略

— boosting: 提升法

- 个体学习器串行学习，集成性能逐步“提升”
- 如何保证不同：个体学习器对训练样本加以不同权重

— bagging: bootstrap aggregating, 自举法或装袋法

- 个体学习器并行学习，学习过程相互独立
- 如何保证不同：个体学习器采用不同训练集

本章总结

□ 结合策略

- 平均法：个体学习器的输出是数值型；简单/加权平均法
- 投票法：分类任务；多数/加权投票法
- 学习法：通过另一个学习器来进行基学习器结合；**Stacking**

□ 多样性

- 误差-分歧分解：个体学习器准确性越高、多样性越大，则集成越好
- 多样性度量：不合度量、相关系数、Q-统计量、**K**-统计量
- 多样性扰动：数据样本/输入属性/输出表示/算法参数/混合扰动