

机器学习

Machine Learning

肖力

信息科学技术学院—6系

<https://faculty.ustc.edu.cn/xiaoli>

k近邻学习

大纲

□ 距离计算

□ **k**近邻学习

□ 度量学习：近邻成分分析

大纲

- 距离计算

- k近邻学习

- 度量学习：近邻成分分析

距离计算

□ 距离度量的性质:

非负性: $\text{dist}(x_i, x_j) \geq 0$

同一性: $\text{dist}(x_i, x_j) = 0$ 当且仅当 $x_i = x_j$

对称性: $\text{dist}(x_i, x_j) = \text{dist}(x_j, x_i)$

直递性: $\text{dist}(x_i, x_j) \leq \text{dist}(x_i, x_k) + \text{dist}(x_k, x_j)$

距离计算

□ 距离度量的性质:

非负性: $dist(x_i, x_j) \geq 0$

同一性: $dist(x_i, x_j) = 0$ 当且仅当 $x_i = x_j$

对称性: $dist(x_i, x_j) = dist(x_j, x_i)$

直递性: $dist(x_i, x_j) \leq dist(x_i, x_k) + dist(x_k, x_j)$

欧氏距离

马氏距离

标准化欧氏距离

海明距离

曼哈顿距离

杰卡德距离

切比雪夫距离

相关距离

闵可夫斯基距离

信息熵

余弦距离

基于核函数的度量

距离计算

□ 距离度量的性质：

非负性： $dist(x_i, x_j) \geq 0$

同一性： $dist(x_i, x_j) = 0$ 当且仅当 $x_i = x_j$

对称性： $dist(x_i, x_j) = dist(x_j, x_i)$

直递性： $dist(x_i, x_j) \leq dist(x_i, x_k) + dist(x_k, x_j)$

□ 常用距离：

闵可夫斯基距离 (Minkowski distance) :

$$dist(x_i, x_j) = \left(\sum_{u=1}^n |x_{iu} - x_{ju}|^p \right)^{\frac{1}{p}}$$



$p=2$: 欧氏距离 (Euclidean distance) .

$p=1$: 曼哈顿距离 (Manhattan distance) .

$p=\infty$: 切比雪夫距离 (Chebyshev distance) .

距离计算

□ 二维向量的闵可夫斯基距离可视化



距离计算

□ 属性介绍

- 连续属性 (continuous attribute)
在定义域上有无穷多个可能的取值
- 离散属性 (categorical attribute)
在定义域上是有限个可能的取值

距离计算

□ 属性介绍

- 连续属性 (continuous attribute)

在定义域上有无穷多个可能的取值

- 离散属性 (categorical attribute)

在定义域上是有限个可能的取值

- 有序属性 (ordinal attribute)

例如定义域为 $\{1,2,3\}$ 的离散属性, “1”与“2”比较接近、与“3”比较远, 称为“有序属性”。

- 无序属性 (non-ordinal attribute)

例如定义域为{飞机, 火车, 轮船}这样的离散属性, 不能直接在属性值上进行计算, 称为“无序属性”。

距离度量

Value Difference Metric, VDM (处理无序属性) :

令 $m_{u,a}$ 表示属性 u 上取值为 a 的样本数, $m_{u,a,i}$ 表示在第 i 个样本簇中在属性 u 上取值为 a 的样本数, k 为样本簇数, 则属性 u 上两个离散值 a 与 b 之间的VDM距离为

$$VDM_p(a, b) = \sum_{i=1}^k \left| \frac{m_{u,a,i}}{m_{u,a}} - \frac{m_{u,b,i}}{m_{u,b}} \right|^p$$

计算“西瓜书”第76页表4.1西瓜数据集2.0属性根蒂上“蜷缩”和“稍蜷”两个离散值之间的距离。

根蒂为蜷缩的样本共有8个(编号1~5、编号12、编号16~17), 即 $m_{u,a} = 8$,

根蒂为稍蜷的样本共有7个(编号6~9和编号13~15), 即 $m_{u,b} = 7$;

设 $i = 1$ 对应好瓜, $i = 2$ 对应坏瓜, 好瓜中根蒂为蜷缩的样本共有5个(编号1~5), 即 $m_{u,a,1} = 5$, 好瓜中根蒂为稍蜷的样本共有3个(编号6~8), 即 $m_{u,b,1} = 3$,

坏瓜中根蒂为蜷缩的样本共有3个(编号12和编号16~17), 即 $m_{u,a,2} = 3$,

坏瓜中根蒂为稍蜷的样本共有4个(编号9和编号13~15), 即 $m_{u,b,2} = 4$,

$$VDM_p(a, b) = \left| \frac{m_{u,a,1}}{m_{u,a}} - \frac{m_{u,b,1}}{m_{u,b}} \right|^p + \left| \frac{m_{u,a,2}}{m_{u,a}} - \frac{m_{u,b,2}}{m_{u,b}} \right|^p = \left| \frac{5}{8} - \frac{3}{7} \right|^p + \left| \frac{3}{8} - \frac{4}{7} \right|^p$$

距离度量

□ MinkovDM_p（处理混合属性）：

$$MinkovDM_p(x_i, x_j) = \left(\sum_{u=1}^{n_c} |x_{iu} - x_{ju}|^p + \sum_{u=n_c+1}^n VDM_p(x_{iu}, x_{ju}) \right)^{\frac{1}{p}}$$


□ 加权距离（样本中不同属性的重要性不同时）：

$$dist(x_i, x_j) = (\omega_1 \cdot |x_{i1} - x_{j1}|^p + \cdots + \omega_n \cdot |x_{in} - x_{jn}|^p)^{\frac{1}{p}}$$

$$\omega_i \geq 0, \sum_{i=1}^n \omega_i = 1$$

距离度量

- 通常，我们是基于某种距离来定义相似性度量；距离越大，相似性越小。
- 然而，用于相似性度量的距离未必一定要满足距离度量的所有基本条件，尤其是直递性。这样的距离称为“非度量距离”



大纲

□ 距离计算

□ **k近邻学习**

□ 度量学习：近邻成分分析

k近邻学习

k近邻学习的工作机制

□ k近邻(k-Nearest Neighbor, kNN)学习是一种常用的有监督学习方法，可以用于基本的分类与回归任务：

- 确定训练样本，以及某种距离度量。
- 对于某个给定的测试样本，找到训练集中距离最近的 k 个样本，对于分类问题使用“投票法”获得预测结果，对于回归问题使用“平均法”获得预测结果。还可基于距离远近进行加权平均或加权投票，距离越近的样本权重越大。
 - 投票法：选择这 k 个样本中出现最多的类别标记作为预测结果。
 - 平均法：将这 k 个样本的实值输出标记的平均值作为预测结果。

□ 本章我们只讨论分类问题中的k近邻学习。

“懒惰学习”与“急切学习”

k近邻学习没有显式的训练过程，属于“懒惰学习”

- “懒惰学习” (lazy learning): 此类学习技术在训练阶段仅仅是把样本保存起来，训练时间开销为零，待收到测试样本后再进行处理。
- “急切学习” (eager learning): 在训练阶段就对样本进行学习处理的方法。

k近邻分类示意图

k近邻学习有k值选取和距离度量这两个基本要素





图 10.1 k 近邻分类器示意图. 虚线显示出等距线; 测试样本在 $k=1$ 或 $k=5$ 时被判别为正例, $k=3$ 时被判别为反例.

□ k近邻分类器中的k是一个重要参数, 当k取不同值时, 分类结果会有显著不同。

k近邻分类示意图

k近邻学习有k值选取和距离度量这两个基本要素



图：测试样本在 $k=1$ 时，若距离用 $p=2$ 的闵可夫斯基距离，测试样本被判为正例；距离用 $p=\infty$ 的闵可夫斯基距离，测试样本被判为负例。

□ 另一方面，若采用不同的距离计算方式，则找出的“近邻”可能也会有显著差别，从而导致分类结果有显著不同。

k近邻学习

分析1NN二分类错误率 $P(err)$

□ 暂且假设距离计算是“恰当”的，即能够恰当地找出k个近邻，我们来对“最近邻分类器”（1NN，即k=1）在二分类问题上的性能做一个简单的讨论。给定测试样本 $\mathbf{x}$ ，若其最近邻样本为 $\mathbf{z}$ ，则最近邻出错的概率就是 $\mathbf{x}$ 与 $\mathbf{z}$ 类别标记不同的概率，即

$$P(err) = 1 - \sum_{c \in \mathcal{Y}} P(c|\mathbf{x})P(c|\mathbf{z})$$

k近邻学习

分析1NN二分类错误率 $P(err)$

□ 假设样本独立同分布，且对任意 $\mathbf{x}$ 和任意小正数 δ ，在 $\mathbf{x}$ 附近 δ 距离范围内总能找到一个训练样本；换言之，对任意测试样本，总能在任意近的范围找到 $P(err) = 1 - \sum_{c \in \mathcal{Y}} P(c|\mathbf{x})P(c|\mathbf{z})$ 中的训练样本 $\mathbf{z}$ 。

□ 令 $c^* = \arg \max_{c \in \mathcal{Y}} P(c|\mathbf{x})$ 表示贝叶斯最优分类器的结果，有

$$\begin{aligned} P(err) &= 1 - \sum_{c \in \mathcal{Y}} P(c|\mathbf{x})P(c|\mathbf{z}) \simeq 1 - \sum_{c \in \mathcal{Y}} P^2(c|\mathbf{x}) \\ &\leq 1 - P^2(c^*|\mathbf{x}) = (1 + P(c^*|\mathbf{x}))(1 - P(c^*|\mathbf{x})) \\ &\leq 2 \times (1 - P(c^*|\mathbf{x})). \end{aligned}$$

□ 最近邻分类虽简单，但它的泛化错误率不超过贝叶斯最优分类器错误率的两倍！

k近邻学习

□ 虽然KNN的基本思想非常简单，但在实际应用中，经常会遇到很多现实问题：

1) 度量样本间距离问题

- ✓ 连续属性和（有序）离散属性：闵可夫斯基距离等
- ✓ （无序）离散属性：VDM距离等
- ✓ 混合属性：MinkovDM_p距离等。

简单说，样本间的距离可分解成样本在每一维上距离；然后再根据每一维上的数据类型来选择合适的距离度量。

k近邻学习

2) 维度灾难 (curse of dimensionality) 问题


- 维度灾难是指在高维样本（特征）空间中，样本数量相对较小时，样本之间变得非常稀疏及其距离计算也变得困难，使得模型难以在所有维度上捕捉到数据的内在结构，从而容易导致模型效果低效和过拟合。
- 缓解维度灾难的一个常用方法是降维，亦称“维数约简”，即通过某种数学变换将原始高维属性空间转变为一个低维“子空间”，在此子空间中样本密度大幅提高，距离计算也变得更容易。

3) 邻域大小问题

- k 是 k 近邻学习中的一个重要参数。同样的数据，不同的 k 可能产生不同的预测结果。
- 对于 k 值的选取主要有两种办法：基于经验直接给定；和基于数据自动学习。

k近邻学习

KNN实现MNIST数字分类



MNIST数据集由0~9手写数字图片和数字标签组成。

- **训练集:** 60000张图片
- **测试集:** 10000张图片
- **图片格式:** 28 * 28像素的灰度图片

每个像素点用1或0表示；
1代表黑色像素、0代表
白色像素。

k近邻学习

KNN实现MNIST数字分类

KNN算法将比较测试图片与训练图片中的距离，这里采用欧氏距离。我们在测试集上观测算法的效果，并对比不同K取值的影响。

k的取值为 1,	预测准确率为 88.5%
k的取值为 2,	预测准确率为 88.0%
k的取值为 3,	预测准确率为 87.5%
k的取值为 4,	预测准确率为 87.5%
k的取值为 5,	预测准确率为 88.5%
k的取值为 6,	预测准确率为 88.5%
k的取值为 7,	预测准确率为 88.0%
k的取值为 8,	预测准确率为 87.0%
k的取值为 9,	预测准确率为 87.0%

大纲

□ 距离计算

□ k近邻学习

□ 度量学习：近邻成分分析

度量学习

研究动机

- 前面介绍的距离计算式都是事先定义好的，但在不少现实任务中，有必要基于数据样本本身来确定合适的距离计算式，这可通过“度量学习”（metric learning）来实现。
- 度量学习的目标是通过学习一个映射函数，将样本映射到一个新的空间中，使得在该空间中，相似的样本间距离较近，而不相似的样本间距离较远。

度量学习

- $\mathbf{M}$ 为一个普通的半正定对称矩阵，两个样本 $\mathbf{x}_i$ 和 $\mathbf{x}_j$ 的马氏距离 (Mahalanobis distance) 定义为

$$\text{dist}_{\text{mah}}^2(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i - \mathbf{x}_j)^T \mathbf{M} (\mathbf{x}_i - \mathbf{x}_j) = \|\mathbf{x}_i - \mathbf{x}_j\|_{\mathbf{M}}^2,$$

其中 $\mathbf{M}$ 亦称“度量矩阵”，而度量学习则是对 $\mathbf{M}$ 进行学习。注意到为了保持距离非负且对称， $\mathbf{M}$ 必须是（半）正定对称矩阵，即必有正交基 $\mathbf{P}$ 使得 $\mathbf{M}$ 能写为 $\mathbf{M} = \mathbf{P}\mathbf{P}^T$ 。

- 对 $\mathbf{M}$ 进行学习当然要设置一个目标。假定我们是希望提高近邻分类器的性能，则可将 $\mathbf{M}$ 直接嵌入到近邻分类器的评价指标中去，通过优化该性能指标相应地求得 $\mathbf{M}$ 。

度量学习

近邻成分分析(Neighbourhood Component Analysis, NCA)

- 近邻成分分析在进行判别时通常使用多数投票法，邻域中的每个样本投**1**票，邻域外的样本投**0**票。不妨将其替换为概率投票法。对于任意样本 $\mathbf{x}_j$ ，它对 $\mathbf{x}_i$ 分类结果影响的概率为

$$p_{ij} = \frac{\exp(-\|\mathbf{x}_i - \mathbf{x}_j\|_{\mathbf{M}}^2)}{\sum_l \exp(-\|\mathbf{x}_i - \mathbf{x}_l\|_{\mathbf{M}}^2)},$$

度量学习

近邻成分分析(Neighbourhood Component Analysis, NCA)

- 近邻成分分析在进行判别时通常使用多数投票法，邻域中的每个样本投**1**票，邻域外的样本投**0**票。不妨将其替换为概率投票法。对于任意样本 $\mathbf{x}_j$ ，它对 $\mathbf{x}_i$ 分类结果影响的概率为

$$p_{ij} = \frac{\exp(-\|\mathbf{x}_i - \mathbf{x}_j\|_{\mathbf{M}}^2)}{\sum_l \exp(-\|\mathbf{x}_i - \mathbf{x}_l\|_{\mathbf{M}}^2)},$$

- 当 $i = j$ 时, p_{ij} 最大。显然, $\mathbf{x}_j$ 对 $\mathbf{x}_i$ 的影响随着它们之间距离的增大而减小。若以留一法(LOO)正确率的最大化为目标, 则可计算 $\mathbf{x}_i$ 的留一法正确率, 即它被自身之外的所有样本正确分类的概率为

$$p_i = \sum_{j \in \Omega_i} p_{ij},$$

其中 Ω_i 表示与 $\mathbf{x}_i$ 属于相同类别的样本的下标集合。

度量学习

近邻成分分析(Neighbourhood Component Analysis, NCA)

□ 整个样本集上的留一法正确率为

$$\sum_{i=1}^m p_i = \sum_{i=1}^m \sum_{j \in \Omega_i} p_{ij}.$$

□ 由 $p_{ij} = \frac{\exp(-\|\mathbf{x}_i - \mathbf{x}_j\|_{\mathbf{M}}^2)}{\sum_l \exp(-\|\mathbf{x}_i - \mathbf{x}_l\|_{\mathbf{M}}^2)}$ 和 $\mathbf{M} = \mathbf{P}\mathbf{P}^T$, 则NCA的优化目标为



$$\min_{\mathbf{P}} \quad 1 - \sum_{i=1}^m \sum_{j \in \Omega_i} \frac{\exp(-\|\mathbf{P}^T \mathbf{x}_i - \mathbf{P}^T \mathbf{x}_j\|_2^2)}{\sum_l \exp(-\|\mathbf{P}^T \mathbf{x}_i - \mathbf{P}^T \mathbf{x}_l\|_2^2)}.$$

求解即可得到最大化最近邻分类器LOO正确率的距离度量矩阵 $\mathbf{M}$ 。

□ 近邻成分分析的核心思想是找到一个线性变换, 使得在变换后的特征空间中, 最近邻分类器在训练集上的分类准确率最大化。

度量学习

近邻成分分析(Neighbourhood Component Analysis, NCA)



- 在原始空间中，样本3有许多来自不同类的邻居，所以不太可能找到正确的类；
- 然而，在**NCA**学习的空间中，样本3的邻居来自于与自己相同类，从而保证将被很好地分类。

□ 可以直观地看到，近邻成分分析可以提高最近邻分类器在复杂数据集（线性不可分）上的准确率。

小结

- **k近邻学习**：k值选取、距离度量、维度灾难
- **度量学习（近邻成分分析）**：马氏距离、近邻成分分析