

机器学习

Machine Learning

肖力

信息科学技术学院—6系

<https://faculty.ustc.edu.cn/xiaoli>

主成分分析PCA

大纲

□ PCA

□ Kernel PCA

大纲

□ **PCA**

□ Kernel PCA

低维嵌入

- 缓解维数灾难的一个重要途径是降维(dimension reduction)
 - 即通过某种数学变换，将原始高维属性空间转变为一个低维“子空间”(subspace)，在这个子空间中样本密度大幅度提高，距离计算也变得更为容易。
- 为什么能进行降维？
 - 数据样本虽然是高维的，但与学习任务密切相关的也许仅是某个低维分布，即高维空间中的一个低维“嵌入”(embedding)，因而可以对数据进行有效的降维。




图 10.2 低维嵌入示意图

线性降维方法


- 一般来说，欲获得低维子空间，最简单的是对原始高维空间进行线性变换。给定 d 维空间中的样本 $\mathbf{X} = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m) \in \mathbb{R}^{d \times m}$ ，变换之后得到 $d' \leq d$ 维空间中的样本

$$\mathbf{Z} = \mathbf{W}^T \mathbf{X},$$

其中 $\mathbf{W} \in \mathbb{R}^{d \times d'}$ 是变换矩阵， $\mathbf{Z} \in \mathbb{R}^{d' \times m}$ 是样本在新空间中的表达。

- 变换矩阵 $\mathbf{W}$ 可视为 d' 个 d 维属性向量。换言之， $\mathbf{z}_i$ 是原属性向量 $\mathbf{x}_i$ 在新坐标系 $\{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_{d'}\}$ 中的坐标向量。若 $\mathbf{w}_i$ 与 $\mathbf{w}_j (i \neq j)$ 正交，则新坐标系是一个正交坐标系，此时 $\mathbf{W}$ 为正交变换。显然，新空间中的属性是原空间中的属性的线性组合。
- 基于线性变换来进行降维的方法称为线性降维方法，对低维子空间性质的不同要求可通过对 $\mathbf{W}$ 施加不同的约束来实现。

线性降维方法






每个图片是 $28*28=784$ 像素，如果用像素点来描述的话确实需要784维。

但是换一种思路，上面的一堆3的图片，只需要用三个维度（水平平移、垂直平移、旋转角度）来描述。

线性降维方法

将3D数据降维成2D数据



主成分分析(Principal Component Analysis, PCA)

- 对于正交属性空间中的样本点，如何用一个超平面（子空间）对所有样本进行恰当的表达？
- 容易想到，若存在这样的超平面，那么它大概应具有这样的性质：
 - 最近重构性：样本点到这个超平面的距离都足够近；
 - 最大可分性：样本点在这个超平面上的投影能尽可能分开。
- 基于最近重构性和最大可分性，能分别得到主成分分析的两种等价推导。

最大可分性

Taking a picture



最大可分性

Taking a picture



最大可分性

Taking a picture



最大可分性

Taking a picture



PCA


所有样本点的投影能尽可能分开，则应该使得投影后样本点的方差最大化。

$$\begin{aligned} \max_{\mathbf{w}_1} \quad & \frac{1}{2m} \sum_{i=1}^m (\mathbf{w}_1^T \mathbf{x}_i - \mathbf{w}_1^T \bar{\mathbf{x}})^2 = \mathbf{w}_1^T \mathbf{S} \mathbf{w}_1 \\ \text{s.t.} \quad & \|\mathbf{w}_1\| = 1 \end{aligned}$$

$\mathbf{S}$ 为样本的协方差矩阵， $\bar{\mathbf{x}}$ 为样本的均值

$$\bar{\mathbf{x}} = \frac{1}{m} \sum_{i=1}^m \mathbf{x}_i$$

$$\mathbf{S} = \frac{1}{m} \sum_{i=1}^m (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^T$$



PCA

求解 w_1 :

$$\begin{aligned} \max_{w_1} \quad & \frac{1}{2m} \sum_{i=1}^m (w_1^T x_i - w_1^T \bar{x})^2 = w_1^T S w_1 \\ \text{s.t.} \quad & \|w_1\| = 1 \end{aligned}$$

拉格朗日乘子法: $w_1^T S w_1 + \alpha_1(1 - w_1^T w_1)$, 对其关于 w_1 求导并等于0, 得到

$$S w_1 = \alpha_1 w_1$$

- 因此, w_1 是 S 的特征向量, 且对应特征值为 α_1 。
- 事实上, 由目标函数可得, w_1 为 S 中最大特征值对应的特征向量。

PCA

同理求解 w_2 :

$$\begin{aligned} \max_{w_2} \quad & w_2^T S w_2 \\ \text{s.t.} \quad & \|w_2\| = 1 \\ & w_2^T w_1 = 0 \end{aligned}$$

拉格朗日乘子法: $w_2^T S w_2 + \alpha_2(1 - w_2^T w_2) + 2\beta w_2^T w_1$, 对其关于 w_2 求导并等于0, 得到

$$S w_2 - \alpha_2 w_2 + \beta w_1 = 0$$

$$\longrightarrow w_1^T S w_2 - \alpha_2 w_1^T w_2 + \beta w_1^T w_1 = 0$$

$$\longrightarrow \alpha_1 w_1^T w_2 - \alpha_2 w_1^T w_2 + \beta w_1^T w_1 = 0$$

$$\longrightarrow \beta = 0$$

PCA

同理求解 w_2 :

$$\begin{aligned} \max_{w_2} \quad & w_2^T S w_2 \\ \text{s.t.} \quad & \|w_2\| = 1 \\ & w_2^T w_1 = 0 \end{aligned}$$

拉格朗日乘子法: $w_2^T S w_2 + \alpha_2(1 - w_2^T w_2) + 2\beta w_2^T w_1$, 对其关于 w_2 求导并等于0, 得到

$$S w_2 - \alpha_2 w_2 + \beta w_1 = 0$$

$$\longrightarrow S w_2 = \alpha_2 w_2$$

- 因此, w_2 是 S 中第二大特征值对应的特征向量。


PCA

依次进行下去，可计算出 S 的前 d' 个特征向量 $w_1, w_2, \dots, w_{d'}$
即线性降维中的变换矩阵

$$W = [w_1, w_2, \dots, w_{d'}]$$

□ 怎么选取 d'

$$\frac{\sum_{i=1}^{d'} \alpha_i}{\sum_{i=1}^d \alpha_i} \geq t$$



最近重构性

- 对样本进行中心化, $\sum_i \mathbf{x}_i = 0$, 再假定投影变换后得到的新坐标系为 $\{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_d\}$, 其中 $\mathbf{w}_i$ 是标准正交基向量,

$$\|\mathbf{w}_i\|_2 = 1, \mathbf{w}_i^T \mathbf{w}_j = 0 (i \neq j).$$

- 若丢弃新坐标系中的部分坐标, 即将维度降低到 $d' < d$, 则样本点 $\mathbf{x}_i$ 在低维坐标系中的投影是 $\mathbf{z}_i = (z_{i1}; z_{i2}; \dots; z_{id'})$, $z_{ij} = \mathbf{w}_j^T \mathbf{x}_i$ 是 $\mathbf{x}_i$ 在低维坐标下第 j 维的坐标, 若基于 $\mathbf{z}_i$ 来重构 $\mathbf{x}_i$, 则会得到

$$\hat{\mathbf{x}}_i = \sum_{j=1}^{d'} z_{ij} \mathbf{w}_j.$$

最近重构性

□ 考虑整个训练集，原样本点 $\mathbf{x}_i$ 与基于投影重构的样本点 $\hat{\mathbf{x}}_i$ 之间的距离为

$$\sum_{i=1}^m \left\| \sum_{j=1}^{d'} z_{ij} \mathbf{w}_j - \mathbf{x}_i \right\|_2^2 = \sum_{i=1}^m \mathbf{z}_i^T \mathbf{z}_i - 2 \sum_{i=1}^m \mathbf{z}_i^T \mathbf{W}^T \mathbf{x}_i + \text{const}$$
$$\propto -\text{tr} \left(\mathbf{W}^T \left(\sum_{i=1}^m \mathbf{x}_i \mathbf{x}_i^T \right) \mathbf{W} \right).$$

□ 根据最近重构性应最小化上式。考虑到 $\mathbf{w}_j$ 是标准正交基, $\sum_i \mathbf{x}_i \mathbf{x}_i^T$

是协方差矩阵，有

$$\min_{\mathbf{W}} \quad -\text{tr}(\mathbf{W}^T \mathbf{X} \mathbf{X}^T \mathbf{W})$$

s.t. $\mathbf{W}^T \mathbf{W} = \mathbf{I}.$

这就是主成分分析的优化目标。

$$\begin{aligned} \min_{\mathbf{W}} \quad & -\text{tr}(\mathbf{W}^T \mathbf{X} \mathbf{X}^T \mathbf{W}) \\ \text{s.t.} \quad & \mathbf{W}^T \mathbf{W} = \mathbf{I}. \end{aligned}$$

□ 对优化式使用拉格朗日乘子法可得

$$\mathbf{X} \mathbf{X}^T \mathbf{w} = \lambda_i \mathbf{w}$$

只需对协方差矩阵 $\mathbf{X} \mathbf{X}^T$ 进行特征值分解，并将求得的特征值排序： $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_d$ ，再取前 d' 个特征值对应的特征向量构成 $\mathbf{W}^* = (\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_{d'})$ ，这就是主成分分析的解。

PCA算法

输入：样本集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$;
低维空间维数 d' .

过程：

- 1: 对所有样本进行中心化: $\mathbf{x}_i \leftarrow \mathbf{x}_i - \frac{1}{m} \sum_{i=1}^m \mathbf{x}_i$;
- 2: 计算样本的协方差矩阵 $\mathbf{X}\mathbf{X}^T$;
- 3: 对协方差矩阵 $\mathbf{X}\mathbf{X}^T$ 做特征值分解;
- 4: 取最大的 d' 个特征值所对应的特征向量 $\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_{d'}$.

输出：投影矩阵 $\mathbf{W} = (\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_{d'})$.

图 10.5 PCA 算法

PCA

$$x_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, x_2 = \begin{bmatrix} 1 \\ 3 \end{bmatrix}, x_3 = \begin{bmatrix} 2 \\ 3 \end{bmatrix}, x_4 = \begin{bmatrix} 4 \\ 4 \end{bmatrix}, x_5 = \begin{bmatrix} 2 \\ 4 \end{bmatrix}$$

$$X = \begin{bmatrix} 1 & 1 & 2 & 4 & 2 \\ 1 & 3 & 3 & 4 & 4 \end{bmatrix}$$




$$\begin{aligned} Y &= (1/\sqrt{2} \quad 1/\sqrt{2}) \begin{pmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{pmatrix} \\ &= (-3/\sqrt{2} \quad -1/\sqrt{2} \quad 0 \quad 3/\sqrt{2} \quad -1/\sqrt{2}) \end{aligned}$$

Wine葡萄酒数据集：178*14，第一列是1,2,3包括三类酒（标记），后面13列式不同成分（属性）

属性	属性描述	属性类型
Class	类别	离散
Alcohol	酒精	连续
Malic acid	苹果酸	连续
Ash	灰	连续
Alcalinity of ash	灰分的碱度	连续
Magnesium	镁	连续
Total phenols	总酚	连续
Flavanoids	黄酮类化合物	连续
Noflavanoid phenols	非黄烷类酚类	连续
Proanthocyanins	原花色素	连续
Color intensity	颜色强度	连续
Hue	色调	连续
OD280/OD315ofdiluted wines	稀释葡萄酒的OD280/OD315	连续
Proline	脯氨酸	连续

Wine葡萄酒数据集：178*14，第一列是1,2,3包括三类酒（标记），后面13列式不同成分（属性）




```
wine.data - 记事本
文件(F) 编辑(E) 格式(O) 查看(V) 帮助(H)
1,14.23,1.71,2.43,15.6,127,2.8,3.06,,28,2.29,5.64,1.04,3.92,1065
1,13.2,1.78,2.14,11.2,100,2.65,2.76,,26,1.28,4.38,1.05,3.4,1050
1,13.16,2.36,2.67,18.6,101,2.8,3.24,,3,2.81,5.68,1.03,3.17,1185
1,14.37,1.95,2.5,16.8,113,3.85,3.49,,24,2.18,7.8,,86,3.45,1480
1,13.24,2.59,2.87,21,118,2.8,2.69,,39,1.82,4.32,1.04,2.93,735
1,14.2,1.76,2.45,15.2,112,3.27,3.39,,34,1.97,6.75,1.05,2.85,1450
1,14.39,1.87,2.45,14.6,96,2.5,2.52,,3,1.98,5.25,1.02,3.58,1290
1,14.06,2.15,2.61,17.6,121,2.6,2.51,,31,1.25,5.05,1.06,3.58,1295
1,14.83,1.64,2.17,14.97,2.8,2.98,,29,1.98,5.2,1.08,2.85,1045
1,13.86,1.35,2.27,16.98,2.98,3.15,,22,1.85,7.22,1.01,3.55,1045
1,14.1,2.16,2.3,18,105,2.95,3.32,,22,2.38,5.75,1.25,3.17,1510
1,14.12,1.48,2.32,16.8,95,2.2,2.43,,26,1.57,5,1.17,2.82,1280
1,13.75,1.73,2.41,16.89,2.6,2.76,,29,1.81,5.6,1.15,2.9,1320
1,14.75,1.73,2.39,11.4,91,3.1,3.69,,43,2.81,5.4,1.25,2.73,1150
1,14.38,1.87,2.38,12,102,3.3,3.64,,29,2.96,7.5,1.2,3,1547
1,13.63,1.81,2.7,17.2,112,2.85,2.91,,3,1.46,7.3,1.28,2.88,1310
1,14.3,1.92,2.72,20,120,2.8,3.14,,33,1.97,6.2,1.07,2.65,1280
1,13.83,1.57,2.62,20,115,2.95,3.4,,4,1.72,6.6,1.13,2.57,1130
1,14.19,1.59,2.48,16.5,108,3.3,3.93,,32,1.86,8.7,1.23,2.82,1680
1,13.64,3.1,2.56,15.2,116,2.7,3.03,,17,1.66,5.1,,96,3.36,845
1,14.06,1.63,2.28,16,126,3.3,3.17,,24,2.1,5.65,1.09,3.71,780
1,12.93,3.8,2.65,18.6,102,2.41,2.41,,25,1.98,4.5,1.03,3.52,770
1,13.71,1.86,2.36,16.6,101,2.61,2.88,,27,1.69,3.8,1.11,4,1035
1,12.85,1.6,2.52,17.8,95,2.48,2.37,,26,1.46,3.93,1.09,3.63,1015
```

PCA


Wine葡萄酒数据集：178*14，第一列是1,2,3包括三类酒（标记），后面13列式不同成分（属性）

主成分方差比率：

$$\frac{\lambda_j}{\sum_{j=1}^d \lambda_j}$$




PCA




PCA

PCA用于图像压缩：用部分基底向量的线性组合表示目标向量



PCA

PCA用于图像压缩：用部分基底向量的线性组合表示目标向量




321x481 image, D is the number of basis vectors used


PCA用于人脸识别: Eigenfaces

- *Goal:*
Face recognition by similarity in principal subspace
- Learn the PCA projection on train set of 319x242 face images
- Reparameterize a query picture to a basis of "eigenfaces"
- Eigenvectors of the data covariance matrix can be rearranged into a 2D image --> has the appearance of a ghostly face

PCA用于人脸识别：Eigenfaces





PCA用于人脸识别：Eigenfaces



PCA

Top eigenvectors: $u_1, \dots, u_k$



Mean: μ



$$\hat{x} = \mu + w_1 u_1 + w_2 u_2 + w_3 u_3 + w_4 u_4 + \dots$$

PCA

PCA可视化MNIST数字





PCA与LDA比较

相同点：

1. 均是线性降维
2. 均使用矩阵特征值分解的思想


不同点：

1. LDA是有监督降维方法，而PCA是无监督降维方法
2. LDA降维最多降到类别数减1的维数，而PCA没有这个限制
3. LDA选择分类性能最好的投影方向，而PCA选择样本点投影具有最大方差的方向。




核化线性降维


- 线性降维方法假设从高维空间到低维空间的函数映射是线性的，然而，在不少现实任务中，可能需要非线性映射才能找到恰当的低维嵌入：



(a) 三维空间中的观察



(b) 本真二维结构



(c) PCA 降维结果

图 10.6 三维空间中观察到的 3000 个样本点，是从本真二维空间中矩形区域采样后以 S 形曲面嵌入，此情形下线性降维会丢失低维结构。图中数据点的染色显示出低维空间的结构。

Kernel PCA

核化主成分分析 (Kernelized PCA, 简称KPCA)

□ 非线性降维的一种常用方法，是基于核技巧对线性降维方法进行“核化” (kernelized)。

□ 假定 $\mathbf{z}_i$ 是由原始属性空间中的样本点 $\mathbf{x}_i$ 通过映射 ϕ 产生，即

$$\mathbf{z}_i = \phi(\mathbf{x}_i), i = 1, 2, \dots, m.$$

□ 假定我们将在高维特征空间中把数据投影到由 $\mathbf{W} = (\mathbf{w}_1, \dots, \mathbf{w}_d)$ 确定的超平面上，则对于 $\mathbf{w}_j$ ，有

$$\left(\sum_{i=1}^m \mathbf{z}_i \mathbf{z}_i^T \right) \mathbf{w}_j = \lambda_j \mathbf{w}_j$$

Kernel PCA

- 假定我们将在高维特征空间中把数据投影到由 $\mathbf{W} = (\mathbf{w}_1, \dots, \mathbf{w}_d)$ 确定的超平面上，则对于 $\mathbf{w}_j$ ，有

$$\left(\sum_{i=1}^m \mathbf{z}_i \mathbf{z}_i^T \right) \mathbf{w}_j = \lambda_j \mathbf{w}_j$$

- 令 $\alpha_i^j = \frac{1}{\lambda_j} \mathbf{z}_i^T \mathbf{w}_j$ ，

$$\mathbf{w}_j = \frac{1}{\lambda_j} \left(\sum_{i=1}^m \mathbf{z}_i \mathbf{z}_i^T \right) \mathbf{w}_j = \sum_{i=1}^m \mathbf{z}_i \frac{\mathbf{z}_i^T \mathbf{w}_j}{\lambda_j} = \sum_{i=1}^m \mathbf{z}_i \alpha_i^j.$$

Kernel PCA

□ 若 ϕ 能被显式表达出来，则通过它将样本映射至高维空间，再在特征空间中实施PCA即可，即有

$$\left(\sum_{i=1}^m \phi(\mathbf{x}_i) \phi(\mathbf{x}_i)^T \right) \mathbf{w}_j = \lambda_j \mathbf{w}_j$$

并且

$$\mathbf{w}_j = \sum_{i=1}^m \phi(\mathbf{x}_i) \alpha_i^j.$$

$$\alpha_i^j = \frac{1}{\lambda_j} \phi(\mathbf{x}_i)^T \mathbf{w}_j$$

Kernel PCA

- 一般情形下，我们不清楚 ϕ 的具体形式，于是引入核函数

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j).$$

- 又由 $\mathbf{w}_j = \sum_{i=1}^m \phi(\mathbf{x}_i) \alpha_i^j$ ，代入优化式 $\left(\sum_{i=1}^m \phi(\mathbf{x}_i) \phi(\mathbf{x}_i)^\top \right) \mathbf{w}_j = \lambda_j \mathbf{w}_j$ ，有

$$\mathbf{K} \boldsymbol{\alpha}^j = \lambda_j \boldsymbol{\alpha}^j.$$

其中 $\mathbf{K}$ 为 κ 对应的核矩阵， $(\mathbf{K})_{ij} = \kappa(\mathbf{x}_i, \mathbf{x}_j)$ ， $\boldsymbol{\alpha}^j = (\alpha_1^j; \dots; \alpha_m^j)$ 。

- 上式为特征值分解问题，取 $\mathbf{K}$ 最大的 d' 个特征值对应的特征向量得到解。


Kernel PCA

□ 对新样本 $\mathbf{x}$ ，其投影后的第 j ($j = 1, 2, \dots, d'$) 维坐标为


$$\begin{aligned} z_j &= \mathbf{w}_j^T \phi(\mathbf{x}) = \sum_{i=1}^m \alpha_i^j \phi(\mathbf{x}_i)^T \phi(\mathbf{x}) \\ &= \sum_{i=1}^m \alpha_i^j \kappa(\mathbf{x}_i, \mathbf{x}). \end{aligned}$$

其中 α_i 已经过规范化。由该式可知，为获得投影后的坐标，KPCA需对所有样本求和，因此它的计算开销较大。

Kernel PCA




(a)



(b)

Kernel PCA with radial basis functional (RBF) kernel

Kernel PCA



哪个是第一个主成分呢？

小结

- **PCA**: 最大可分性和最近重构性等价推导出PCA
- **Kernel PCA**: 处理具有非线性结构的数据