

机器学习

Machine Learning

肖力

信息科学技术学院—6系

<https://faculty.ustc.edu.cn/xiaoli>

流形学习

大纲


- 多维缩放MDS
- 等度量映射Isomap (发表在*Science*, 2000)
- 局部线性嵌入LLE (发表在*Science*, 2000)

流形 (Manifold)

在数学中，**流形**（英语：manifold）是可以“局部欧几里得空间化”的一个拓扑空间，即在此拓扑空间中，每个点附近“局部类似于欧氏空间”。更精确地说，**n维流形**（ n -manifold），简称**n流形**，是一个拓扑空间，其性质是每个点都有一个邻域同胚于 n 维欧氏空间的一个开集。


流形是欧几里得空间中的曲线、曲面等概念的推广。欧几里得空间就是最简单的流形的实例。地球表面这样的球面则是一个稍微复杂的例子。一般的流形可以通过把许多平直的片折弯并粘连而成。

Examples of 1-manifolds and 2-manifolds



流形 (Manifold)

下图是三维空间中的一个流形，观察到的数据是三维的，但其本质是一个二维流形，因为曲面是二维的。虽然数据是三维的，但真正表征这个数据的核心特征只有二维，其余维度都是冗余的。所以，高维数据其实是低维流形结构嵌入在高维空间中的表现，这个低维流形结构就是我们需要提取的重要特征。



流形学习



流形学习

- 流形学习(manifold learning)是一类借鉴了拓扑流形概念的降维方法。“流形”是在局部与欧氏空间同胚的空间，换言之，它在局部具有欧氏空间的性质，能用欧氏距离来进行距离计算。
- 若低维流形嵌入到高维空间中，则数据样本在高维空间的分布虽然看上去非常复杂，但在局部上仍具有欧氏空间的性质，因此，可以容易地在局部建立降维映射关系，然后再设法将局部映射关系推广到全局。
- 当维数被降至二维或三维时，能对数据进行可视化展示，因此流形学习也可被用于可视化。

多维缩放MDS

□ 若要求原始空间中样本之间的距离在低维空间中得以保持，即得到“多维缩放” (Multiple Dimensional Scaling, MDS):

□ 假定有 m 个样本，在原始空间中的距离矩阵为 $\mathbf{D} \in \mathbb{R}^{m \times m}$ ，其第 i 行 j 列的元素 $dist_{ij}$ 为样本 $\mathbf{x}_i$ 到 $\mathbf{x}_j$ 的距离。

□ 目标是获得样本在 d' 维空间中的表示，且任意两个样本在 d' 维空间中的欧氏距离等于原始空间中的距离，
$$\|\mathbf{z}_i - \mathbf{z}_j\| = dist_{ij}.$$

□ 令 $\mathbf{B} = \mathbf{Z}^T \mathbf{Z} \in \mathbb{R}^{m \times m}$ ，其中 $\mathbf{B}$ 为降维后的内积矩阵， $b_{ij} = \mathbf{z}_i^T \mathbf{z}_j$ ，有

$$\begin{aligned} dist_{ij}^2 &= \|\mathbf{z}_i\|^2 + \|\mathbf{z}_j\|^2 - 2\mathbf{z}_i^T \mathbf{z}_j \\ &= b_{ii} + b_{jj} - 2b_{ij}. \end{aligned}$$




图 10.2 低维嵌入示意图

多维缩放MDS

□ 为便于讨论，令降维后的样本 $\mathbf{Z}$ 被中心化，即 $\sum_{i=1}^m \mathbf{z}_i = \mathbf{0}$ 。显然，矩阵 $\mathbf{B}$ 的行与列之和均为零，即

$$\sum_{i=1}^m b_{ij} = \sum_{j=1}^m b_{ij} = 0.$$

易知 $\sum_{i=1}^m dist_{ij}^2 = \text{tr}(\mathbf{B}) + mb_{jj}$, $\sum_{j=1}^m dist_{ij}^2 = \text{tr}(\mathbf{B}) + mb_{ii}$, $\sum_{i=1}^m \sum_{j=1}^m dist_{ij}^2 = 2m \text{tr}(\mathbf{B})$,

其中 $\text{tr}(\cdot)$ 表示矩阵的迹(trace), $\text{tr}(\mathbf{B}) = \sum_{i=1}^m \|\mathbf{z}_i\|^2$ 。令

$$dist_{i.}^2 = \frac{1}{m} \sum_{j=1}^m dist_{ij}^2 \quad dist_{.j}^2 = \frac{1}{m} \sum_{i=1}^m dist_{ij}^2 \quad dist_{..}^2 = \frac{1}{m^2} \sum_{i=1}^m \sum_{j=1}^m dist_{ij}^2$$

由此即可通过降维前后保持不变的距离矩阵 $\mathbf{D}$ 求取内积矩阵 $\mathbf{B}$:

$$b_{ij} = -\frac{1}{2}(dist_{ij}^2 - dist_{i.}^2 - dist_{.j}^2 + dist_{..}^2).$$

多维缩放MDS

□ 对矩阵 $\mathbf{B}$ 做特征值分解 $\mathbf{B} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^T$, 其中 $\mathbf{\Lambda} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_d)$ 为特征值构成的对角矩阵, $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$

$\mathbf{V}$ 为特征向量矩阵, 假定其中有 d^* 个非零特征值, 它们构成对角矩阵 $\mathbf{\Lambda}_* = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_{d^*})$, 令 $\mathbf{V}_*$ 表示相应的特征向量矩阵, 则 $\mathbf{Z}$ 可表达为 $\mathbf{Z} = \mathbf{\Lambda}_*^{1/2} \mathbf{V}_*^T \in \mathbb{R}^{d^* \times m}$ 。

□ 在现实应用中为了有效降维, 往往仅需降维后的距离与原始空间中的距离尽可能接近, 而不必严格相等。此时可取 $d' \ll d$ 个最大特征值构成对角矩阵 $\tilde{\mathbf{\Lambda}} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_{d'})$, 令 $\tilde{\mathbf{V}}$ 表示相应的特征向量矩阵, 则 $\mathbf{Z}$ 可表达为

$$\mathbf{Z} = \tilde{\mathbf{\Lambda}}^{1/2} \tilde{\mathbf{V}}^T \in \mathbb{R}^{d' \times m}.$$

多维缩放MDS

MDS算法的描述

输入： 距离矩阵 $\mathbf{D} \in \mathbb{R}^{m \times m}$, 其元素 $dist_{ij}$ 为样本 $\mathbf{x}_i$ 到 $\mathbf{x}_j$ 的距离;
低维空间维数 d' .

过程：


- 1: 根据式(10.7)–(10.9)计算 $dist_{i.}^2, dist_{.j}^2, dist_{..}^2$;
- 2: 根据式(10.10)计算矩阵 $\mathbf{B}$;
- 3: 对矩阵 $\mathbf{B}$ 做特征值分解;
- 4: 取 $\tilde{\mathbf{\Lambda}}$ 为 d' 个最大特征值所构成的对角矩阵, $\tilde{\mathbf{V}}$ 为相应的特征向量矩阵.

输出： 矩阵 $\tilde{\mathbf{V}}\tilde{\mathbf{\Lambda}}^{1/2} \in \mathbb{R}^{m \times d'}$, 每行是一个样本的低维坐标

图 10.3 MDS 算法

等度量映射Isomap

- 低维流形嵌入到高维空间之后，直接在高维空间中计算直线距离具有误导性，因为高维空间中的直线距离在低维嵌入流形上不可达。而低维嵌入流形上两点间的本真距离是“测地线” (geodesic) 距离。
- 两个点的测地线距离为它们在所在流形上的最短路径距离。




(a) 测地线距离与高维直线距离

等度量映射Isomap

□ 测地线距离的计算：利用流形在局部上与欧氏空间同胚这个性质，对每个点基于欧氏距离找出其近邻点，然后就能建立一个近邻连接图，图中近邻点之间存在连接，而非近邻点之间不存在连接，于是，计算两点之间测地线距离的问题，就转变为计算近邻连接图上两点之间的最短路径问题。

□ 最短路径的计算可通过Dijkstra算法或Floyd算法实现。得到距离后可通过多维缩放方法获得样本点在低维空间中的坐标。





(b) 测地线距离与近邻距离

等度量映射Isomap

□ 近邻图的构建通常有两种做法：

- 指定近邻点个数，例如欧氏距离最近的 k 个点为近邻点，这样得到的近邻图称为 k 近邻图；
- 指定距离阈值 ϵ ，距离小于 ϵ 的点被认为是近邻点，这样得到的近邻图称为 ϵ 近邻图。



等度量映射Isomap

Isomap算法的描述

输入: 样本集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$;

近邻参数 k ;

低维空间维数 d' .

过程:

1: **for** $i = 1, 2, \dots, m$ **do**

2: 确定 $\mathbf{x}_i$ 的 k 近邻;

3: $\mathbf{x}_i$ 与 k 近邻点之间的距离设置为欧氏距离, 与其他点的距离设置为无穷大;

4: **end for**

5: 调用最短路径算法计算任意两样本点之间的距离 $\text{dist}(\mathbf{x}_i, \mathbf{x}_j)$;


6: 将 $\text{dist}(\mathbf{x}_i, \mathbf{x}_j)$ 作为 MDS 算法的输入;

7: **return** MDS 算法的输出


输出: 样本集 D 在低维空间的投影 $Z = \{\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_m\}$.

图 10.8 Isomap 算法

等度量映射 Isomap



等度量映射Isomap



等度量映射Isomap

□ 总结：PCA和Isomap均为MDS的特例。

- MDS + Euclidean distance: PCA
- MDS + geodesic distance: ISOMap


局部线性嵌入LLE

□ 局部线性嵌入试图保持邻域内的线性关系，并使得该线性关系在降维后的空间中继续保持。

$$\min_{w_1, w_2, \dots, w_m} \sum_{i=1}^m \left\| \mathbf{x}_i - \sum_{j \in Q_i} w_{ij} \mathbf{x}_j \right\|_2^2$$



$$\min_{z_1, z_2, \dots, z_m} \sum_{i=1}^m \left\| \mathbf{z}_i - \sum_{j \in Q_i} w_{ij} \mathbf{z}_j \right\|_2^2$$



局部线性嵌入LLE

□ LLE先为每个样本 $\mathbf{x}_i$ 找到其近邻下标集合 Q_i ，然后计算出基于 Q_i 中的样本点对 $\mathbf{x}_i$ 进行线性重构的系数 $\mathbf{w}_i$ ：

$$\begin{aligned} \min_{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_m} \sum_{i=1}^m \left\| \mathbf{x}_i - \sum_{j \in Q_i} w_{ij} \mathbf{x}_j \right\|_2^2 \\ \text{s.t. } \sum_{j \in Q_i} w_{ij} = 1, \end{aligned}$$

其中 $\mathbf{x}_i$ 和 $\mathbf{x}_j$ 均为已知，令 $C_{jk} = (\mathbf{x}_i - \mathbf{x}_j)^T (\mathbf{x}_i - \mathbf{x}_k)$ ， w_{ij} 有闭式解

$$w_{ij} = \frac{\sum_{k \in Q_i} C_{jk}^{-1}}{\sum_{l, s \in Q_i} C_{ls}^{-1}}.$$

局部线性嵌入LLE

- LLE在低维空间中保持 $\mathbf{w}_i$ 不变, 于是 $\mathbf{x}_i$ 对应的低维空间坐标 $\mathbf{z}_i$ 可通过下式求解:

$$\min_{\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_m} \sum_{i=1}^m \left\| \mathbf{z}_i - \sum_{j \in Q_i} w_{ij} \mathbf{z}_j \right\|_2^2$$

- 令 $\mathbf{Z} = (\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_m) \in \mathbb{R}^{d' \times m}$, $(\mathbf{W})_{ij} = w_{ij}$,

$$\mathbf{M} = (\mathbf{I} - \mathbf{W})^T (\mathbf{I} - \mathbf{W}),$$

- 则优化式可重写为右式,

$$\begin{aligned} \min_{\mathbf{Z}} \operatorname{tr}(\mathbf{Z}\mathbf{M}\mathbf{Z}^T) \\ \text{s.t. } \mathbf{Z}\mathbf{Z}^T = \mathbf{I}. \end{aligned}$$

并通过特征值分解求解。 $\mathbf{M}$ 最小的 d' 个特征值对应的特征向量组成 $\mathbf{Z}^T$

局部线性嵌入LLE

LLE算法的描述

输入: 样本集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$;

近邻参数 k ;

低维空间维数 d' .

过程:

1: **for** $i = 1, 2, \dots, m$ **do**

2: 确定 $\mathbf{x}_i$ 的 k 近邻;

3: 从式(10.27)求得 $w_{ij}, j \in Q_i$;

4: 对于 $j \notin Q_i$, 令 $w_{ij} = 0$;

5: **end for**

6: 从式(10.30)得到 $\mathbf{M}$;


7: 对 $\mathbf{M}$ 进行特征值分解;

8: **return** $\mathbf{M}$ 的最小 d' 个特征值对应的特征向量

输出: 样本集 D 在低维空间的投影 $Z = \{\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_m\}$.

图 10.10 LLE 算法

局部线性嵌入LLE




局部线性嵌入LLE


A selection from the 64-dimensional digits dataset

0	1	2	3	4	5	0	1	2	3	4	5	0	1	2	3	4	5	0	1	2	3	4	5
5	5	0	4	1	3	5	1	0	0	2	2	2	0	4	1	2	3	3	3	3	3	3	3
4	4	1	5	0	5	2	2	0	0	1	3	2	1	4	3	1	3	1	3	1	4	4	4
3	4	4	0	5	7	1	5	6	4	2	2	2	5	5	4	6	0	0	1				
2	3	4	5	0	1	2	3	4	5	0	1	2	3	4	5	0	5	5	5				
0	4	4	3	5	1	0	0	2	2	1	0	4	3	3	3	3	4	4					
4	5	0	5	2	1	0	0	1	3	1	4	3	1	3	1	4	3	1	4	3	1	4	4
0	5	7	4	5	4	4	1	2	1	5	5	4	4	0	0	1	2	3	4				
5	0	1	2	3	4	5	0	4	2	3	4	5	0	5	5	5	0	4	1				
3	5	1	0	0	2	2	2	0	4	2	3	3	3	3	4	4	1	5	0				
5	2	2	0	0	4	3	2	1	4	3	1	3	1	4	3	1	4	0	5				
3	1	5	4	4	2	2	2	5	5	4	4	0	3	0	1	2	3	4	5				
0	1	2	3	4	5	0	1	2	3	4	5	0	5	5	5	0	4	1	3				
5	1	0	0	1	2	2	0	1	2	3	3	3	3	4	4	1	5	0	5				
1	2	0	0	1	3	2	1	4	3	1	3	1	4	3	1	4	0	5	3				
4	5	4	4	2	2	5	5	4	4	0	0	1	2	3	4	5	0	1					
2	3	4	5	0	1	2	3	4	5	0	5	5	5	0	4	1	3	5	4				
0	0	1	2	2	0	1	2	3	3	3	3	4	4	1	0	5	2	2					
0	0	1	2	1	1	4	3	1	4	3	1	4	0	5	3	1	5						
4	4	2	2	1	5	5	4	4	0	1	2	3	4	5	0	1	2	3					


Isomap projection of the digits (time 1.13s)




MDS embedding of the digits (time 2.78s)



Locally Linear Embedding of the digits (time 0.42s)



局部线性嵌入LLE



小结

- 流形
- 流形学习
- 多维缩放
- 等度量映射
- 局部线性嵌入