

机器学习

Machine Learning

肖力

信息科学技术学院—6系

<https://faculty.ustc.edu.cn/xiaoli>

字典学习

字典学习

为普通稠密表达的样本找到合适的字典，将样本转化为稀疏表示，这一过程称为字典学习

- 给定数据集 $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$, $\mathbf{x}_i \in \mathbb{R}^d$
- 学习目标是字典矩阵 $\mathbf{B} \in \mathbb{R}^{d \times k}$ 以及样本的稀疏表示 $\boldsymbol{\alpha}_i \in \mathbb{R}^k$
- k 称为字典的词汇量，通常由用户指定
- 则最简单的字典学习的优化形式为

$$\min_{\mathbf{B}, \boldsymbol{\alpha}_i} \sum_{i=1}^m \|\mathbf{x}_i - \mathbf{B}\boldsymbol{\alpha}_i\|_2^2 + \lambda \sum_{i=1}^m \|\boldsymbol{\alpha}_i\|_1$$


字典学习

$$\min_{\mathbf{B}, \boldsymbol{\alpha}_i} \sum_{i=1}^m \|\mathbf{x}_i - \mathbf{B}\boldsymbol{\alpha}_i\|_2^2 + \lambda \sum_{i=1}^m \|\boldsymbol{\alpha}_i\|_1$$

- 字典矩阵 $\mathbf{B} = [\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_k] \in \mathbb{R}^{d \times k}$ 和 $\boldsymbol{\alpha}_i \in \mathbb{R}^k$ 可同时缩放, 所以需要增加额外限制 $\|\mathbf{b}_i\| \leq 1, i = 1, 2, \dots, k$
- 目的是寻找一组“超完备”基向量组或字典 ($k > d$) 来更高效地表示数据样本
- 系数 $\boldsymbol{\alpha}_i$ 不再唯一, 故需增加额外的稀疏性正则项来解决此退化问题。

字典学习

以空间维度换取表征效率：以够大的线性相关组来构造字典；
以其中少部分原子的线性组合表征某个具体的样本。



字典学习的解法(1)

- 固定字典 $\mathbf{B}$, 参考LASSO的方法求解

$$\min_{\alpha_i} \|\mathbf{x}_i - \mathbf{B}\alpha_i\|_2^2 + \lambda \|\alpha_i\|_1 .$$

- 以 α_i 为初值求解字典 $\mathbf{B}$,

$$\min_{\mathbf{B}} \|\mathbf{X} - \mathbf{B}\mathbf{A}\|_F^2,$$

$\|\cdot\|_F$ 是矩阵的Frobenius 范数

- 基于逐列更新策略的KSVD [Aharon et al., 2006]

$$\min_{\mathbf{b}_i} \left\| \mathbf{X} - \sum_{j=1}^k \mathbf{b}_j \alpha^j \right\|_F^2$$

表示矩阵 $\mathbf{X}$ 的第 i 列, α^i 表示矩阵 $\mathbf{A}$ 的第 i 行

字典学习的解法(2)

- 上式可以变化为

$$\min_{b_i} \left\| \left(\mathbf{X} - \sum_{j \neq i} b_j \alpha^j \right) - b_i \alpha^i \right\|_F^2 = \min_{b_i} \left\| \mathbf{E}_i - b_i \alpha^i \right\|_F^2 .$$

- 对 $\mathbf{E}_i$ 进行奇异值分解，取得最大奇异值对应的正交向量

为了不破坏稀疏性， α^i 仅保留非零元素， $\mathbf{E}_i$ 仅保留 b_i 与 α^i 非零元素的乘积项

- 反复迭代以获得最优解

字典学习

$$\min_{\mathbf{D}, \mathbf{X}} \|\mathbf{Y} - \mathbf{DX}\|_F^2 + \lambda \|\mathbf{x}_i\|_1$$

输入：原始样本，字典，稀疏矩阵

输出：字典，稀疏矩阵


1. 初始化：从原始样本 $\mathbf{Y} \in \mathbf{R}^{m \times n}$ 随机取 K 个列向量或者取它的左奇异矩阵的前 K 个列向量 $\{\mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_K\}$ 作为初始字典的原子，得到字典 $\mathbf{D}^{(0)} \in \mathbf{R}^{m \times K}$ 。令 $j = 0$ ，重复下面步骤2-3，直到达到指定的迭代步数，或收敛到指定的误差：
2. 稀疏编码：利用字典上一步得到的字典 $\mathbf{D}^{(j)}$ ，稀疏编码，得到 $\mathbf{X}^{(j)} \in \mathbf{R}^{K \times n}$ 。
3. 字典更新：逐列更新字典 $\mathbf{D}^{(j)}$ ，字典的列 $\mathbf{d}_k \in \{\mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_K\}$
 - 当更新 $\mathbf{d}_k$ 时，计算误差矩阵 $\mathbf{E}_k$

$$\mathbf{E}_k = \mathbf{Y} - \sum_{j \neq k} \mathbf{d}_j \mathbf{x}_T^j.$$

- 取出稀疏矩阵第 k 个行向量 $\mathbf{x}_T^k$ 不为 0 的索引的集合 $\omega_k = \{i | 1 \leq i \leq n, \mathbf{x}_T^k(i) \neq 0\}$ ， $\mathbf{x}'_T^k = \{\mathbf{x}_T^k(i) | 1 \leq i \leq n, \mathbf{x}_T^k(i) \neq 0\}$
- 从 $\mathbf{E}_k$ 取出对应 ω_k 不为 0 的列，得到 $\mathbf{E}'_k$ 。
- 对 $\mathbf{E}'_k$ 作奇异值分解 $\mathbf{E}_k = \mathbf{U} \Sigma \mathbf{V}^T$ ，取 $\mathbf{U}$ 的第 1 列更新字典的第 k 列，即 $\mathbf{d}_k = \mathbf{U}(\cdot, 1)$ ；令 $\mathbf{x}'_T^k = \Sigma(1, 1) \mathbf{V}(\cdot, 1)^T$ ，得到 $\mathbf{x}'_T^k$ ，将其对应地更新到原 $\mathbf{x}_T^k$ 。
- $j = j + 1$

字典学习

比如下图中，学习了**64**个基向量，然后用这些基向量去表示一个图片，在表示时其实只有**3**个是有值的，其他基向量的共享为**0**。



字典学习

图像去噪：信号可以很好地被字典来表示，而高斯白噪声却不能



$$\underbrace{\mathbf{y}}_{\text{measurements}} = \underbrace{\mathbf{x}_{orig}}_{\text{original image}} + \underbrace{\mathbf{w}}_{\text{noise}}$$

<https://blog.csdn.net/baimafujinji>

字典学习

基于图像去噪原理，字典学习还可用于图像修复

