

机器学习

Machine Learning

肖力

信息科学技术学院—6系

<https://faculty.ustc.edu.cn/xiaoli>

第11章：特征选择

大纲

- 特征子集搜索与评价
- 过滤式特征选择
- 包裹式特征选择
- 嵌入式特征选择与 L_1 正则化


大纲

- 特征子集搜索与评价
- 过滤式特征选择
- 包裹式特征选择
- 嵌入式特征选择与 L_1 正则化

特征

□ 特征/属性

- 描述物体在某方面的表现或性质的可观测量，例如人的身高、体重、性别、年龄...



特征


□ 特征的分类

- 相关特征：对**当前学习任务**有用的属性
- 无关特征：与**当前学习任务**无关的属性
- 冗余特征*：其所包含信息能由其他特征推演出来

注：同个数据集，若学习任务不同，则相关特征很可能不同。因此，特征的“相关”和“无关”均是对当前特定任务而言。

*为简化讨论，本章暂不涉及冗余特征


例子：西瓜的特征



特征选择


□ 特征选择

- 从给定的特征集合中选出**任务相关**特征子集的过程
- 必须确保不丢失重要特征




- ## □ 特征选择是一个重要的“数据预处理”步骤，在现实任务中，获得数据之后通常先进行特征选择，此后再训练学习器

例子：判断是否好瓜时的特征选择



降维--特征选择与特征变换




- 减轻维度灾难，在少量属性上构建模型，从而缓解模型过拟合风险
- 可视化结果

特征选择的一般方法

❑ 遍历所有可能的特征子集

- 计算上遭遇组合爆炸，不可行

❑ 可行方法



两个关键环节：子集搜索和子集评价


子集搜索

- 前向搜索：逐渐增加相关特征
- 后向搜索：从完整的特征集合开始，逐渐减少特征
- 双向搜索：每一轮逐渐增加相关特征，同时减少无关特征

上述策略都基于贪心法去选择包含重要信息的特征子集，搜索中仅仅考虑了使本轮选定集最优，所以得到的是次优的结果。


前向搜索

- 最优子集初始为空集，特征集合初始时包括所有给定特征




后向搜索

- 最优子集初始为完整的特征集合（包括所有给定特征）




子集搜索



由4个属性及在属性子集上的交并运算定义的格


子集搜索

黑色箭头指向该策略每一步选取的属性子集；黄色箭头表示每一步尝试但不成功的搜索方向；



子集搜索

黑色箭头指向该策略每一步选取的属性子集；黄色箭头表示每一步尝试但不成功的搜索方向；



子集评价

□ 特征子集 A 确定了对数据集 D 的一个划分

- A 上的取值将数据集 D 分为 V 份（子集），每一份（子集）用 D^v 表示；每个子集中的样本在 A 上取值相同；
- $\text{Ent}(D^v)$ 表示 D^v 上的信息熵

□ 样本标记 Y 对应着对数据集 D 的真实划分

- $\text{Ent}(D)$ 表示 D 上的信息熵

D 上的信息熵定义为

$$\text{Ent}(D) = - \sum_{k=1}^{|Y|} p_k \log_2 p_k$$

第 k 类样本所占比例为 p_k

特征子集 A 的信息增益为：

$$\text{Gain}(A) = \text{Ent}(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Ent}(D^v)$$

子集评价

- 特征子集确定了对数据集的一个划分
 - 每个划分区域对应着特征子集上的某种取值
- 样本标记对应着对数据集的真实划分

通过估算这两个划分的差异，就能对特征子集进行评价；与样本标记对应的划分的差异越小，则说明当前特征子集越好

- 信息熵仅是判断这个差异的一种途径，其他能判断两个划分差异的机制都能用于特征子集评价。

常见的特征选择方法

将特征子集搜索机制与子集评价机制相结合，即可得到特征选择方法

常见的特征选择方法大致分为如下三类：

- 过滤式 (filter)
- 包裹式 (wrapper)
- 嵌入式 (embedding)


大纲

- 特征子集搜索与评价
- 过滤式特征选择
- 包裹式特征选择
- 嵌入式特征选择与 L_1 正则化

过滤式特征选择

先对数据集进行特征选择，然后用选择的特征来训练模型；特征选择过程与后续学习器无关

Filter式属性选择的一般流程



过滤式特征选择

□ Relief (Relevant Features) 是过滤式特征选择方法的代表

- 为每个初始特征赋予一个“**相关统计量**”，度量特征的重要性
- 特征子集的重要性由子集中每个特征所对应的**相关统计量之和**决定
- 设计一个**阈值**，然后选择比**阈值大**的**相关统计量分量**所对应的特征
- 或者指定欲选取的特征个数，然后选择**相关统计量分量最大**的指定个数特征

如何确定相关统计量？

Relief方法中相关统计量的确定

- 猜中近邻 (near-hit) : x_i 的同类样本中的最近邻 $x_{i,nh}$
- 猜错近邻 (near-miss) : x_i 的异类样本中的最近邻 $x_{i,nm}$

- 相关统计量对应于属性 j 的分量为

$$\delta^j = \sum_i -\text{diff}(x_i^j, x_{i,nh}^j)^2 + \text{diff}(x_i^j, x_{i,nm}^j)^2$$

若 j 为离散型, 则 $x_a^j = x_b^j$ 时
 $\text{diff}(x_a^j, x_b^j) = 0$, 否则为 1 ;
若 j 为连续型, 则
 $\text{diff}(x_a^j, x_b^j) = |x_a^j - x_b^j|$, 注意 x_a^j, x_b^j 已规范化到 $[0,1]$ 区间

- 相关统计量越大, 属性 j 上, 猜中近邻比猜错近邻越近, 即属性 j 对区分同类与异类样本是有益的; 反之, 属性 j 上, 猜中近邻比猜错近邻越远, 则属性 j 对区分同类与异类样本起负面作用。
- 实际上 Relief 只需在数据集的采样上而不必在整个数据集上估计相关统计量。Relief 方法的时间开销随采样次数以及原始特征数线性增长, 运行效率很高

Relief方法的多类拓展

Relief方法是为二分类问题设计的，其扩展变体
Relief-F能处理多分类问题

- 数据集中的样本来自 $|\mathcal{Y}|$ 个类别，其中 $\mathbf{x}_i$ 属于第 k 类
- 猜中近邻：第 k 类中 $\mathbf{x}_i$ 的最近邻 $\mathbf{x}_{i,nh}$
- 猜错近邻：第 k 类之外的每个类中找到一个 $\mathbf{x}_i$ 的最近邻作为猜错近邻，记为 $\mathbf{x}_{i,l,nm} (l = 1, 2, \dots, |\mathcal{Y}|; l \neq k)$
- 相关统计量对应于属性的分量为

p_l 为第 l 类样本
在数据集 D 中
所占的比例

$$\delta^j = \sum_i -\text{diff}(x_i^j, x_{i,nh}^j)^2 + \sum_{l \neq k} \left(p_l \times \text{diff}(x_i^j, x_{i,l,nm}^j)^2 \right)$$

过滤式特征选择

其他常用的几种过滤式特征选择方法

➤ 特征变量自身或特别变量之间的关系

- 方差过滤
- 多重共线性方差膨胀系数

➤ 特征变量与标签变量之间的关系

- 卡方检验
- F检验
- 相关系数
- 互信息

过滤式特征选择

- 卡方检验用于检验两个类别变量之间的相关性。它的零假设是两变量之间不相关。

是否健身	是否受伤						
0	1						
1	0						
1	0						
...	...						
1	1						
0	0						
0	0						

统计观察值 →

	受伤	不受伤	合计	健身率
健身	28	11	39	47%
不健身	12	32	44	53%
合计	40	43	83	
受伤率	48%	52%		

基于受伤率=48%, 不受伤率=52%, 计算理论值 →

	受伤	不受伤	合计	健身率
健身	39*48%=19	39*52%=20	39	47%
不健身	44*48%=21	44*52%=23	44	53%
合计	40	43	83	
受伤率	48%	52%		

$$\chi^2 = \sum \frac{(\text{observed} - \text{expected})^2}{\text{expected}} = \frac{(28 - 19)^2}{19} + \frac{(11 - 20)^2}{20} + \frac{(12 - 21)^2}{21} + \frac{(32 - 23)^2}{23} = 15.69$$

- 互信息衡量两个变量之间相互依赖程度。

$$I(X, Y) = \sum_{y \in Y} \sum_{x \in X} p(x, y) \log\left(\frac{p(x, y)}{p(x)p(y)}\right)$$

当X与Y独立时，互信息为0；当X=Y时，互信息最大。互信息越大，变量相关性越强

大纲

- 特征子集搜索与评价
- 过滤式特征选择
- 包裹式特征选择
- 嵌入式特征选择与 L_1 正则化


包裹式特征选择

包裹式特征选择直接把最终将要使用的学习器的性能作为特征子集的评价准则

- ❑ 包裹式特征选择的目的是为给定学习器选择最有利于其性能、“量身定做”的特征子集
- ❑ 包裹式选择方法直接针对给定学习器进行优化，因此从最终学习器性能来看，包裹式特征选择比过滤式特征选择更好
- ❑ 但另一面，包裹式特征选择过程中需多次训练学习器，计算开销通常比过滤式特征选择大得多

包裹式特征选择

Wrapper式属性选择的一般流程



LVW包裹式特征选择方法

LVW是一个典型的包裹式方法，它在拉斯维加斯方法框架下使用随机策略来进行子集搜索，并以最终分类器的误差作为特征子集评价准则

基本步骤

- 在循环的每一轮随机产生一个特征子集
- 在随机产生的特征子集上通过交叉验证推断当前特征子集的误差
- 进行多次循环，在多个随机产生的特征子集中选择误差最小的特征子集作为最终解*

*若有运行时间限制，则该算法有可能给不出解

LVW包裹式特征选择方法

□ LVW算法伪代码

- 第8行是通过在数据集 D 上，使用交叉验证法来估计学习器在特征子集 A' 上误差；若它比当前特征子集 A^* 上的误差更小，或误差相当但 A' 中包含的特征数量更少，则将 A' 保留。
- 子集搜索采用了随机策略，每次特征子集评价都需训练学习器，计算开销大。

输入：数据集 D ;
特征集 A ;
学习算法 $\mathcal{L}$;
停止条件控制参数 T .

过程:

```
1:  $E = \infty$ ;  
2:  $d = |A|$ ;  
3:  $A^* = A$ ;  
4:  $t = 0$ ;  
5: while  $t < T$  do  
6:   随机产生特征子集  $A'$ ;  
7:    $d' = |A'|$ ;  
8:    $E' = \text{CrossValidation}(\mathcal{L}(D^{A'}))$ ;  
9:   if  $(E' < E) \vee ((E' = E) \wedge (d' < d))$  then  
10:     $t = 0$ ;  
11:     $E = E'$ ;  
12:     $d = d'$ ;  
13:     $A^* = A'$   
14:   else  
15:     $t = t + 1$   
16:   end if  
17: end while  
输出：特征子集  $A^*$ 
```

大纲

- 特征子集搜索与评价
- 过滤式特征选择
- 包裹式特征选择
- 嵌入式特征选择与 L_1 正则化

嵌入式特征选择

□ 回顾线性回归模型，以平方误差为损失函数

$$\min_{\mathbf{w}} \sum_{i=1}^m (y_i - \mathbf{w}^\top \mathbf{x}_i)^2$$

$$\longleftrightarrow \mathbf{w}^* = \arg \min_{\mathbf{w}} (\mathbf{y} - \mathbf{X}\mathbf{w})^T (\mathbf{y} - \mathbf{X}\mathbf{w})$$

令 $E_{\mathbf{w}} = (\mathbf{y} - \mathbf{X}\mathbf{w})^T (\mathbf{y} - \mathbf{X}\mathbf{w})$ ，对 $\mathbf{w}$ 求导可得

$$\frac{\partial E_{\mathbf{w}}}{\partial \mathbf{w}} = 2\mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{y})$$

当 $\mathbf{X}^T \mathbf{X}$ 为满秩时，可得最优解的闭式解为 $\mathbf{w}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$ 。

但现实任务中 $\mathbf{X}^T \mathbf{X}$ 往往不是满秩的，例如当特征数量大于样本数量时，或者特征多重共线性时。此时可解出多个 $\mathbf{w}^*$ ，它们都能使得均方误差最小化。根据归纳偏好，常常加入正则化项来决定学习模型。

嵌入式特征选择

嵌入式特征选择是将特征选择过程与学习器训练过程融为一体，两者在同一个优化过程中完成，在学习器训练过程中自动地进行特征选择

- 考虑最简单的线性回归模型，以平方误差为损失函数，并引入 L_2 范数正则化项防止过拟合，则有

$$\min_{\mathbf{w}} \sum_{i=1}^m (y_i - \mathbf{w}^\top \mathbf{x}_i)^2 + \lambda \|\mathbf{w}\|_2^2$$


岭回归 (ridge regression)
[Tikhonov and Arsenin, 1977]

- 将 L_2 范数替换为 L_1 范数，则有**LASSO** [Tibshirani, 1996]

$$\min_{\mathbf{w}} \sum_{i=1}^m (y_i - \mathbf{w}^\top \mathbf{x}_i)^2 + \lambda \|\mathbf{w}\|_1$$

易获得稀疏解，是一种嵌入式特征选择方法

使用 L_1 范数正则化易获得稀疏解



假设 $\mathbf{x}$ 仅有两个属性，则 $\mathbf{w}$ 有两个分量 w_1 和 w_2 。那么目标优化的解要在平方误差项与正则化项之间折中，即出现在图中平方误差项等值线与正则化等值线相交处。

从图中可以看出，采用 L_1 范数时交点常出现在坐标轴上，即产生 w_1 或者 w_2 为0的稀疏解。

等值线即取值相同的点的连线

L₂正则化问题的求解(1)

$$\min_{\mathbf{w}} \sum_{i=1}^m (y_i - \mathbf{w}^\top \mathbf{x}_i)^2 + \lambda \|\mathbf{w}\|_2^2$$

□ 由于 $\frac{\partial \mathbf{w}^\top \mathbf{w}}{\partial \mathbf{w}} = 2\mathbf{w}$ ，所以令上面目标函数的偏导为0，可得最优解的闭式解为

$$\mathbf{w}^* = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}$$

但是当特征数量很大时候，矩阵求逆运算的时间复杂度还是挺高；所以一般会采用梯度下降的迭代算法去求解上述优化问题。



L₂正则化问题的求解(2)

$$\min_{\mathbf{x}} f(\mathbf{x}) + \lambda \|\mathbf{x}\|_2^2 \triangleq \min_{\mathbf{x}} g(\mathbf{x})$$

梯度下降（Gradient Descend，简称GD）解法：梯度的反方向就是函数下降最快的方向

□ 根据梯度和当前位置更新下一次所在位置，进行反复迭代直至找到最优解

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha \cdot \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}_k} \quad \alpha \text{ 称为为学习率}$$



L_1 正则化问题的求解

$$\min_{\mathbf{x}} f(\mathbf{x}) + \lambda \|\mathbf{x}\|_1$$

近端梯度下降 (Proximal Gradient Descend, 简称PGD) 解法
[Combettes and Wajs, 2005]

□ 假设 ∇f 满足 L -Lipschitz条件, 即存在常数 $L > 0$ 使得


$$\|\nabla f(\mathbf{x}') - \nabla f(\mathbf{x})\| \leq L \|\mathbf{x}' - \mathbf{x}\|$$

□ 每次在 $\mathbf{x}_k$ 的附近寻找最优点, 不断迭代, 即寻找

$$\mathbf{x}_{k+1} = \arg \min_{\mathbf{x}} \frac{L}{2} \left\| \mathbf{x} - \left(\mathbf{x}_k - \frac{1}{L} \nabla f(\mathbf{x}_k) \right) \right\|_2^2 + \lambda \|\mathbf{x}\|_1$$

□ 令 $\mathbf{z} = \mathbf{x}_k - 1/L \nabla f(\mathbf{x}_k)$, 上式有闭式解 $x_{k+1}^i = \begin{cases} z^i - \lambda/L, & \lambda/L < z^i; \\ 0, & |z^i| \leq \lambda/L; \\ z^i + \lambda/L, & z^i < -\lambda/L, \end{cases}$

嵌入式特征选择一般流程



应用例子

Heart Disease Dataset

Public Health Dataset

1. age
2. sex
3. chest pain type (4 values)
4. resting blood pressure
5. serum cholestoral in mg/dl
6. fasting blood sugar > 120 mg/dl
7. resting electrocardiographic results (values 0,1,2)
8. maximum heart rate achieved
9. exercise induced angina
10. oldpeak = ST depression induced by exercise relative to rest
11. the slope of the peak exercise ST segment
12. number of major vessels (0-3) colored by flourosopy
13. thal: 0 = normal; 1 = fixed defect; 2 = reversable defect

患者的姓名和社会保险号码最近从数据库中删除，取而代之的是虚拟值。

Kaggle数据集[1025 rows x 14 columns]



应用例子

```
> head(df, 10)
```

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target
1	52	1	0	125	212	0	1	168	0	1.0	2	2	3	0
2	53	1	0	140	203	1	0	155	1	3.1	0	0	3	0
3	70	1	0	145	174	0	1	125	1	2.6	0	0	3	0
4	61	1	0	148	203	0	1	161	0	0.0	2	1	3	0
5	62	0	0	138	294	1	1	106	0	1.9	1	3	2	0
6	58	0	0	100	248	0	0	122	0	1.0	1	0	2	1
7	58	1	0	114	318	0	2	140	0	4.4	0	3	1	0
8	55	1	0	160	289	0	0	145	1	0.8	1	1	3	0
9	46	1	0	120	249	0	0	144	0	0.8	2	0	3	0
10	54	1	0	122	286	0	0	116	1	3.2	1	2	2	0


```
> summary(df)
```

age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang
Min. :29.00	0:312	0:497	Min. : 94.0	Min. :126	0:872	0:497	Min. : 71.0	0:680
1st Qu.:48.00	1:713	1:167	1st Qu.:120.0	1st Qu.:211	1:153	1:513	1st Qu.:132.0	1:345
Median :56.00		2:284	Median :130.0	Median :240		2: 15	Median :152.0	
Mean :54.43		3: 77	Mean :131.6	Mean :246			Mean :149.1	
3rd Qu.:61.00			3rd Qu.:140.0	3rd Qu.:275			3rd Qu.:166.0	
Max. :77.00			Max. :200.0	Max. :564			Max. :202.0	

oldpeak	slope	ca	thal	target
Min. :0.000	0: 74	0:578	0: 7	0:499
1st Qu.:0.000	1:482	1:226	1: 64	1:526
Median :0.800	2:469	2:134	2:544	
Mean :1.072		3: 69	3:410	
3rd Qu.:1.800		4: 18		
Max. :6.200				


应用例子

岭回归：当正则化的 λ 参数越大，模型的参数估计就越小，一些无关变量的系数就会趋向于0。



应用例子

LASSO回归：系数的值会受到L1正则惩罚，以至于它可以为零，所以lasso可以实现剔除某些无关变量达到变量选择的效果



本章小结

- 特征选择：子集选择（前向搜索、后向搜索）、子集评价
 - 过滤式选择：先过滤初始特征，再训练模型
 - 通过信息增益对特征进行衡量（信息增益）
 - 包裹式选择
 - 通过是否对后续学习任务有用对特征进行衡量（模型准确率）
 - 嵌入式选择：用 L_1 正则化
 - L_1 正则化会导致稀疏特征，间接实现特征选择。